

TRƯỜNG ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH HỆ THỐNG THÔNG TIN

ỨNG DỤNG CÁC KỸ THUẬT GIẢI THÍCH MÔ HÌNH ĐỂ PHÂN TÍCH KẾT QUẢ CHẨN ĐOÁN BỆNH TRÊN DỮ LIỆU METAGENOMICS

Sinh viên: **Đặng Ngọc Xuân Đài**
Mã số: **B2003731**
Khóa: **46**

Cần Thơ, 2024

TRƯỜNG ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH HỆ THỐNG THÔNG TIN

**ỨNG DỤNG CÁC KỸ THUẬT GIẢI THÍCH MÔ
HÌNH ĐỂ PHÂN TÍCH KẾT QUẢ CHẨN ĐOÁN
BỆNH TRÊN DỮ LIỆU METAGENOMICS**

Người hướng dẫn
TS. Nguyễn Thanh Hải

Sinh viên: **Đặng Ngọc Xuân Đài**
Mã số: **B2003731**
Khóa: **46**

Cần Thơ, 12/2024

XÁC NHẬN CHỈNH SỬA LUẬN VĂN THEO YÊU CẦU CỦA HỘI ĐỒNG

Tên luận văn (tiếng Việt và tiếng Anh):

Ứng dụng các kỹ thuật giải thích mô hình để phân tích kết quả chẩn đoán bệnh trên dữ liệu metagenomics

Leveraging Explainable Artificial Intelligence for disease diagnosis result analysis on metagenomic data

Họ tên sinh viên: Đặng Ngọc Xuân Đài

MASV: B2003731

Mã lớp: DI2095A1

Đã báo cáo tại hội đồng ngành: Hệ thống thông tin

Ngày báo cáo: 07/12/2024

Luận văn đã được chỉnh sửa theo góp ý của Hội đồng.

Cần Thơ, ngày 15 tháng 12 năm 2024

Giáo viên hướng dẫn

(Ký và ghi họ tên)

Nguyễn Thanh Hải

LỜI CẢM ƠN

Để hoàn thành luận văn với đề tài là “Ứng dụng các kỹ thuật giải thích mô hình để phân tích kết quả chẩn đoán bệnh trên dữ liệu metagenomics”, bên cạnh sự cố gắng nỗ lực không ngừng của bản thân, trước tiên em xin được bày tỏ lòng biết ơn chân thành sâu sắc đến cha mẹ đã cố vũ, động viên, hỗ trợ về tinh thần cũng như tạo mọi điều kiện thuận lợi cho em hoàn thành tốt bài luận văn này.

Em xin chân thành cảm ơn thầy Nguyễn Thanh Hải, người hướng dẫn trực tiếp cho em. Thầy đã góp ý, hướng dẫn em tìm hiểu thêm nhiều kiến thức mới, giúp đỡ em rất nhiều trong quá trình nghiên cứu. Cảm ơn thầy đã luôn quan tâm chỉ dạy, theo dõi, và giúp đỡ tận tình để em có thể thực hiện luận văn của mình một cách tốt nhất. Luận văn này là sản phẩm đào tạo của đề tài T2024-87, được thực hiện trong khuôn khổ các nghiên cứu khoa học và đào tạo tại trường.

Và hơn hết, em xin bày tỏ lòng biết ơn trân trọng đến quý thầy cô Trường Công Nghệ Thông Tin và Truyền Thông nói chung và quý thầy cô bộ môn Hệ Thống Thông Tin nói riêng đã tận tình chỉ dạy, truyền đạt những kiến thức quý báu cho em trong thời gian vừa qua để em có đủ kiến thức, tạo điều kiện cho em có cơ hội học tập, giúp em có được nền tảng kiến thức quý báu để thực hiện luận văn này. Đồng thời em cũng rất biết ơn các cán bộ trực ở thư viện, trung tâm học liệu, phòng máy... đã hỗ trợ giúp đỡ em trong thời gian qua.

Đồng cảm ơn đến các tác giả trong các quyển sách báo, Internet, các anh chị đi trước đã tìm tòi, nghiên cứu đúc kết kinh nghiệm làm tài liệu để em có thể tham khảo trong quá trình thực hiện luận văn.

Sau cùng xin cảm ơn các bạn cùng lớp Hệ Thống Thông Tin, Trường Công Nghệ Thông Tin và Truyền Thông, Trường Đại học Cần Thơ đã tận tình giúp đỡ, hỗ trợ cho em thực hiện luận văn này.

Tuy nhiên, do kiến thức chuyên môn còn hạn chế, báo cáo của em không thể tránh khỏi những thiếu sót. Do đó, em mong nhận được sự góp ý và chỉ bảo quý giá từ quý thầy cô và các cán bộ hướng dẫn, nhằm giúp báo cáo này được hoàn thiện hơn.

Em xin chân thành cảm ơn!

LỜI CAM ĐOAN

Em tên Đặng Ngọc Xuân Đài, Mã số sinh viên: B2003731, xin cam đoan các nội dung kết quả nghiên cứu được trình bày trong luận văn như sau:

1. Các phần kết quả đưa vào luận văn từ các nghiên cứu khác để so sánh, phân tích được trích dẫn đầy đủ.
2. Kết quả trình bày trong luận văn được hoàn thành dựa trên các kết quả nghiên cứu mà em đã tham gia thực hiện. Các kết quả của nghiên cứu này chưa được dùng cho bất cứ luận văn cùng cấp của các tác giả nào khác. Các kết quả trình bày là trung thực, em không ngụy tạo kết quả.

Cần Thơ, ngày 05 tháng 12 năm 2024

Người cam đoan

Đặng Ngọc Xuân Đài

TÓM TẮT

Metagenomics là một lĩnh vực nghiên cứu tiên tiến, đã cách mạng hóa việc nghiên cứu vật liệu di truyền được chiết xuất từ các mẫu môi trường. Lĩnh vực này có ứng dụng rộng rãi, từ nghiên cứu môi trường đến sức khỏe con người, đặc biệt trong việc hiểu hệ vi sinh vật đường ruột. Tuy nhiên, việc áp dụng trí tuệ nhân tạo (AI) vào chẩn đoán bệnh vẫn còn phức tạp, đòi hỏi các phương pháp giải thích để làm rõ cách AI đưa ra quyết định. Trong luận văn này, chúng tôi hướng đến việc cải thiện khả năng dự đoán bệnh bằng cách áp dụng các kỹ thuật AI giải thích (XAI) như LIME, ALIME, SHAP, DiCE, cùng với hai mô hình máy học cơ bản là Random Forest (RF) và Gradient Boosting Classifier (GBC). Mục tiêu là xác định phương pháp hiệu quả nhất, đồng thời khám phá các đặc trưng mới có khả năng gây bệnh hoặc không gây bệnh, dựa trên từng mẫu và yếu tố địa lý. Nghiên cứu tập trung vào phân loại bệnh ung thư đại trực tràng (CRC) trên bốn tập dữ liệu metagenomics. Kết quả thực nghiệm và so sánh giữa các phương pháp XAI khác nhau cho thấy tiềm năng trong việc cải thiện độ chính xác dự đoán bệnh. Đồng thời, một số đặc trưng ảnh hưởng đến CRC đã được xác định, nhấn mạnh vai trò của XAI trong việc chẩn đoán bệnh và mở ra các hướng nghiên cứu sâu hơn trong lĩnh vực này. Các phát hiện từ nghiên cứu không chỉ đóng góp vào việc nâng cao hiệu quả phân loại bệnh mà còn mở ra triển vọng mới cho nghiên cứu metagenomics và bệnh CRC trong tương lai.

Từ khóa: *Giải thích kết quả của các thuật toán trí tuệ nhân tạo, Metagenomics, Ung thư đại trực tràng, Dự đoán bệnh*

ABSTRACT

Metagenomics is a cutting-edge field that has revolutionized the study of genetic material extracted from environmental samples. Its applications span diverse areas, from environmental research to human health, particularly in understanding the gut microbiome. However, the application of artificial intelligence(AI) in disease diagnosis remains complex, necessitating interpretable methods to elucidate the decision-making processes of AI models. In this thesis, we aim to enhance disease prediction by applying explainable AI(XAI) techniques, including LIME, ALIME, SHAP, DiCE, and two fundamental machine learning models, Random Forest(RF) and Gradient Boosting Classifier(GBC). Our goal is to identify the most effective and suitable methods while exploring novel findings, such as identifying new features that may contribute to or mitigate disease, based on individual samples and geographical factors. The study focuses on classifying colorectal cancer(CRC) using four metagenomic datasets. Experimental results and comparisons between different XAI methods reveal the potential of XAI to improve disease prediction accuracy. Moreover, several features influencing CRC have been identified, underscoring the value of XAI in disease diagnosis and paving the way for further exploration in this domain. These findings emphasize the role of XAI in advancing metagenomic research and CRC studies, opening new directions for deeper investigations into disease mechanisms and diagnostic improvements.

Keywords: *Explainable Artificial Intelligence, Metagenomics, Colorectal Cancer, Disease Prediction*

MỤC LỤC

Mục lục	ix
Danh sách Hình	xi
Danh sách Bảng	xiii
1 GIỚI THIỆU VÀ MÔ TẢ BÀI TOÁN	1
1.1 Giới thiệu	2
1.2 Đặt vấn đề	6
1.3 Các nghiên cứu liên quan	7
1.4 Mục tiêu đề tài	13
1.5 Đối tượng và phạm vi đề tài	13
1.6 Nội dung đề tài	14
1.7 Những đóng góp chính của đề tài	15
1.8 Bố cục của luận văn	15
1.9 Tổng kết chương	16
2 MÔ TẢ BÀI TOÁN	17
2.1 Mô tả chi tiết bài toán	18
2.1.1 Mô tả dữ liệu	19
2.2 Hướng tiếp cận giải quyết của đề tài	20
2.2.1 Hướng tiếp cận thứ 1: Sử dụng mô hình AI và các kỹ thuật XAI để phát hiện các đặc trưng quan trọng	20
2.2.2 Hướng tiếp cận thứ 2: Áp dụng các phương pháp XAI: LIME, ALIME, SHAP, và DiCE	21
2.2.3 Hướng tiếp cận thứ 3: Thực nghiệm trên dữ liệu với các mẫu và số lượng đặc trưng khác nhau	22
2.3 Tổng kết chương	22
3 THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP	23
3.1 Kiến trúc tổng quát hệ thống	24
3.1.1 LIME	26
3.1.2 ALIME	28
3.1.3 SHAP	32
3.1.4 DiCE	35
3.2 Xây dựng các mô hình	39
3.2.1 RF model	39
3.2.2 GBC model	40
3.3 Giải pháp cài đặt	41

3.4	Tổng kết chương	41
4	KIỂM THỬ VÀ ĐÁNH GIÁ	43
4.1	Môi trường thực nghiệm và cách đánh giá	44
4.1.1	Môi trường cài đặt	44
4.1.2	Các độ đo đánh giá hiệu quả	44
4.2	Kịch bản kiểm thử	46
4.3	Kết quả kiểm thử	46
4.3.1	LIME	49
4.3.2	ALIME	64
4.3.3	SHAP	78
4.3.4	DiCE	95
4.4	Thảo luận kết quả	111
4.5	So sánh kết quả với các bài báo trước	114
4.6	Tổng kết chương	116
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	117
5.1	Kết luận	117
5.2	Hạn chế	118
5.3	Hướng phát triển	118
	tài liệu tham khảo	131
A	Ý NGHĨA CỦA OTU	133
B	HƯỚNG DẪN CODE CHẠY THỰC NGHIỆM	137

DANH SÁCH HÌNH VẼ

2.1	Dataset	19
3.1	Quy trình giải thích mô hình AI.	24
3.2	Các bước chính của LIME.	27
3.3	Các bước chính của ALIME.	29
3.4	Các bước chính của SHAP.	34
3.5	Các bước chính của DiCE.	37
4.1	Biểu đồ minh họa giá trị AUC của RF và GBC trên 4 phương pháp XAI . .	46
4.2	Biểu đồ biến thiên giá trị AUC của dữ liệu gốc với mô hình RF	47
4.3	Biểu đồ biến thiên giá trị AUC của dữ liệu gốc với mô hình GBC	48
4.4	Biểu đồ Min-Max trọng số LIME của 50 đặc trưng quan trọng	49
4.5	Biểu đồ phân phối trọng số LIME 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC	50
4.6	Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên	51
4.7	Dự đoán của LIME với bộ dataset của bệnh CRC	52
4.8	Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên . . .	54
4.9	Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên	55
4.10	Biểu đồ Min-Max trọng số LIME của 50 đặc trưng quan trọng	56
4.11	Biểu đồ phân phối trọng số LIME 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC	57
4.12	Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên	58
4.13	Dự đoán của LIME với bộ dataset của bệnh CRC	59
4.14	Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên . . .	61
4.15	Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên	62
4.16	Biểu đồ Min-Max trọng số ALIME của 50 đặc trưng quan trọng	64
4.17	Biểu đồ phân phối trọng số ALIME 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC	65
4.18	Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên	66
4.19	Dự đoán của ALIME với bộ dataset của bệnh CRC	67
4.20	Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên . . .	69
4.21	Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên	70
4.22	Biểu đồ Min-Max trọng số LIME của 50 đặc trưng quan trọng	71

4.23	Biểu đồ phân phối trọng số LIME 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC	72
4.24	Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên	73
4.25	Dự đoán của ALIME với bộ dataset của bệnh CRC	74
4.26	Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên	76
4.27	Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên	77
4.28	Biểu đồ Min-Max trọng số SHAP của 50 đặc trưng quan trọng	79
4.29	Biểu đồ phân phối trọng số SHAP 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC	79
4.30	Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên	81
4.31	Biểu đồ dự đoán SHAP với bộ dữ liệu Yu.	82
4.32	Biểu đồ dự đoán SHAP với bộ dữ liệu Feng.	82
4.33	Biểu đồ dự đoán SHAP với bộ dữ liệu Zeller.	83
4.34	Biểu đồ dự đoán SHAP với bộ dữ liệu Vogtmann.	83
4.35	Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên	84
4.36	Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên	86
4.37	Biểu đồ Min-Max trọng số SHAP của 50 đặc trưng quan trọng	87
4.38	Biểu đồ phân phối trọng số SHAP 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC	88
4.39	Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên	89
4.40	Biểu đồ dự đoán SHAP với bộ dữ liệu Yu.	90
4.41	Biểu đồ dự đoán SHAP với bộ dữ liệu Feng.	90
4.42	Biểu đồ dự đoán SHAP với bộ dữ liệu Zeller.	90
4.43	Biểu đồ dự đoán SHAP với bộ dữ liệu Vogtmann.	91
4.44	Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên	92
4.45	Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên	93
4.46	Biểu đồ Min-Max trọng số DiCE của 50 đặc trưng quan trọng	95
4.47	Biểu đồ phân phối trọng số DiCE 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC	96
4.48	Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên	97
4.49	Biểu đồ dự đoán DiCE với bộ dữ liệu Yu.	98
4.50	Biểu đồ dự đoán DiCE với bộ dữ liệu Feng.	98
4.51	Biểu đồ dự đoán DiCE với bộ dữ liệu Zeller.	99
4.52	Biểu đồ dự đoán DiCE với bộ dữ liệu Vogtmann.	99
4.53	Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên	101
4.54	Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên	102
4.55	Biểu đồ Min-Max trọng số DiCE của 50 đặc trưng quan trọng	103
4.56	Biểu đồ phân phối trọng số DiCE 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC	104

4.57	Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên	105
4.58	Biểu đồ dự đoán DiCE với bộ dữ liệu Yu.	106
4.59	Biểu đồ dự đoán DiCE với bộ dữ liệu Feng.	106
4.60	Biểu đồ dự đoán DiCE với bộ dữ liệu Zeller.	107
4.61	Biểu đồ dự đoán DiCE với bộ dữ liệu Vogtmann.	107
4.62	Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên . . .	109
4.63	Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên	110
B.1	Các dòng lệnh thực nghiệm của tập Yu	137
B.2	Các dòng lệnh thực nghiệm của tập Feng	137
B.3	Các dòng lệnh thực nghiệm của tập Zeller	138
B.4	Các dòng lệnh thực nghiệm của tập Vogtmann	138
B.5	Các dòng lệnh của dữ liệu gốc.	139

DANH SÁCH BẢNG

1	Các ký hiệu viết tắt được dùng trong báo cáo và diễn giải.	xv
3.1	Điểm khác nhau của LIME và ALIME	32
4.1	Bảng giá trị AUC của mô hình RF	46
4.2	Bảng giá trị AUC của mô hình GBC	46
4.3	Kết quả so sánh độ đo AUC với nghiên cứu trước	114
A.1	Bảng đối chiếu OTU	133

DANH MỤC BẢNG VIẾT TẮT

Bảng 1. Các ký hiệu viết tắt được dùng trong báo cáo và diễn giải.

Chữ viết tắt	Chữ đầy đủ
AI	Artificial Intelligence
ALIME	Anchored Local Interpretable Model-Agnostic Explanations
ANN	Artificial Neural Network
ARGs	Antibiotic Resistance Genes
ASD	Autism Spectrum Disorder
CNS	Central Nervous System
CRC	Colorectal Cancer
DiCE	Diverse Counterfactual Explanations
DNN	Deep Neural Network
DNA	Deoxyribonucleic Acid
DT	Decision Tree
GBC	Gradient Boosting Classifier
GMM	Gaussian Mixture Model
GNB	Gaussian Naive Bayes
HC	Healthy Control
IDS	Intrusion Detection System
KNN	K-Nearest Neighbors
LIME	Local Interpretable Model-Agnostic Explanations
LPS	Lipopolysaccharide
LRP	Layer-wise Relevance Propagation
MCI	Mild Cognitive Impairment
MG	Myasthenia Gravis
MGEs	Mobile Genetic Elements
MLP	Multi-layer Perceptron
mNGs	Metagenomic Next-Generation Sequencing
PCOS	Polycystic Ovary Syndrome
ONT	Oxford Nanopore Technologies
RF	Random Forest
RP	Radiation Pneumonitis
SCGAN	Semi-Conditional Generative Adversarial Network
SHAP	Shapley Additive Explanations
SVC	Support Vector Classifier
VAE	Variational Autoencoder
XAI	Explainable Artificial Intelligence

GIỚI THIỆU VÀ MÔ TẢ BÀI TOÁN

1.1	Giới thiệu	2
1.2	Đặt vấn đề	6
1.3	Các nghiên cứu liên quan	7
1.4	Mục tiêu đề tài	13
1.5	Đối tượng và phạm vi đề tài	13
1.6	Nội dung đề tài	14
1.7	Những đóng góp chính của đề tài	15
1.8	Bố cục của luận văn	15
1.9	Tổng kết chương	16

Chương này đã giới thiệu vấn đề cơ bản và các đóng góp mà đề tài này sẽ làm để phát triển đề tài về Metagenomics. Metagenomics là một chủ đề rộng lớn nên việc nghiên cứu chuyên sâu và có những đóng góp mới cho lĩnh vực này vừa là cơ hội vừa là thách thức. Cùng với đó là làm quen với một khái niệm mới XAI (Explainable AI) và cách áp dụng các phương pháp XAI này. Phần còn lại của nghiên cứu này được tổ chức như sau: Chương 2 sẽ mô tả tập dữ liệu, các hướng tiếp cận đề tài, bốn phương pháp XAI sử dụng cùng với hai mô hình RF và GBC. Chương 3 trình bày các kiến trúc tổng quát của cả đề tài và các luồng xử lý của các phương pháp XAI được sử dụng trong bài luận văn này. Chương 4 là các kết quả sau khi thực nghiệm và tóm tắt kết luận. Chương 5 mô tả ngắn gọn công việc có thể thực hiện trong tương lai theo hướng này và kết luận tầm quan trọng của nghiên cứu.

1.1 Giới thiệu

Metagenomics là một lĩnh vực nghiên cứu phát triển nhanh chóng nhờ vào những tiến bộ của khoa học kỹ thuật hiện đại. Dù không hoàn toàn mới đối với giới khoa học nhưng lĩnh vực này đã chứng kiến sự bùng nổ trong việc áp dụng các phương pháp tính toán trong nghiên cứu metagenomics những năm gần đây. Nghiên cứu về bộ gen vi sinh vật bắt đầu từ cuối những năm 1970. Tuy nhiên với số lượng lớn bộ gen vi khuẩn, nhưng chỉ một tỷ lệ nhỏ vi khuẩn trong tự nhiên có thể nuôi cấy và rất hiếm khi vi khuẩn cùng loài tương tác cùng nhau trong môi trường sống. Do đó việc nuôi cấy vô tính sẽ không thể hiện được sự tương tác lẫn nhau giữa các vi khuẩn và sự biến đổi của chúng với các kết quả sinh học khác nhau.

Cũng chính vì điều này đã thúc đẩy các nhà khoa học nghiên cứu để các công nghệ giải trình tự mới khắc phục những hạn chế trên. Vào năm 1998, thuật ngữ "metagenome" mới được giới thiệu bởi tác giả Jo Handelsman [1]. Metagenome được định nghĩa là tập hợp tất cả các vật liệu di truyền (DNA) được phân lập trực tiếp từ một mẫu môi trường cụ thể. Nó bao gồm toàn bộ gen của tất cả các vi sinh vật có mặt trong mẫu đó, không chỉ giới hạn ở một loài cụ thể. Tiếp theo đó vào năm 2000, người ra nghiên cứu ra dữ liệu trình tự trực tiếp từ môi trường gọi là metagenomics[2]. Metagenomics, hay còn gọi là di truyền học môi trường, di truyền học sinh thái hoặc di truyền học quần xã, là phương pháp nghiên cứu đa hệ gen của tất cả vi sinh vật thu thập trực tiếp từ môi trường tự nhiên mà không qua nuôi cấy. Thực chất, metagenomics là một lĩnh vực nghiên cứu liên quan đến việc phân tích các bộ gen từ một mẫu môi trường mà không cần phải nuôi cấy các vi sinh vật riêng lẻ. Điều này cho phép các nhà khoa học khám phá và hiểu biết sâu hơn về đa dạng sinh học của các hệ vi sinh vật, các mối quan hệ sinh thái và vai trò của chúng trong các hệ sinh thái tự nhiên cũng như nhân tạo. Tác giả Kevin Chen đã định nghĩa metagenomics là "việc ứng dụng các kỹ thuật di truyền hiện đại để nghiên cứu quần xã vi sinh vật trực tiếp trong môi trường tự nhiên của chúng mà không cần phải phân lập và nuôi cấy trong phòng thí nghiệm"[3]. Điều này cho phép chúng ta thu được thông tin bộ gen trực tiếp từ các cộng đồng vi sinh vật trong môi trường sống tự nhiên của chúng, thay vì chỉ xem xét một vài loài riêng lẻ, chúng ta có thể nghiên cứu hàng chục nghìn loài cùng lúc. Với sự ra đời của các kỹ thuật giải trình tự thế hệ tiếp theo, các bộ dữ liệu trình tự môi trường ngày càng phức tạp đã được tạo ra, từ đó dẫn đến sự phát triển của các công cụ sinh học để phân tích, so sánh và nghiên cứu nhiều hơn về các bộ dữ liệu này.

Quá trình nghiên cứu metagenomics bao gồm việc thu thập mẫu, chiết xuất DNA, giải trình tự DNA cho ra các mã gen (ATCG) và phân tích dữ liệu. Các metagenome có thể được thu thập từ nhiều nguồn khác nhau như đất, biển, bùn, rừng, thực vật, động vật, không gian và thậm chí trong cơ thể con người,... đôi khi được thu thập từ các mẫu thủy sinh, trên cạn, đường ruột, hoặc phân. Các vi sinh vật trong các môi trường này có thể bao gồm vi khuẩn, virus, nấm, giun,... Tiếp theo, DNA được chiết xuất từ mẫu để thu thập toàn bộ thông tin di truyền từ tất cả các vi sinh vật có mặt trong mẫu. Các công nghệ giải trình tự như Illumina, PacBio, hay Oxford Nanopore được sử dụng để giải mã các đoạn DNA đã chiết xuất [4]. Và cuối cùng, các đoạn DNA được giải trình tự sẽ được gắn kết, chú thích, và phân tích để xác định các loài vi sinh vật có mặt và chức năng của chúng. Sự thành công của metagenomics phụ thuộc rất lớn vào các phần mềm tin sinh học và nguồn dữ liệu thu thập được.

Metagenomics có nhiều ứng dụng tiềm năng trong y học và vi sinh vật môi trường. Một trong những nghiên cứu tiêu biểu trong lĩnh vực y học là của tác giả Mingyue Cheng [5], họ đã tóm tắt các chiến lược phân tích hiện tại trong khai thác dữ liệu lớn về microbiome, bao gồm công nghệ giải trình tự đơn bào và metagenomics. Bên cạnh đó bài báo thảo luận về mối liên hệ giữa microbiome đường ruột với các cơ quan và bệnh lý của cơ thể, đồng thời đề xuất các xu hướng khai thác dữ liệu lớn trong microbiome bằng cách tiếp cận đa omics và giải trình tự đơn bào. Vào năm 2022, Svetoslav Nanev Slavov đã nghiên cứu việc ứng dụng metagenomics virus trong y học truyền máu để xác định các virus mới nổi [6]. Metagenomics virus giúp phát hiện các virus chưa biết hoặc chưa được mô tả rõ ràng từ các mẫu lâm sàng, bao gồm mẫu máu. Việc phân tích "virome máu" của người hiến máu khỏe mạnh có thể phát hiện các virus mới nổi tiềm ẩn nguy cơ lây nhiễm qua truyền máu. Metagenomics lâm sàng bằng giải trình tự thế hệ mới (mNGS) đang chuyển từ nghiên cứu sang ứng dụng trong các phòng thí nghiệm lâm sàng, thay đổi cách chẩn đoán và điều trị bệnh nhiễm trùng. Trong bài báo của Charles Y. Chiu, tác giả đã đề xuất phương pháp này với nhiều ứng dụng, bao gồm kháng kháng sinh, microbiome, biểu hiện gen của người ở bệnh ung thư [7]. Bài viết tập trung vào các thách thức khi triển khai mNGS trong phòng thí nghiệm lâm sàng và đưa ra các giải pháp tiềm năng để tối đa hóa ảnh hưởng của nó đối với chăm sóc bệnh nhân và sức khỏe cộng đồng.

Trong lĩnh vực nông nghiệp, người ta cũng đã nghiên cứu phân tích metagenomics tiết lộ vai trò quan trọng của các cộng đồng vi sinh vật trong duy trì hệ sinh thái nông nghiệp, ảnh hưởng đến sức khỏe và năng suất cây trồng [8]. Các vi sinh vật trong đất, đặc biệt là vi khuẩn và nấm, tham gia vào chu trình dinh dưỡng, chuyển đổi các nguyên tố như nitơ, photpho và kali thành dạng mà cây trồng có thể hấp thụ, cải thiện độ phì nhiêu của đất và dinh dưỡng cây trồng. Ngoài ra, chúng sản xuất hormone và hóa chất thúc đẩy tăng trưởng cây, giúp kiểm soát sinh học bệnh cây và giảm sự phụ thuộc vào thuốc trừ sâu hóa học. Các vi sinh vật còn giúp cây trồng đối phó với các "stress" phi sinh học như hạn hán, độ mặn và nhiệt độ cực đoan, đóng vai trò quan trọng trong hệ thống nông nghiệp bền vững và thích ứng với biến đổi khí hậu. Cụ thể như bài viết của Kedibone Masenya, tác giả đã cho thấy vai trò của metagenomics trong ngũ cốc giúp tăng cường an ninh lương thực thông qua việc khám phá các tương tác vi sinh vật có lợi và gây bệnh [9]. Gần đây, tác giả Vidya Niranjan đã cho ra bài báo nghiên cứu sử dụng phân tích metagenomics để khám phá đa dạng phân loại và tiềm năng chức năng của các cộng đồng vi sinh vật trong đất trồng dâu tằm, đặc biệt tập trung vào vùng rễ [10]. Các loài vi khuẩn quan trọng như *Pseudomonas*, *Frankia* và *Azospirillum* được xác định, cho thấy vai trò của chúng đối với sức khỏe và bệnh tật của cây dâu tằm. Bằng cách kết hợp giải trình tự cao thông lượng và tin sinh học, nghiên cứu xác định các chất chuyển hóa tiềm năng làm phân bón sinh học và thuốc trừ sâu sinh học, nhằm cải thiện tính bền vững trong nông nghiệp. Phương pháp metagenomics cũng đã tiết lộ sự di động và sự xuất hiện đồng thời của resistomes kháng sinh giữa môi trường nuôi trồng thủy sản không tập trung và con người. Nuôi trồng thủy sản là một nguồn thực phẩm quan trọng trên toàn thế giới. Sự sử dụng rộng rãi kháng sinh trong các trang trại quy mô lớn đã dẫn đến sự phát triển kháng chống lại kháng sinh như trong nghiên cứu của tác giả Li Tian [11] đã nói đến vấn đề này.

Trong lĩnh vực môi trường, tác giả Cátia Santos-Pereira đã tập trung vào vai trò của

metagenomics trong khám phá đa dạng sinh học vi sinh vật và tiềm năng sinh học của môi trường có độ mặn cao cực độ [12]. Các môi trường cực độ hình thành cộng đồng vi sinh vật độc đáo với những đặc điểm và khả năng đặc biệt. Metagenomics là phương pháp mạnh mẽ và tinh vi cho phép khai thác động vật vi sinh vật chưa được khai thác của các môi trường cực độ, giúp khắc phục các thách thức trong việc nuôi cấy chúng và đánh giá khả năng sản xuất các sản phẩm sinh học. Năm 2023, tác giả Elisa Banchi đã đề xuất phương pháp gen hóa giải thông qua metagenomics để khám phá vi khuẩn trong cát mặt của Vịnh Venice, tiết lộ khả năng sinh học cao và tính linh hoạt của chúng [13]. Vi khuẩn trong cát có vai trò quan trọng trong hệ sinh thái biển và những thông tin sâu hơn về sinh thái học và sinh hóa học của những hợp chất chưa được khai thác này có thể được tìm thấy từ các phương pháp "omics".

Với lĩnh vực công nghiệp, tác giả Qiuyue Xie và Zedong Zhang vào năm 2023 đã nghiên cứu điều tra khả năng của esterase ưa nhiệt từ thư viện metagenomics trong việc xử lý nước trắng sản xuất giấy thô với dung môi hữu cơ ở nhiệt độ cao [14]. Esterase ưa nhiệt được cố định trên chất nhựa xốp, giúp tăng cường ổn định và chịu nhiệt. Vào năm 2024, tác giả Linjun Gao đã sử dụng phân tích metagenomics để khám phá sự phân bố, chức năng và các vi khuẩn chủ của các gen phân hủy trong bùn hoạt tính từ các nhà máy xử lý nước thải công nghiệp [15]. Các gen phân hủy liên quan đến các hợp chất hữu cơ như benzoates, biphenyls, triazines, nitrotoluenes và các hợp chất thơm clo hóa phổ biến hơn trong mẫu công nghiệp so với mẫu đô thị. Nghiên cứu cũng chỉ ra rằng các vi khuẩn chủ quan trọng như *Bradyrhizobium*, *Hydrogenophaga* và *Mesorhizobium* có vai trò chính trong việc mang các gen phân hủy này, cung cấp thông tin quan trọng để phát triển các chiến lược xử lý nước thải công nghiệp hiệu quả hơn. Nghiên cứu của tác giả Andréia O. Santos này đã nhấn mạnh vai trò của metagenomics trong việc chuyển đổi các dư lượng lignocellulosic thành nguồn tài nguyên sinh học có giá trị cao [16]. Lignocellulosic biomass, mặc dù có tiềm năng lớn, vẫn chưa được khai thác hiệu quả do đặc tính kháng cự của nó. Metagenomics có thể khám phá các enzyme mới và vi sinh vật thông qua các sàng lọc chức năng và trình tự, góp phần sản xuất các hợp chất sinh học có giá trị như nhiên liệu sinh học, hóa chất sinh học, polymer và chất xúc tác sinh học từ các môi trường chưa được khai thác.

Hầu hết mọi khía cạnh của cuộc sống con người, cũng như cuộc sống của mọi sinh vật khác đang ở trên hành tinh đều bị ảnh hưởng bởi vi khuẩn. Vì thế metagenomics cũng được ứng dụng nghiên cứu trong chăm sóc sức khỏe khi cơ thể con người có rất nhiều hệ vi sinh vật sinh sống, trên da, trong ruột, khoang miệng, khoang mũi, mắt,... Các vi sinh vật này có ảnh hưởng lớn đến sức khỏe cả hai mặt tốt lẫn xấu, hiệu quả sử dụng thuốc, khả năng hấp thu dinh dưỡng của con người như trong bài báo của tác giả Biniam Moges [17] và tác giả Rebeca Martín [18] đã đề cập. Cùng với việc xác định rõ đóng góp của hệ vi sinh vật cho sức khỏe, phát hiện, điều trị bệnh cho các cá thể, không chỉ với người mà động vật, thực vật cũng được phát triển các phương pháp điều trị mới trên cơ sở các kiến thức metagenomics. Một số nghiên cứu trên động vật như nghiên cứu của tác giả Kirsty T. T. Kwok giải trình tự gen thể hệ mới trong gia súc cho thấy lợn là loài được nghiên cứu nhiều nhất và mẫu từ gia cầm có sự đa dạng virus cao nhất [19]. Với sự phát triển nhanh chóng của công nghệ giải trình tự thể hệ cao, tác giả Ruirui Hu đã xuất bản bài báo trong đó cơ sở dữ liệu AnimalMetagenome DB tích hợp dữ liệu giải trình tự metagenomic với thông tin

về vật chủ, giúp người dùng dễ dàng tìm kiếm, duyệt và tải xuống dữ liệu metagenomic của động vật [20]. Với thực vật, vào năm 2024 tác giả Alhagie K Cham đã nghiên cứu sử dụng phần mềm Qmatey để phân tích metagenome liên quan đến lá khoai lang và phát hiện ra các mối tương quan tích cực giữa bộ phận trắng và các endosymbiont của nó [21]. Không chỉ khoai lang, người ta còn sử dụng phương pháp phân tích metagenomics dựa trên dữ liệu long-read để khảo sát gen của vi sinh vật trong phần môi trường lá của lúa như bài viết của tác giả Sachiko Masuda [22]. Metagenomics hiện nay cũng được áp dụng cho điều tra y tế hoặc pháp y như tạo điều kiện cho bước đột phá trong bệnh lý pháp y, độc tính học và xét nghiệm lạm dụng chất gây nghiện.

Ở Việt Nam hiện nay, phương pháp metagenomics cũng được nghiên cứu rộng rãi và thu thập dữ liệu phong phú. Việt Nam là một trong những nước sản xuất và xuất khẩu tôm hàng đầu thế giới, nhưng dịch bệnh do virus và vi khuẩn gây ra thiệt hại nặng nề cho ngành nuôi tôm, cùng với việc sử dụng kháng sinh không đúng cách dẫn đến sự gia tăng các mầm bệnh kháng thuốc. Nghiên cứu của tác giả Son Giang Nguyen về phân bố theo mùa của cộng đồng vi khuẩn và gen kháng kháng sinh (ARGs) ở hạ lưu sông Đáy, Ninh Bình đã sử dụng phương pháp metagenomics dựa trên giải trình tự cao để khảo sát [23]. Kết quả cho thấy sự phong phú và đa dạng của các ARGs và các yếu tố di truyền di động (MGEs) thay đổi theo mùa, với sự gia tăng trong mùa mưa. Các gen kháng đa thuốc và các yếu tố di truyền di động chiếm ưu thế nhất, gây nguy cơ cho sức khỏe tôm và con người. Một bài báo khác của tác giả Lan Anh Le về Ninh Thuận, khu vực chuyên sản xuất và nuôi tôm đã thu thập hai mẫu nước từ ao nuôi tôm để phân tích microbiome bằng công nghệ metagenomics của Oxford Nanopore Technologies (ONT) [24]. Dữ liệu này cung cấp cái nhìn sâu hơn về sự đa dạng và chức năng của cộng đồng vi sinh vật, giúp cải thiện quản lý sức khỏe ao nuôi và ngành nuôi tôm. Một bài báo của tác giả Nguyen To Anh về phân tích metagenomic virus trong dịch não tủy từ bệnh nhân bị nhiễm trùng hệ thần kinh trung ương (CNS) cấp tính không rõ nguyên nhân tại Việt Nam đã sử dụng công nghệ giải trình tự thế hệ mới [25]. Nghiên cứu đã phát hiện 8 loài virus trong 52,4% mẫu dịch não tủy, nhưng sau khi xác nhận bằng PCR, tỷ lệ phát hiện giảm xuống còn 14,7%, với enterovirus là loại virus phổ biến nhất. Kết quả cho thấy gánh nặng lâm sàng của enterovirus tại Việt Nam và nhấn mạnh những thách thức trong việc xác định tác nhân virus hợp lý trong dịch não tủy của bệnh nhân nhiễm trùng CNS. Tác giả Dinh Minh Tran vào năm 2022 đã ra bài báo phân tích microbiome vùng rễ của cây cà phê Robusta trồng tại Tây Nguyên, Việt Nam bằng phương pháp metagenomics dựa trên 16S rRNA [26]. Dữ liệu được thu thập từ mẫu đại diện gồm năm mẫu đất rễ của cây cà phê Robusta, cung cấp thông tin về sự đa dạng và chức năng của cộng đồng vi sinh vật vùng rễ. Kết quả này có thể hỗ trợ phát triển kỹ thuật canh tác bền vững cho sản xuất cà phê Robusta tại khu vực này.

Explainable Artificial Intelligence (XAI) là một lĩnh vực quan trọng trong khoa học dữ liệu, đặc biệt là trong các nghiên cứu yêu cầu sự minh bạch như metagenomics. XAI cung cấp các phương pháp và công cụ giúp con người hiểu và giải thích được các quyết định của mô hình học máy. Các phương pháp XAI không chỉ giúp giải thích cách thức mà các thuật toán phân tích và xử lý dữ liệu mà còn cung cấp thông tin về tầm quan trọng của từng đặc trưng trong việc tạo ra dự đoán hoặc kết quả.

Trong bối cảnh nghiên cứu metagenomics, XAI có vai trò rất quan trọng. Bởi vì dữ liệu metagenomics có tính đa dạng và phức tạp cao, việc áp dụng các phương pháp XAI có thể giúp các nhà khoa học hiểu rõ hơn về mối quan hệ giữa các vi sinh vật và các biến đổi trong hệ sinh thái. Các phương pháp XAI ngày càng phát triển góp phần vào việc xác định các đặc điểm vi sinh vật quan trọng, các yếu tố môi trường và vai trò của chúng đối với sức khỏe, năng suất nông nghiệp hoặc sự bền vững môi trường. Ví dụ, trong nghiên cứu về hệ vi sinh vật đường ruột hoặc đất, XAI có thể giúp xác định những loài vi sinh vật nào có ảnh hưởng lớn đến sức khỏe con người hoặc cây trồng, nhờ đó tối ưu hóa việc chăm sóc sức khỏe và sản xuất nông nghiệp. Trong các nghiên cứu metagenomics về bệnh truyền nhiễm, XAI có thể xác định các yếu tố hoặc nhóm gen tiềm năng có liên quan đến kháng thuốc, giúp cải thiện các phương pháp chẩn đoán và điều trị. XAI còn giúp các nhà khoa học đánh giá chính xác độ tin cậy của các dự đoán của mô hình trong các bối cảnh môi trường, từ đó tối ưu hóa chiến lược bảo vệ môi trường và tài nguyên thiên nhiên. Với sự kết hợp của metagenomics và XAI, lĩnh vực này không chỉ cho phép phân tích dữ liệu môi trường phức tạp mà còn cung cấp các thông tin mang tính giải thích cao để hỗ trợ ra quyết định trong nhiều lĩnh vực.

1.2 Đặt vấn đề

Metagenomics là một lĩnh vực nghiên cứu phức tạp, đòi hỏi kiến thức chuyên sâu về sinh học phân tử, sinh tin học và các công nghệ tiên tiến. Một trong những thách thức lớn nhất trong phân tích dữ liệu metagenomic là tìm ra và giải thích vai trò của các đặc trưng quan trọng trong chẩn đoán bệnh từ các mẫu dữ liệu phức tạp. Để thực hiện điều này, các nhà nghiên cứu thường dựa vào các kỹ thuật phân tích dữ liệu và các mô hình trí tuệ nhân tạo (AI) phức tạp, vốn đòi hỏi hiểu biết sâu về toán học và học máy. Đối với những người mới tiếp xúc với metagenomics, việc hiểu cách các mô hình AI đưa ra quyết định chẩn đoán là một thách thức lớn, bởi yêu cầu kiến thức cao về học máy và các thuật toán phân tích dữ liệu tiên tiến. Chính vì thế, các công cụ giải thích mô hình AI trở nên cần thiết, giúp cả người trong ngành lẫn ngoài ngành có thể hiểu rõ cách thức hoạt động của mô hình, xác định các đặc trưng quan trọng, hỗ trợ nghiên cứu và áp dụng kết quả phân tích hiệu quả.

Trong phân tích dữ liệu metagenomic, ML đóng vai trò quan trọng không chỉ trong các ứng dụng dữ liệu ADN mà còn trong các loại dữ liệu khác. Các thuật toán ML có khả năng học và dự đoán từ các mẫu dữ liệu dựa trên đặc trưng. Tuy nhiên, các mô hình ML thường được coi là "hộp đen" (black-box), thay vì các đặc trưng do chuyên gia xác định và áp dụng chúng theo cách phi tuyến tính cao, tức là có khả năng dự đoán chính xác nhưng khó hiểu và khó giải thích lý do tại sao một mẫu dữ liệu lại được phân vào một nhóm cụ thể [27]. Điều này có thể làm giảm độ tin cậy của kết quả và gây khó khăn khi hiểu rõ quyết định của mô hình.

AI và XAI là những khía cạnh khác nhau của AI với mục tiêu và đặc điểm riêng. Trong khi AI tập trung vào tự động hóa các hành vi thông minh, XAI lại nhắm đến việc giải thích lý do đằng sau các quyết định và dự đoán của hệ thống, từ đó giúp người dùng hiểu rõ hơn về cách thức mô hình hoạt động. Giải thích này mang lại sự minh bạch, công bằng, và giúp

nâng cao độ tin cậy khi dựa vào các quyết định của AI. Chẳng hạn, trong mô hình phát hiện ung thư từ hình ảnh hiển vi, giải thích của mô hình có thể chỉ ra các pixel cụ thể đóng góp vào phân loại bệnh.

Để giải quyết các vấn đề trên, nghiên cứu này áp dụng bốn phương pháp giải thích mô hình là LIME (Local Interpretable Model-agnostic Explanations), ALIME (Autoencoder-based Local Interpretable Model-agnostic Explanations), SHAP (SHapley Additive Explanations), và DICE (Diverse Counterfactual Explanations) nhằm tìm ra các đặc trưng quan trọng trong dữ liệu metagenomics phục vụ chẩn đoán bệnh. Mỗi phương pháp có cách tiếp cận riêng biệt: LIME và ALIME là các công cụ giải thích mô hình cục bộ, SHAP cung cấp phương pháp tiếp cận toàn diện tính toán mức độ đóng góp của từng đặc trưng, còn DICE tạo ra các phản chứng để làm rõ vai trò của các đặc trưng. Việc so sánh bốn phương pháp này giúp đánh giá điểm mạnh và hạn chế của từng phương pháp, từ đó xác định cách tiếp cận phù hợp nhất trong giải thích mô hình AI cho dữ liệu metagenomics, hỗ trợ nhà nghiên cứu và người dùng hiểu rõ hơn về các đặc trưng quan trọng trong dự đoán chẩn đoán bệnh.

1.3 Các nghiên cứu liên quan

Phương pháp XAI đang ngày càng phổ biến rộng rãi hơn và là một phần quan trọng giúp người nghiên cứu có thể đưa ra những quyết định một cách khách quan. Hiện nay có rất nhiều các phương pháp XAI được nghiên cứu nhưng đâu là phương pháp phù hợp và thích hợp nhất? Làm thế nào để chọn lựa phù hợp giữa các phương pháp XAI và nhu cầu của các bên liên quan trong bối cảnh ra quyết định tự động? Chính vì thế tác giả Tom Vermeire đã nghiên cứu một bài báo lập luận rằng cần có một phương pháp để kết nối nhu cầu của người dùng với các phương pháp giải thích, nhằm hỗ trợ các nhà khoa học dữ liệu trong việc cung cấp giải thích cho các bên liên quan [28]. Song song đó, vì những thiếu sót trong khả năng giải thích và tính minh bạch trong mối liên hệ giữa đầu vào và đầu ra. Vậy nên rất cần những nghiên cứu nhằm cải thiện khả năng giải thích và diễn giải của các mô hình học sâu, để giải quyết vấn đề "hộp đen" trong trí tuệ nhân tạo như trong bài báo của tác giả F. J. Duarte [29].

XAI được sử dụng rộng rãi vào việc nghiên cứu trong lĩnh vực y tế, đặc biệt là góp phần nhận biết các thành phần gây bệnh cũng như đưa ra các phương pháp khách quan trong việc điều trị nhiều loại bệnh. Trong bào báo của tác giả Bas H.M. vander Velden [30] đã cung cấp cái nhìn tổng quan về các kỹ thuật XAI trong phân tích ảnh y khoa dựa trên học sâu, đồng thời giới thiệu một khung phân loại cho các phương pháp này. Nghiên cứu phân loại các phương pháp XAI theo tiêu chí và vị trí giải phẫu, đồng thời thảo luận về các cơ hội phát triển trong tương lai của XAI trong lĩnh vực này. Cũng cùng đề tài này nhưng với cấp độ các chuyên gia bài báo của tác giả Satya M. Muddamsetty [31] đã thu thập các chú thích khi các chuyên gia phân loại hình ảnh y tế và phát triển phương pháp so sánh kết quả này với các giải thích từ các phương pháp XAI. Kết quả cho thấy phương pháp đánh giá cấp độ chuyên gia có hiệu quả trong nhiều thí nghiệm khác nhau. Tác giả Devam Dave [32] cũng nghiên cứu vai trò của XAI trong ngành y tế, nhấn mạnh tầm quan trọng của tính minh

bạch và khả năng giải thích trong các mô hình AI, đặc biệt là trong chẩn đoán y khoa. Tác giả giới thiệu các kỹ thuật giải thích khác nhau và sử dụng tập dữ liệu bệnh tim để minh họa cách các kỹ thuật này có thể tạo ra độ tin cậy trong việc áp dụng AI trong chăm sóc sức khỏe. Bài viết còn nhấn mạnh rằng sự tin tưởng vào các hệ thống AI có thể nâng cao khả năng ứng dụng của chúng trong lĩnh vực y tế. Nghiên cứu của tác giả Hamza Ahmed Shad vào năm 2021 đã khám phá khả năng dự đoán bệnh Alzheimer ở các giai đoạn khác nhau của bệnh thông qua việc sử dụng các mô hình mạng nơ-ron khác nhau và dữ liệu hình ảnh MRI [33]. Mặc dù có nhiều dữ liệu sinh học và tâm lý thần kinh hiện có, nhưng vẫn còn khó khăn trong việc phát hiện sớm bệnh Alzheimer ở những bệnh nhân bị suy giảm nhận thức nhẹ (MCI). Tác giả đã thử nghiệm các mô hình mạng nơ-ron hiện có, bao gồm Resnet50, VGG16 và Inception v3, đạt được độ chính xác phân loại lần lượt là 82,56%, 86,82% và 82,04% trong việc phát hiện bệnh Alzheimer ở giai đoạn đầu, đồng thời sử dụng khung XAI dựa trên LIME để phân tích khu vực chính xác mà việc phân loại xảy ra. Cùng nghiên cứu về bệnh Alzheimer, tác giả K. Muthamil Sudar đã chứng minh rằng việc dự đoán sớm bệnh là rất quan trọng, vì hiện chưa có phương pháp điều trị hiệu quả [34]. Vì thế tác giả đã sử dụng phương pháp Layer-wise Relevance Propagation (LRP) trong XAI cùng với các thuật toán như VGG-16 và CNN để xác định các giai đoạn của bệnh Alzheimer, cung cấp phân tích đáng tin cậy với giải thích chi tiết cho các đặc trưng đã sử dụng. Bài báo của tác giả Firas Ketata đã đề xuất một phương pháp phân tích độ tin cậy cho XAI trong lĩnh vực y tế, đặc biệt là các bệnh nội tiết như bệnh suy giáp và tiểu đường [35]. Phương pháp kết hợp các kỹ thuật XAI với k-fold để nâng cao và đánh giá độ tin cậy của các giải thích được cung cấp bởi các mô hình ML. Nghiên cứu còn cho thấy rằng sự kết hợp giữa SHAP và k-fold cho độ tổng quát, ổn định và sự nhất quán vượt trội so với sự kết hợp của LIME với k-fold. Phương pháp này có thể giúp tăng cường niềm tin của các bác sĩ vào các mô hình ML và thúc đẩy việc áp dụng chúng trong thực tế y tế. Vào năm 2023, tác giả Mohanad M. Alsaleh đã tổng quan về việc sử dụng XAI và các phương pháp ML để dự đoán đồng thời hai hoặc nhiều bệnh lý khác nhau, một thách thức lớn trong chăm sóc sức khỏe ảnh hưởng đến chất lượng cuộc sống của bệnh nhân [36]. Hệ thống đã phân tích 829 bài viết và lựa chọn 22 bài, với 61 mô hình được xem xét, trong đó 33 mô hình đạt độ chính xác cao từ 80-95% và AUC từ 0.80-0.89. Mặc dù có tiềm năng lớn trong việc phát hiện các bệnh đồng bệnh mới và cho thấy tiềm năng lớn trong việc phát hiện các nhu cầu y tế chưa được đáp ứng, dù còn nhiều thách thức về tiêu chuẩn đánh giá XAI và dữ liệu hạn chế.

Với lĩnh vực metagenomics, người ta nghiên cứu nhiều bài báo áp dụng XAI vào lĩnh vực này. Như nghiên cứu của tác giả Karthik Sekaran nhằm khám phá sự mất cân bằng trong hệ vi sinh vật của âm đạo liên quan đến nguyên nhân gây bệnh ung thư cổ tử cung, cho thấy sự thống trị của các vi khuẩn Firmicutes, Actinobacteria, và Proteobacteria [37]. Sự gia tăng đáng kể của *Lactobacillus iners* và *Prevotella timonensis* được xác định có ảnh hưởng đến sự tiến triển của bệnh. Sử dụng SHAP để phân tích kết quả, nghiên cứu phát hiện rằng sự gia tăng của *Ralstonia* có khả năng cao trong việc dự đoán ung thư cổ tử cung, xác nhận sự hiện diện của các vi sinh vật gây bệnh trong mẫu âm đạo của bệnh nhân. Một mô hình XAI nhằm xác định các dấu ấn sinh học gen liên quan đến COVID-19 thông qua dữ liệu mNGS từ 234 bệnh nhân được trình bày trong bài báo của tác giả Fatma Hilal Yagin [38]. Mô hình sử dụng các kỹ thuật máy học như LASSO để chọn lọc gen và SVM-SMOTE để xử lý vấn đề mất cân bằng lớp. Kết quả cho thấy mô hình XGBoost đạt độ chính xác cao

nhất là 0.930, với các gen quan trọng nhất được xác định bằng SHAP là IFI27, LGR6 và FAM83A. Mô hình này không chỉ dự đoán chính xác COVID-19 mà còn cung cấp hiểu biết rõ ràng về ảnh hưởng của các yếu tố rủi ro thông qua các phương pháp LIME và SHAP. Tác giả Pierfrancesco Novielli cũng đã nghiên cứu về XAI để xác định các vi khuẩn trong hệ vi sinh đường ruột liên quan đến rối loạn tự kỷ (ASD) [39], tiết lộ các dấu ấn sinh học cá nhân hóa cho ASD. Kết quả phân cụm dựa trên SHAP cho thấy có các nhóm ASD với mức độ rủi ro khác nhau, nhấn mạnh tính đa dạng của rối loạn này. Nghiên cứu này có tiềm năng hỗ trợ phát triển các can thiệp, nâng cao độ chính xác trong chẩn đoán và theo dõi bệnh ASD. Một nghiên cứu khác tìm hiểu về XAI để xác định các dấu ấn sinh học vi sinh vật và chất chuyển hóa trong đường ruột liên quan đến bệnh nhợt cơ (MG) như bài báo của tác giả Che-Cheng Chang [40]. Mô hình đạt hiệu quả chẩn đoán cao, với các dấu ấn sinh học quan trọng gồm Lachnospiraceae, inosine, và methylhistidine, cho thấy sự khác biệt rõ rệt giữa nhóm MG và không MG. Công cụ này cung cấp các giải thích cá nhân hóa, giúp làm rõ vai trò của vi sinh vật và chất chuyển hóa trong chẩn đoán MG và hỗ trợ chẩn đoán thông qua giao diện trực tuyến. Gần đây nhất, tác giả Hania Tourab đã tìm hiểu về hệ vi sinh vật đường ruột đã đạt được tiến bộ lớn nhờ tích hợp trí tuệ nhân tạo và học máy [41], giúp giải mã dữ liệu phức tạp và hiểu rõ hơn về ảnh hưởng của vi sinh vật đến sức khỏe con người. Bài viết đánh giá vai trò của XAI trong nghiên cứu vi sinh vật đường ruột và nhận diện các lỗ hổng tri thức, từ đó đề xuất hướng nghiên cứu tương lai. Dù vậy, phần lớn các mô hình hiện tại vẫn mang tính "hộp đen" và chưa chú trọng đầy đủ đến tính tái lập của các nghiên cứu.

Một số bài báo nghiên cứu và sử dụng các phương pháp XAI khác nhau cho các mục đích khác nhau. Trong đó LIME đã được sử dụng giải thích cho nhiều mô hình máy học với đa dạng dữ liệu. Vào năm 2023, bài báo của tác giả Jaeyoung Shin đã đánh giá hiệu suất chọn đặc trưng của thuật toán LIME cho các tập dữ liệu fNIRS [42], so sánh với các phương pháp chọn đặc trưng khác như minimum-redundancy maximum-relevance, t-test và sequential forward selection. Kết quả phân tích cho thấy LIME vượt trội hơn hầu hết các phương pháp khác và đạt độ chính xác phân cụm cao hơn đáng kể so với các phương pháp benchmark. Những phát hiện này ngụ ý rằng LIME là một phương pháp chọn đặc trưng hiệu quả cho các tập dữ liệu fNIRS. Nghiên cứu của tác giả Advithi D kết hợp kỹ thuật SMOTE và LIME để cải thiện dự đoán đột quỵ bằng các phương pháp học máy [43]. Các mô hình học máy khác nhau được đánh giá rồi sử dụng LIME để giải thích và phân tích các chỉ số hiệu suất khác nhau. Đáng chú ý, mô hình RF cho thấy hiệu suất vượt trội so với các mô hình khác, đạt độ chính xác 94.70%. Mercy Mawia Mulwa vào năm 2024 giới thiệu mô hình GMM-LIME trong việc giải thích các mô hình học máy cho dữ liệu về chân đi của con người [44]. LIME được cải thiện bằng cách kết hợp mô hình phân phối Gaussian (GMM) để đạt được tính ổn định cao hơn và tránh bước lấy mẫu. Nghiên cứu áp dụng các mô hình học máy có giám sát trên dữ liệu GaitRec và HugaDB, đạt độ chính xác cao nhất là Multilayer Perceptron (95%) và RF (99%). Kết quả đồ họa cho thấy GMM-LIME không chỉ sản xuất những giải thích chính xác và đáng tin cậy hơn so với LIME gốc, mà còn ổn định một cách nhất quán.

LIME hiện nay có rất nhiều phiên bản mở rộng, cải tiến nhiều hơn hẳn so với LIME ban đầu, đặc biệt là việc sử dụng kiến trúc autoencoder để cải thiện khả năng giải thích. Phương

pháp giải thích dự đoán của mô hình học sâu được tác giả Lev Utkin đề xuất sử dụng kết hợp giữa autoencoder tiêu chuẩn và variational autoencoder (VAE) [45]. Autoencoder tiêu chuẩn được sử dụng để tái tạo hình ảnh gốc và tạo ra các vector biểu diễn ẩn, trong khi VAE chuyển đổi các đầu ra của mô hình học sâu thành các vector biểu diễn ẩn của autoencoder tiêu chuẩn. Phương pháp này sử dụng VAE để tạo ra các vector giải thích và sau đó dùng decoder của autoencoder để tái tạo các hình ảnh, tạo ra bản đồ nhiệt giải thích cho hình ảnh gốc. Bài báo của tác giả Niloofar Ranjbar đã trình bày một phiên bản sửa đổi của phương pháp giải thích mô hình học sâu có tên ALIME, sử dụng autoencoder để giải thích các dự đoán của mô hình [46]. Trong phiên bản này mới đây, ALIME sử dụng cây quyết định thay vì mô hình tuyến tính để tăng tính giải thích của mô hình. Các thí nghiệm cho thấy phương pháp mới cải thiện đáng kể độ ổn định, độ trung thành cục bộ và khả năng giải thích của ALIME. Bài báo của tác giả Xu Xiang đề xuất phương pháp VAE-SLIME, VAE, nhằm cung cấp các giải thích ổn định và đáng tin cậy cho mô hình máy học, khắc phục nhược điểm của LIME về tính ổn định và độ trung thành cục bộ [47]. VAE-SLIME sử dụng nhiễu cố định thay vì nhiễu Gaussian ngẫu nhiên, tạo ra các mẫu ổn định hơn và giới thiệu chỉ số FSSI để đánh giá tính ổn định của giải thích. So với 6 phương pháp tiên tiến khác trên 7 tập dữ liệu, VAE-SLIME cho thấy các giải thích ổn định nhất và độ trung thành cục bộ cao hơn 65.17% so với các phương pháp khác. Bài báo khác của tác giả Xingyu Zhao giới thiệu một phương pháp mới gọi là BayLIME, mở rộng framework LIME bằng cách sử dụng lý thuyết Bayes để cải thiện khả năng giải thích của mô hình [48]. So với LIME, BayLIME tận dụng kiến thức trước và lý thuyết Bayes để nâng cao tính nhất quán trong các giải thích lặp lại của một dự đoán duy nhất và tính bền vững đối với các cài đặt kernel. BayLIME cũng vượt trội hơn các phương pháp giải thích hiện đại như LIME, SHAP và GradCAM nhờ khả năng tích hợp kiến thức từ các kỹ thuật XAI khác và các phương pháp xác minh và kiểm định. Các đặc tính đáng mong đợi của BayLIME được chứng minh qua phân tích lý thuyết và các thử nghiệm thực tế trong bài viết. SurvLIME là một phương pháp mới được đề xuất để giải thích các mô hình học máy được nghiên cứu bởi tác giả Maxim S. Kovalev [49]. Đây có thể được xem là một mở rộng hoặc sửa đổi của phương pháp LIME nổi tiếng. Ý tưởng chính của phương pháp này là áp dụng mô hình nguy cơ tỷ lệ Cox để xấp xỉ mô hình sống sót tại khu vực địa phương xung quanh. Các thí nghiệm số cho thấy hiệu quả của SurvLIME. Một phương pháp khác cải tiến của LIME phải kể đến đó là NormLIME. NormLIME là một phương pháp mới để xác định độ quan trọng của các đặc trưng trong việc giải thích các mô hình học sâu [50]. Phương pháp này cải tiến các mô hình giải thích cục bộ của LIME bằng cách tổng hợp chúng thành các giải thích toàn cục và cụ thể cho từng lớp. Thay vì sử dụng các xấp xỉ toàn cục, NormLIME tập trung vào việc cung cấp các giải thích chính xác hơn về hành vi của mô hình trong các vùng nhỏ của không gian dữ liệu. Các thí nghiệm số xác nhận rằng NormLIME có hiệu quả trong việc nhận diện các đặc trưng quan trọng.

Cũng là một trong những phương pháp phổ biến như LIME, SHAP đã được sử dụng rất nhiều trong XAI với nhiều lĩnh vực nghiên cứu khác nhau. Như bài viết của tác giả I.U. Ekanayake nói về các kỹ thuật máy học đã được sử dụng để dự đoán chính xác cường độ nén của bê tông [51]. Nghiên cứu này áp dụng SHAP để giải thích các dự đoán của ML, đặc biệt với các thuật toán như XGBoost và LKRR đạt hiệu quả cao. SHAP cung cấp cái nhìn sâu sắc về tầm quan trọng của từng đặc tính, cho thấy sự phù hợp với hành vi nén của bê tông trong thực tế. Một bài viết khác dự đoán hệ số áp lực gió của mô hình máy học cho

các tòa nhà mái dốc thấp đã đạt độ chính xác cao trong bài viết của Pasindu Meddage [52]. Nghiên cứu này sử dụng SHAP để giải thích các dự đoán, cung cấp cái nhìn về sự tương tác và tầm quan trọng của các biến đối với kết quả. SHAP cũng xác nhận tính phù hợp của các dự đoán ML với quy luật khí động học, giúp tăng độ tin cậy của mô hình. Trong bài báo của tác giả Randika K. Makumbura, các mô hình máy học kết hợp với XAI đã dự đoán chất lượng nước với độ chính xác cao [53], trong đó XGBoost đạt hiệu suất tốt nhất. SHAP cung cấp cái nhìn chi tiết về các yếu tố ảnh hưởng, cho thấy COD và BOD là các yếu tố quan trọng nhất trong dự đoán chất lượng nước. Phương pháp này giúp các chuyên gia và nhà hoạch định quyết định có được công cụ dự đoán chất lượng nước đáng tin cậy và dễ hiểu. Một cải tiến của SHAP trong bài viết của tác giả Maximilian Muschalik, đó là TreeSHAP-IQ cung cấp phương pháp tính toán hiệu quả cho tương tác Shapley bậc bất kỳ trong các mô hình cây [54]. Với khung toán học tối ưu hóa, TreeSHAP-IQ giảm độ phức tạp khi tính các điểm tương tác chỉ bằng một lần duyệt đệ quy qua cây. Phương pháp này giúp khám phá tương tác đặc tính phức tạp trong các tập dữ liệu chuẩn.

Ngoài LIME nhiều bài báo so sánh và áp dụng LIME lẫn SHAP cho các nghiên cứu của họ. Điển hình như bài báo của hai tác giả Nguyễn Quốc Huy và Từ Lăng Phiêu giới thiệu bài báo mô tả chi tiết các bước thực hiện của LIME và SHAP trên dữ liệu nhỏ, và giải thích các đặc trưng sau khi thực nghiệm phân loại trên dữ liệu thử nghiệm bằng phương pháp học sâu [55]. Kết quả thực nghiệm cho thấy LIME và SHAP đều mang lại thông tin quan trọng và thú vị về các đặc trưng của mô hình sau huấn luyện. Một hệ thống được tác giả Viswan Vimbi đề xuất trình bày việc khám phá ứng dụng của các khung công cụ LIME và SHAP trong giải thích phát hiện bệnh Alzheimer (AD) [56]. Nó xác định 23 bài viết liên quan, điều tra khả năng tiềm năng, lợi ích và thách thức của các khung công cụ này. Đánh giá nhấn mạnh vai trò quan trọng của trích dẫn trí tuệ nhân tạo trong việc củng cố tính đáng tin cậy của các dự đoán dựa trên trí tuệ nhân tạo cho việc dự báo AD, nhằm nâng cao tính chính xác trong hệ thống hỗ trợ quyết định lâm sàng. Các phương pháp như LIME và SHAP được áp dụng để cung cấp thông tin chi tiết về quyết định của mô hình, hỗ trợ các chuyên gia an ninh mạng phân tích kết quả Hệ thống Phát hiện Xâm nhập (IDS) và đưa ra các quyết định có căn cứ như trong bài báo của Diogo Gaspar [57]. Bài báo tập trung vào việc tăng cường tính minh bạch và khả năng giải thích của các mô hình hộp đen như Mạng nơ-ron Đa tầng (MLP). Cùng với đó là phân tích biến động xác nhận các giải thích này, chỉ ra tác động của các đặc trưng cụ thể đối với kết quả mô hình và so sánh hiệu quả của LIME và SHAP trong việc tăng tính minh bạch. Đề tài trong lĩnh vực chăm sóc sức khỏe của tác giả Kahakashan Ashraf sử dụng các mô hình học máy như Decision Tree (DT), RF, Support Vector Classifier (SVC), K-Nearest Neighbors (KNN) và Gaussian Naive Bayes (GNB) để chẩn đoán và dự đoán các bệnh [58]. Mô hình KNN đạt độ chính xác cao nhất là 98.56%, cho thấy khả năng chẩn đoán mạnh mẽ. Hơn nữa, LIME và SHAP được áp dụng để giải thích Trí tuệ Nhân tạo, giúp giải thích và minh họa quyết định của các mô hình này, nâng cao tính minh bạch trong dự đoán sức khỏe. Xây dựng trên các mô hình radiomics, nghiên cứu của tác giả Sotiris Raptis đã áp dụng dữ liệu đa phương tiện để dự đoán các kết quả như viêm phổi do bức xạ (RP) [59]. Mạng nơ-ron sâu (DNN) đã cho thấy hiệu suất vượt trội với Multi-Modal AUC-ROC đạt 0.90, chỉ số nhạy và đặc hiệu cao lần lượt là 0.85 và 0.91. SHAP và LIME được áp dụng để cải thiện khả năng giải thích của mô hình, giúp các bác sĩ hình dung được tác động của các đặc trưng và cung cấp lời giải thích cục bộ cho mỗi dự

đoán, từ đó nâng cao sự dễ hiểu của mô hình. Các phương pháp này đánh dấu một bước tiến lớn trong việc tích hợp phân tích dữ liệu với hiểu biết chuyên môn y khoa để đưa ra những dự đoán tiên lượng chính xác. Rituparna Chowdhury đã nghiên cứu khám phá ứng dụng các thuật toán học máy để phát hiện chất lượng tảo một cách chính xác và kịp thời, thay thế các phương pháp truyền thống như phân tích vật lý và hóa học [60]. Nó đánh giá và so sánh hiệu suất của nhiều phương pháp học máy, trong đó Mạng nơ-ron nhân tạo (ANN) xuất sắc nhất với độ chính xác 92.87%. Sau đó, các kỹ thuật trích dẫn Trí tuệ Nhân tạo, đặc biệt là LIME và SHAP, được sử dụng để giải thích và minh họa quá trình ra quyết định phức tạp của các mô hình. Các phân tích này cung cấp những thông tin quan trọng về quá trình ra quyết định, đóng góp đáng kể cho các phương pháp tiến bộ trong phát hiện chất lượng tảo

Không dừng lại ở việc sử dụng các phương pháp XAI thông qua các giá trị cục bộ như LIME hay SHAP, người ta còn nghiên cứu cả phương pháp XAI với các phản chứng. Nghiên cứu của tác giả Ulf Lesley khảo sát mong muốn của bác sĩ về cách XAI giải thích các dự đoán AI y tế, đánh giá hai phương pháp LIME và DiCE [61]. Trong đó DiCE là một phương pháp mới tạo phản chứng. Kết quả cho thấy giải thích của XAI hiện chưa đáp ứng nhu cầu giảm bớt sự không chắc chắn và cung cấp thông tin đủ sâu cho các quyết định lâm sàng. Các bác sĩ đề xuất cần đào tạo thêm về AI và XAI cho nhân viên y tế và tích hợp các công cụ này vào quy trình chăm sóc sức khỏe. Các phương pháp XAI được so sánh trong bài báo Bujar Raufi gồm SHAP, LIME, ANCHORS và DiCE trong việc giải thích mô hình ANN phát hiện gian lận thẻ tín dụng [62]. Kết quả từ phân tích thống kê cho thấy SHAP, ANCHORS và DiCE có ý nghĩa cao về độ ổn định, tính tách biệt và độ tương đồng trong giải thích mô hình. SHAP, LIME và ANCHORS đạt độ ổn định và khả năng giải thích cao hơn trong các phương diện đánh giá về độ phức tạp tính toán và khả năng giải thích. Tác giả Chihcheng Hsieh đã giới thiệu DiCE4EL [63], một phương pháp cải tiến từ DiCE nhằm tạo giải thích đối lập cho dự đoán quá trình nghiệp vụ. DiCE hiện không hiệu quả với dữ liệu sự kiện do không tính đến kiến thức miền, chuỗi sự kiện dài và khó tối ưu hóa với biến phân loại. DiCE4EL khắc phục bằng cách cung cấp giải thích đối lập dựa trên các mốc quan trọng trong quá trình thực thi, giúp tăng tính dễ hiểu cho người dùng. Kết quả thử nghiệm trên dữ liệu sự kiện thực tế cho thấy DiCE4EL hiệu quả hơn trong việc giải thích dự đoán quá trình. Vào năm 2023, tác giả Siqiong Zhou cũng giới thiệu SCGAN (Sparse CounterGAN) [64], một phương pháp tạo ra các giải thích đối lập để thiết lập quan hệ nhân quả giữa các đặc trưng ICM (hình ảnh, thông tin lâm sàng, và các yếu tố phân tử) và phản ứng điều trị ung thư vú sau liệu pháp NST. SCGAN sử dụng phương pháp sinh ngẫu nhiên để tạo ra các mẫu đối lập thực tế, giúp đảm bảo các mẫu này gần giống mẫu gốc. Kết quả thử nghiệm trên các tập dữ liệu công khai và dữ liệu ung thư vú cho thấy SCGAN tạo ra các giải thích đối lập hợp lý và chỉ thay đổi ở một số ít đặc trưng, giúp hiểu rõ quan hệ nhân quả giữa đặc trưng ICM và phản ứng điều trị. Một bài báo khác đã đề xuất một mô hình tác nhân tạo hình ảnh phản thực tế (counterfactual images) để giải thích các dự đoán của mô hình AI trong phân loại hình ảnh y tế của tác giả Yingying Fang [65]. Phương pháp này giúp phát hiện các đặc trưng quan trọng ảnh hưởng đến quyết định của mô hình học sâu, đặc biệt trong các nhiệm vụ phát hiện bệnh sớm và dự đoán. Kết quả cho thấy phương pháp có thể cải thiện độ tin cậy của mô hình so với các phương pháp giải thích truyền thống.

1.4 Mục tiêu đề tài

Mục tiêu của nghiên cứu này là áp dụng các kỹ thuật giải thích mô hình để phân tích kết quả chẩn đoán bệnh trên dữ liệu metagenomics, xác định các đặc trưng nào quan trọng ảnh hưởng nhiều đến kết quả chẩn đoán bệnh. Các phương pháp giải thích mô hình được sử dụng trong nghiên cứu này bao gồm LIME, SHAP, ALIME và DiCE, nhằm xác định các đặc trưng quan trọng từ dữ liệu metagenomics và kiểm tra khả năng dự đoán bệnh của các mô hình học máy. Cụ thể mục tiêu như sau:

- Áp dụng bốn phương pháp giải thích mô hình (LIME, SHAP, ALIME, DiCE) để tìm ra 50 đặc trưng quan trọng nhất trong dữ liệu metagenomics.
- Sử dụng các đặc trưng quan trọng từ các phương pháp giải thích mô hình để huấn luyện hai mô hình học máy: RF và GBC. Các mô hình này sẽ được sử dụng để phân loại bệnh hoặc không bệnh.
- Áp dụng bốn phương pháp trên để phân tích và làm rõ các đặc trưng quan trọng thuộc nhóm tăng khả năng gây bệnh hoặc giảm khả năng gây bệnh. Các đặc trưng này sẽ ảnh hưởng mạnh mẽ đến quyết định của các mô hình phân loại.
- Tiếp đến sẽ đánh giá độ chính xác của các mô hình RF và GBC trong việc phân loại bệnh hay không bệnh. So sánh cả 4 phương pháp kết hợp 2 mô hình với nhau để tìm ra phương pháp phù hợp nhất với dữ liệu metagenomics này cũng như các đặc trưng nào xuất hiện thường xuyên trong cả 4 phương pháp.
- So sánh kết quả dự đoán của các phương pháp giải thích với mô hình học máy.
- Cuối cùng là so sánh các kết quả dự đoán với kết quả thực tế của các bài báo khác để kiểm tra tính hiệu quả của các mô hình, đồng thời tìm ra các nguyên nhân gây bệnh, giảm bệnh.

Nghiên cứu đề tài luận văn này với mong muốn mọi người trong và ngoài ngành hiểu rõ hơn về cách thức hoạt động của các mô hình bằng việc làm sáng tỏ các quyết định của thuật toán, giúp cải thiện hiểu biết về quá trình dự đoán và tạo cơ sở cho các ứng dụng thực tiễn trong chẩn đoán y khoa. Đồng thời mong muốn cung cấp thông tin hỗ trợ cho các chuyên gia y tế trong việc đưa ra quyết định chẩn đoán, thông qua việc sử dụng các kết quả phân tích từ các mô hình giải thích, từ đó cải thiện độ tin cậy và chất lượng chẩn đoán dựa trên dữ liệu metagenomics trong lĩnh vực y tế.

1.5 Đối tượng và phạm vi đề tài

Đề tài tập trung vào việc nghiên cứu và ứng dụng các kỹ thuật giải thích mô hình trong phân tích kết quả chẩn đoán bệnh. Đề tài cũng tập trung vào việc sử dụng các kỹ thuật giải thích mô hình để hiểu rõ hơn về cách các mô hình này đưa ra dự đoán, cũng như xác định các đặc trưng quan trọng trong dữ liệu ảnh hưởng đến kết quả chẩn đoán. Đối tượng chính

là dữ liệu metagenomics, bao gồm các đặc trưng sinh học của các loài vi sinh vật trong mẫu bệnh thu thập từ cơ thể người. Dữ liệu metagenomics trong nghiên cứu này có sẵn từ các bộ dữ liệu công khai (chủ yếu là bệnh nhân bị nghi ngờ hoặc đã mắc bệnh CRC) Các dữ liệu này sẽ được sử dụng để xác định các đặc trưng quan trọng và dự đoán khả năng mắc bệnh hay không mắc bệnh.

Các mô hình học máy được sử dụng bao gồm RF và GBC để phân loại bệnh hay không bệnh dựa trên dữ liệu metagenomics. Các phương pháp giải thích mô hình như LIME, SHAP, ALIME và DiCE sẽ được áp dụng để xác định các đặc trưng quan trọng trong dữ liệu metagenomics và đánh giá độ tin cậy cũng như khả năng dự đoán bệnh của mô hình. Song song đó nghiên cứu nâng cao độ tin cậy và làm rõ quá trình dự đoán bệnh thông qua các mô hình học máy, nhằm cung cấp các kết quả hỗ trợ cho các chuyên gia y tế trong quá trình ra quyết định chẩn đoán bệnh dựa trên dữ liệu metagenomics.

1.6 Nội dung đề tài

Đề tài "Ứng dụng các kỹ thuật giải thích mô hình để phân tích kết quả chẩn đoán bệnh trên dữ liệu metagenomics" tập trung vào việc sử dụng các phương pháp XAI nhằm phân tích các đặc trưng có liên quan đến bệnh ung thư đại trực tràng từ dữ liệu metagenomics. Dữ liệu metagenomics được coi là nguồn tài nguyên quan trọng trong nghiên cứu y học, đặc biệt trong việc phát hiện và phân tích các yếu tố tác động đến sự phát triển của bệnh ung thư đại trực tràng. Nghiên cứu này sẽ khám phá đặc điểm của dữ liệu metagenomics trong ngữ cảnh chẩn đoán ung thư đại trực tràng, đồng thời mô tả phương pháp thu thập dữ liệu và các đặc trưng có thể sử dụng để phân loại bệnh. Việc ứng dụng các phương pháp XAI như LIME, SHAP, ALIME và DiCE sẽ đóng vai trò quan trọng trong việc làm sáng tỏ các quyết định của mô hình học máy, từ đó nâng cao khả năng giải thích và minh bạch hóa các kết quả phân tích. Các phương pháp giải thích mô hình này giúp xác định những đặc trưng quan trọng ảnh hưởng mạnh mẽ đến kết quả dự đoán của mô hình. Sau khi xác định được 50 đặc trưng quan trọng từ bốn phương pháp XAI, những đặc trưng này sẽ được sử dụng để huấn luyện hai mô hình học máy, bao gồm RF và GBC, qua đó giúp so sánh và đánh giá hiệu quả của các mô hình trong việc phân loại bệnh ung thư đại trực tràng. Quá trình huấn luyện các mô hình và các tham số sử dụng trong huấn luyện sẽ được mô tả chi tiết để làm rõ phương pháp tiếp cận. Đánh giá độ chính xác của các mô hình trong việc phân loại bệnh và không bệnh sẽ được thực hiện, và kết quả giữa các mô hình sẽ được so sánh để tìm ra mô hình nào hiệu quả nhất khi sử dụng các đặc trưng quan trọng đã được lựa chọn.

Các phương pháp giải thích mô hình sẽ tiếp tục được sử dụng để phân tích kết quả dự đoán từ các mô hình đã huấn luyện, từ đó giúp xác định và giải thích những đặc trưng có ảnh hưởng tích cực hay tiêu cực đến khả năng mắc bệnh ung thư đại trực tràng. Kèm theo đó việc so sánh kết quả của mô hình học máy với kết quả của các phương pháp XAI cũng là một phần quan trọng của nghiên cứu. Mô hình học máy sẽ cho ra các dự đoán về bệnh hay không bệnh, sau đó sẽ sử dụng các phương pháp XAI để xem kết quả giữa mô hình học máy và XAI có trùng khớp hay không và giải thích các yếu tố quyết định dẫn đến các dự đoán đó. Nghiên cứu này sẽ không chỉ chỉ ra các yếu tố quan trọng có thể gây bệnh mà

còn giúp xác định những yếu tố bảo vệ khỏi bệnh. Cuối cùng, nghiên cứu sẽ kết luận những phát hiện chính, đóng góp của phương pháp giải thích mô hình đối với công tác chẩn đoán bệnh thông qua dữ liệu metagenomics và nhấn mạnh lợi ích của việc áp dụng các kỹ thuật XAI trong lĩnh vực y khoa. Những kết quả này không chỉ hỗ trợ cho công tác chẩn đoán mà còn mở ra các cơ hội phát triển các phương pháp giải thích mô hình để ứng dụng rộng rãi hơn trong các lĩnh vực y tế và nghiên cứu khoa học, qua đó tạo ra những nền tảng vững chắc cho các nghiên cứu tiếp theo, nhằm thúc đẩy sự phát triển của các công cụ hỗ trợ quyết định trong y học.

1.7 Những đóng góp chính của đề tài

Quá trình nghiên cứu và triển khai đề tài đã đem lại nhiều đóng góp quan trọng trong lĩnh vực metagenomics và học máy. Nghiên cứu đã xây dựng và huấn luyện các mô hình máy học, sử dụng hai mô hình cơ bản kết hợp với 4 phương pháp XAI. Các mô hình đã được kiểm thử và đánh giá trên nhiều tập dữ liệu khác nhau, bao gồm cả những tập dữ liệu đã được công khai trước đó bởi các nghiên cứu khác. Ngoài ra, nghiên cứu cũng đã tạo ra sự nhận định mới trong việc so sánh độ hiệu quả của các phương pháp XAI trong dữ liệu metagenomics. Đồng thời, tìm ra được các đặc trưng quan trọng ảnh hưởng đến dự đoán bệnh hay không bệnh của mô hình. Trong lĩnh vực y tế, hi vọng đề tài này sẽ góp phần không nhỏ giúp các y bác sĩ cũng như các chuyên gia xác định nhanh chóng bệnh của các bệnh nhân cũng như có sự chuẩn bị chu đáo hơn trong việc điều trị. Về mặt khoa học, nghiên cứu sẽ là một đóng góp cho các công trình khoa học cũng như các nghiên cứu tiên tiến trong tương lai cho cả những người đã hiểu biết sâu về tài này và những người đang mong muốn tìm hiểu về chúng.

1.8 Bố cục của luận văn

Bố cục của luận văn gồm 5 phần chính như sau:

Chương 1 Giới thiệu

- Giới thiệu
- Đặt vấn đề
- Các nghiên cứu liên quan
- Mục tiêu đề tài
- Đối tượng và phạm vi đề tài
- Nội dung đề tài
- Những đóng góp chính của đề tài
- Bố cục của luận văn

Chương 2 Mô tả bài toán

- Mô tả chi tiết bài toán
- Hướng tiếp cận giải quyết vấn đề của đề tài

Chương 3 Thiết kế và cài đặt giải pháp

- Kiến trúc tổng quát hệ thống
- LIME
- ALIME
- SHAP
- DiCE
- Xây dựng các mô hình
- Giải pháp cài đặt

Chương 4 Kiểm thử và đánh giá

- Kịch bản kiểm thử
- Kết quả kiểm thử

Chương 5 Kết luận và hướng phát triển

- Kết luận
- Hạn chế
- Hướng phát triển

1.9 Tổng kết chương

Thông qua chương này em đã trình bày các phần cơ sở về lý thuyết của bài toán, trong đó có giới thiệu, đặt vấn đề, các nghiên cứu có liên quan, mục tiêu đề tài, đối tượng và phạm vi đề tài, nội dung chính và những đóng góp chính của bài toán, sau cùng là bố cục của luận văn. Chương này bày tổng quan về bài toán các mục tiêu của bài toán, nội dung cần thực hiện cùng với đó là các đóng góp mà em đã thực hiện trong đề tài này. Với các mục tiêu được trình bày, trong phần tiếp theo em sẽ trình bày các bước thực hiện chúng.

MÔ TẢ BÀI TOÁN

2.1	Mô tả chi tiết bài toán	18
2.1.1	Mô tả dữ liệu	19
2.2	Hướng tiếp cận giải quyết của đề tài	20
2.2.1	Hướng tiếp cận thứ 1: Sử dụng mô hình AI và các kỹ thuật XAI để phát hiện các đặc trưng quan trọng	20
2.2.2	Hướng tiếp cận thứ 2: Áp dụng các phương pháp XAI: LIME, ALIME, SHAP, và DiCE	21
2.2.3	Hướng tiếp cận thứ 3: Thực nghiệm trên dữ liệu với các mẫu và số lượng đặc trưng khác nhau	22
2.3	Tổng kết chương	22

Trong chương này, đề tài tập trung làm rõ các yêu cầu của bài toán và mô tả chi tiết về tập dữ liệu được sử dụng. Tiếp theo, đề tài trình bày ba hướng tiếp cận đã được đề xuất để giải quyết bài toán. Hướng tiếp cận thứ nhất sử dụng mô hình AI và các kỹ thuật XAI để phát hiện các đặc trưng quan trọng, giúp xác định các đặc trưng có ý nghĩa nhất trong dữ liệu, từ đó tối ưu hóa việc phân tích. Hướng tiếp cận thứ hai áp dụng các phương pháp XAI nhằm giải thích, dự đoán kết quả chẩn đoán bệnh và hiểu rõ hơn cách thức hoạt động của mô hình đã được huấn luyện, giúp tăng tính minh bạch và khả năng giải thích của mô hình. Hướng tiếp cận thứ ba thực nghiệm trên tập dữ liệu với các mẫu và số lượng đặc trưng khác nhau nhằm đánh giá hiệu quả của các phương pháp XAI và đảm bảo tính tổng quát của kết quả trên các trường hợp khác nhau.


2.1 Mô tả chi tiết bài toán

Chẩn đoán bệnh từ dữ liệu metagenomics là một thách thức quan trọng trong nghiên cứu y học hiện đại. Metagenomics là lĩnh vực nghiên cứu DNA của các quần thể vi sinh vật trong một mẫu môi trường mà không cần phải nuôi cấy các vi sinh vật đó trong phòng thí nghiệm. Thông qua việc phân tích các đoạn DNA, các nhà nghiên cứu có thể xác định thành phần vi sinh vật và các đặc điểm sinh học khác trong mẫu, qua đó khám phá vai trò của vi sinh vật trong sức khỏe và bệnh lý. Tuy nhiên, do đặc tính đa dạng và khối lượng lớn của dữ liệu metagenomics, việc phát hiện các đặc trưng sinh học quan trọng để phục vụ chẩn đoán bệnh là một nhiệm vụ phức tạp. Bài luận văn này hướng đến việc phát triển một hệ thống phát hiện và giải thích các đặc trưng quan trọng từ dữ liệu metagenomics, giúp hỗ trợ các nhà khoa học và bác sĩ trong chẩn đoán bệnh. Đặc biệt sử dụng các mô hình AI để học từ dữ liệu và đưa ra các dự đoán chẩn đoán. Tuy nhiên, các mô hình AI thường được coi là "blackbox," khiến cho việc hiểu cách thức chúng đưa ra quyết định trở nên khó khăn, đặc biệt trong lĩnh vực y học nơi tính minh bạch và khả năng giải thích là vô cùng cần thiết.

Để giải quyết vấn đề này, áp dụng bốn phương pháp giải thích mô hình là LIME, ALIME, SHAP và DiCE để chọn lọc ra 50 đặc trưng quan trọng nhất từ dữ liệu. Việc chọn lọc 50 đặc trưng quan trọng nhất từ dữ liệu dựa trên một số lý do như sau: đầu tiên, điều này giúp giảm độ phức tạp của mô hình, đặc biệt khi xử lý dữ liệu lớn như dữ liệu metagenomics. Chọn 50 đặc trưng giúp giảm số lượng đầu vào, cải thiện hiệu suất tính toán và tăng tốc độ huấn luyện. Thứ hai, việc chọn ra 50 đặc trưng quan trọng nhất tăng hiệu quả của các đặc trưng được huấn luyện và khả năng giải thích của mô hình, đặc biệt quan trọng khi áp dụng các phương pháp XAI để hiểu rõ yếu tố quyết định kết quả. Thứ ba, con số 50 đảm bảo cân bằng giữa việc giữ lại đủ thông tin cần thiết để dự đoán chính xác và tránh dư thừa hay gây nhiễu kết quả. Sau đó, các đặc trưng này sẽ được sử dụng để huấn luyện hai mô hình học máy là RF và GBC trên các tập dữ liệu metagenomics đã được gán nhãn, nhằm học cách phân loại hoặc dự đoán các điều kiện bệnh lý dựa trên đặc điểm vi sinh vật. Từ kết quả huấn luyện, so sánh các phương pháp và mô hình để xác định phương pháp nào đạt độ chính xác cao và phù hợp nhất với dữ liệu metagenomics liên quan đến bệnh ung thư đại trực tràng. Để hiểu rõ hơn về cách mô hình AI đưa ra các quyết định, đề tài sẽ áp dụng các kỹ thuật giải thích để xác định những đặc trưng sinh học quan trọng nhất trong việc phân loại và chẩn đoán. Đề tài thử nghiệm với mẫu đầu tiên để phân tích ảnh hưởng của các đặc trưng quan trọng đến nhóm gây bệnh và không gây bệnh, sau đó mở rộng thử nghiệm trên 50 mẫu ngẫu nhiên từ mỗi bộ dữ liệu để tổng hợp các đặc trưng tiềm năng liên quan đến bệnh và không liên quan đến bệnh. Kết quả thực nghiệm sẽ giúp xác định các đặc trưng có khả năng liên quan đến bệnh ung thư đại trực tràng và các đặc trưng không ảnh hưởng đến bệnh. Đánh giá tần suất xuất hiện của các đặc trưng quan trọng và xem xét liệu các đặc trưng này có ảnh hưởng đến dự đoán của mô hình hay không, cũng như kiểm tra tính nhất quán giữa kết quả của các mô hình và các phương pháp giải thích XAI. Đây là các vấn đề đề tài sẽ giải quyết trong bài luận văn này. Bài toán đặt ra là phải vừa đạt được độ chính xác cao trong dự đoán, vừa đảm bảo các quyết định chẩn đoán có thể giải thích được, nhằm cung cấp một hệ thống chẩn đoán minh bạch, hỗ trợ các chuyên gia y tế trong việc xác định nguyên nhân bệnh và đề xuất phương pháp điều trị hiệu quả.

2.1.1 Mô tả dữ liệu

CRC là một trong những loại ung thư phổ biến nhất trên thế giới và là nguyên nhân gây tử vong do ung thư đứng thứ hai. Năm 2020, ước tính có khoảng 930.000 ca tử vong do CRC, chiếm 10% tổng số ca tử vong do ung thư toàn cầu[66]. Đây là một dạng ung thư đường tiêu hóa phổ biến và gây tử vong cao. Các nghiên cứu gần đây chỉ ra rằng thói quen ăn uống kém và lối sống không lành mạnh có thể làm tăng nguy cơ mắc bệnh và tử vong do CRC. Cơ chế sinh bệnh của CRC thường bắt đầu từ các polyp lành tính hoặc tiền ung thư, những tổn thương này dần chuyển dạng trong nhiều năm và có thể xâm lấn thành ruột, lan đến các hạch bạch huyết gần đó hoặc di căn đến các bộ phận khác của cơ thể[67]. Hình ảnh 2.1 dưới đây mô tả dữ liệu metagenomics của bệnh CRC được sử dụng trong nghiên cứu này:



Hình 2.1. Dataset

Dataset này bao gồm tổng hợp và phân tích từ 526 mẫu metagenomic từ bốn nhóm nghiên cứu tại các quốc gia khác nhau. Cụ thể, dữ liệu bao gồm các mẫu từ các quốc gia như Mỹ [68], Áo [69], Trung Quốc [70], và Đức cùng Pháp [71], với tổng cộng 271 mẫu không mắc bệnh và 255 mẫu mắc ung thư đại trực tràng (CRC), được thu thập từ các nghiên cứu trước đó, với thông tin chi tiết đã được trình bày từ bài báo gốc của tác giả Zhenwei Dai [72].

Trong các nhóm nghiên cứu, mẫu từ Mỹ có tổng cộng 52 mẫu không bệnh và 48 mẫu CRC với 1976 đặc trưng. Dữ liệu từ Áo bao gồm 1981 đặc trưng, 63 mẫu không bệnh và 46 mẫu CRC. Nhóm nghiên cứu Trung Quốc có 1932 đặc trưng, 92 mẫu không bệnh và 73 mẫu CRC. Điều kiện thu mẫu của nhóm này cũng yêu cầu bệnh nhân không sử dụng kháng sinh hoặc can thiệp y tế trong ba tháng trước đó, và không có tiền sử bệnh ung thư hay bệnh viêm nhiễm đường ruột. Cuối cùng, nhóm nghiên cứu từ Đức và Pháp gồm 1980 đặc trưng, 64 mẫu không bệnh và 88 mẫu CRC. Các mẫu này được thu thập trước bất kỳ can thiệp y

tế nào và không có tiền sử bệnh lý liên quan đến đường ruột. Dữ liệu metagenomic trong nghiên cứu này đã được chuyển đổi thành dữ liệu số thông qua quá trình giải trình tự gen bằng nền tảng Illumina Hiseq 2000/2500, với độ sâu đọc mục tiêu đạt 5GB và chiều dài đọc là 100 bp. Các chuỗi gen được xử lý này đã được phân loại và căn chỉnh bằng công cụ Kraken v_0.10.5-beta, giúp chuyển đổi các đoạn DNA thô thành dữ liệu định dạng số có thể phân tích và lưu trữ. Toàn bộ dữ liệu đã được thu thập, xử lý và tổ chức chi tiết, sau đó được lưu trữ trong kho GitHub tại ¹.

2.2 Hướng tiếp cận giải quyết của đề tài

Một trong những vấn đề với các mô hình học máy phức tạp là chúng thường khó hiểu và khó giải thích, điều này có thể gây ra thiếu minh bạch và những người sử dụng không trong chuyên ngành sẽ không hiểu được. Do đó, chúng ta cần một phương pháp giúp giải thích rõ ràng các dự đoán của mô hình.. Để khắc phục điều này, đề tài áp dụng các phương pháp XAI nhằm làm rõ các quyết định của mô hình trong quá trình chẩn đoán bệnh dựa trên dữ liệu metagenomics. Để đạt được mục tiêu này, đề tài sử dụng một cách tiếp cận tổng quan, kết hợp các mô hình AI và các kỹ thuật XAI để phát hiện và giải thích các đặc trưng quan trọng có ảnh hưởng đến kết quả chẩn đoán.

2.2.1 Hướng tiếp cận thứ 1: Sử dụng mô hình AI và các kỹ thuật XAI để phát hiện các đặc trưng quan trọng

Đề tài lựa chọn các mô hình AI bao gồm RF và GBC để xử lý và phân loại dữ liệu metagenomics. Các mô hình này được lựa chọn không chỉ vì khả năng phân loại tốt mà còn bởi tính dễ sử dụng và khả năng dễ dàng tích hợp với các phương pháp XAI nhằm giải thích các đặc trưng quan trọng trong dữ liệu.

Các mô hình học máy như RF và GBC đã được xây dựng bằng cách sử dụng các thư viện scikit-learn và scikit-survival, vốn là những công cụ mạnh mẽ cho phân tích dữ liệu và học máy. Trong đó, scikit-learn cung cấp các thuật toán phổ biến cùng các công cụ tiền xử lý và lựa chọn đặc trưng, còn scikit-survival hỗ trợ phân tích sống sót, xử lý dữ liệu kiểm duyệt và các mô hình dự đoán thời gian sống. Các tiện ích mở rộng tùy chỉnh cho scikit-learn và scikit-survival đã được phát triển để bổ sung các phương pháp và chức năng cần thiết cho báo cáo này.

- Random Forest (RF): RF là một thuật toán học máy dựa trên tập hợp nhiều cây quyết định, giúp giảm thiểu hiện tượng quá khớp (overfitting) và tăng cường độ chính xác. Mô hình này dễ sử dụng và cung cấp thông tin rõ ràng về tầm quan trọng của các đặc trưng, giúp xác định nhanh chóng các đặc trưng nổi bật trong dữ liệu. RF là lựa chọn phổ biến trong nhiều bài toán phân loại nhờ tính ổn định, độ tin cậy cao, và khả năng giải thích các đặc trưng một cách trực quan.

¹<https://github.com/DAIZHENWEI/meta-analysis-microbiome/tree/master>

- Gradient Boosting Classifier (GBC): GBC là một thuật toán mạnh mẽ trong việc tối ưu hóa và nâng cao độ chính xác của mô hình thông qua việc học từ các lỗi của mô hình trước đó. Mô hình này rất hiệu quả trong việc xử lý các bài toán phân loại phức tạp và đạt độ chính xác cao nhờ khả năng học sâu từ các đặc trưng quan trọng. GBC cũng dễ triển khai và thường mang lại hiệu suất cao trên nhiều loại dữ liệu khác nhau, làm cho nó trở thành một công cụ mạnh mẽ trong phân loại dữ liệu metagenomics.

Sau khi các mô hình AI được huấn luyện, tiếp tục sử dụng các kỹ thuật XAI bao gồm LIME, ALIME, SHAP, và DICE để xác định các đặc trưng quan trọng nhất. Sau đó so sánh kết quả sau khi huấn luyện giữa các phương pháp XAI và các mô hình với nhau để tìm ra đâu là phương pháp và mô hình tối ưu nhất cho dữ liệu metagenomics về bệnh ung thư đại trực tràng.

2.2.2 Hướng tiếp cận thứ 2: Áp dụng các phương pháp XAI: LIME, ALIME, SHAP, và DiCE

Các phương pháp XAI được chọn bao gồm LIME [73], ALIME [74], SHAP[75], và DiCE[76]. Mỗi phương pháp này có vai trò và cách tiếp cận riêng trong việc giải thích mô hình AI:

- LIME: giúp giải thích các dự đoán cục bộ của mô hình bằng cách xây dựng các mô hình đơn giản quanh mỗi mẫu, cung cấp cái nhìn cụ thể về vai trò của từng đặc trưng.
- ALIME: một biến thể của LIME sử dụng Autoencoder để tạo ra các đặc trưng tốt hơn cho quá trình giải thích, làm tăng độ chính xác trong việc phát hiện các đặc trưng quan trọng.
- SHAP: cung cấp giải thích toàn diện và công bằng bằng cách tính toán mức độ đóng góp của mỗi đặc trưng đối với dự đoán tổng thể.
- DICE: tạo ra các ví dụ đối kháng giúp làm rõ vai trò của các đặc trưng bằng cách cho thấy thay đổi nhỏ nào có thể làm thay đổi kết quả chẩn đoán.

Mỗi phương pháp này cung cấp một góc nhìn khác nhau về cách các đặc trưng ảnh hưởng đến dự đoán của mô hình, giúp hiểu rõ hơn về mức độ quan trọng của các đặc trưng trong dữ liệu. Bằng cách này, mỗi kỹ thuật XAI sẽ đóng vai trò bổ sung cho nhau, để hiểu rõ hơn về cách các đặc trưng ảnh hưởng đến quyết định của mô hình. Ngoài ra, mỗi phương pháp sẽ được áp dụng trên hai hướng tiếp cận:

- Đầu tiên, xét cả 4 phương pháp trên mẫu đầu tiên để có cái nhìn sâu sắc về các đặc trưng quan trọng trong từng dự đoán cụ thể;
- Thứ hai, xét cả 4 phương pháp trên 50 mẫu ngẫu nhiên để tìm ra các đặc trưng chung gây bệnh và không bệnh, từ đó nhận diện các yếu tố tiềm ẩn ảnh hưởng đến kết quả chẩn đoán.

2.2.3 Hướng tiếp cận thứ 3: Thực nghiệm trên dữ liệu với các mẫu và số lượng đặc trưng khác nhau

Để kiểm tra tính ổn định và nhất quán của các đặc trưng quan trọng, đề tài tiến hành thực nghiệm bằng cách áp dụng các phương pháp XAI trên các mẫu khác nhau và với số lượng đặc trưng khác nhau. Quá trình thực nghiệm được chia thành hai phần chính:

- Thực nghiệm với mẫu đầu tiên trong mỗi dataset: lựa chọn 1 mẫu duy nhất để phân tích chi tiết, giúp đánh giá cách thức các đặc trưng quan trọng ảnh hưởng tới dự đoán của mô hình trên từng mẫu riêng lẻ.
- Thực nghiệm với nhiều mẫu ngẫu nhiên (50 mẫu): nhằm đánh giá tính nhất quán của các đặc trưng quan trọng trên toàn bộ dữ liệu. Bằng cách áp dụng phương pháp này trên nhiều mẫu khác nhau, có thể xác định liệu các đặc trưng quan trọng có thay đổi giữa các mẫu khác nhau hay không, từ đó đánh giá mức độ tin cậy của các đặc trưng được chọn.

Phương pháp tiếp cận này cho phép đề tài xác định những đặc trưng quan trọng nhất gây bệnh và không gây bệnh ung thư đại trực tràng, đồng thời cung cấp sự giải thích rõ ràng về cách các mô hình AI đưa ra quyết định, giúp hỗ trợ các nhà nghiên cứu và bác sĩ trong việc áp dụng kết quả phân tích vào thực tiễn chẩn đoán bệnh từ dữ liệu metagenomics.

2.3 Tổng kết chương

Qua kịch bản được trình bày ở trên, đề tài này đã trình bày chi tiết về mô tả xử lý bài toán dựa trên các khảo sát liên quan đến các hướng tiếp cận để có thể tìm ra các đặc trưng gây bệnh hoặc không bệnh trong tập dữ liệu của CRC. Sau đó em trình bày các hướng tiếp cận mà em đã khảo sát, dựa trên các hướng tiếp cận để có thể trích xuất. Ở mỗi hướng tiếp cận, em có mô tả cách thức để có thể tính toán và tìm ra các đặc trưng. Cuối cùng em có đánh giá lại các hướng tiếp cận dựa trên các kết quả thực nghiệm đạt được để tiến hành tìm ra các đặc trưng chung và tiến hành xem xét các giá trị độ chính xác của các đặc trưng chung này so với tập gốc sẽ như thế nào.


THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP

3.1	Kiến trúc tổng quát hệ thống	24
3.1.1	LIME	26
3.1.2	ALIME	28
3.1.3	SHAP	32
3.1.4	DiCE	35
3.2	Xây dựng các mô hình	39
3.2.1	RF model	39
3.2.2	GBC model	40
3.3	Giải pháp cài đặt	41
3.4	Tổng kết chương	41

Trong kịch bản này đề tài này trình bày các kiến trúc tổng thể của bài toán để từ đó xây dựng mô hình phân lớp để tiến hành thực nghiệm trên các bộ được lựa chọn với hai mô hình RF và GBC. Sau đó giới thiệu 4 phương pháp XAI là LIME, ALIME, SHAP, DiCE và cách thức hoạt động của chúng, cách mà chúng đưa ra giải thích. Tiếp theo đề tài này sẽ trình bày các giải pháp cài đặt để có thể thử nghiệm các tập dữ liệu với mô hình được cài đặt

3.1 Kiến trúc tổng quát hệ thống

Trong báo cáo này, đề tài xây dựng hệ thống dự đoán và phân tích bệnh dựa trên dữ liệu metagenomics bằng cách áp dụng bốn phương pháp XAI gồm LIME, ALIME, SHAP, và DiCE kết hợp với hai mô hình huấn luyện là RF và GBC. Hệ thống tập trung vào việc so sánh hiệu quả của từng phương pháp XAI và mô hình huấn luyện để xác định giải pháp tối ưu trong việc nhận diện các vi khuẩn gây bệnh và không gây bệnh ở con người. Ngoài ra, hệ thống đánh giá khả năng của các phương pháp XAI trong việc tái tạo kết quả từ mô hình huấn luyện, đồng thời xác định các yếu tố vi khuẩn quan trọng liên quan đến bệnh lý, hỗ trợ lĩnh vực y tế cải thiện các phương pháp điều trị. Thông qua việc áp dụng các phương pháp XAI, đề tài làm hiểu rõ hơn về lý do đằng sau các quyết định của mô hình học máy, từ đó mang lại sự minh bạch và dễ hiểu trong kết quả phân tích. Kiến trúc tổng quát của hệ thống được trình bày ngắn gọn qua 3.1



Hình 3.1. Quy trình giải thích mô hình AI.

1. Thu thập và tiền xử lý dữ liệu (dataset):

Quá trình xây dựng hệ thống bắt đầu với việc thu thập và tiền xử lý tập dữ liệu phù hợp với bài toán nghiên cứu. Tập dữ liệu được lựa chọn là dữ liệu số có cấu trúc, trong đó các đặc trưng (features) đại diện cho thành phần vi sinh vật, còn các mẫu (samples) biểu thị các bệnh nhân tham gia nghiên cứu. Dữ liệu này được sử dụng để huấn luyện các mô hình AI. Cụ thể lựa chọn dữ liệu metagenomics liên quan đến bệnh ung thư đại trực tràng.

2. Lựa chọn đặc trưng (Feature selection)

Sau khi tiền xử lý, áp dụng các kỹ thuật XAI như LIME, ALIME, SHAP và DiCE để chọn ra các đặc trưng quan trọng nhất (50 đặc trưng). Những phương pháp này giúp

xác định những yếu tố có tác động lớn nhất đến kết quả mô hình. Dataset ban đầu có thể chứa rất nhiều đặc trưng, nhưng không phải tất cả đều đóng góp nhiều vào việc dự đoán. Việc giảm số lượng đặc trưng giúp giảm độ phức tạp của mô hình. Dataset cũng có thể chứa các đặc trưng không liên quan hoặc thậm chí gây nhiễu, làm giảm hiệu quả của mô hình. Việc chọn lọc giúp tập trung vào những đặc trưng thực sự quan trọng và cải thiện hiệu suất của mô hình.

3. Lựa chọn mô hình học máy (Select model)

Trong bước này sử dụng RF và GBC để huấn luyện mô hình dự đoán bởi RF mang lại sự ổn định và khả năng tổng quát, trong khi GBC tối ưu hiệu suất và chi tiết hơn trong các bài toán phân loại phức tạp.

4. Phương pháp huấn luyện (Training Techniques)

StratifiedKFold được sử dụng để chia dữ liệu thành k-fold. Số lần chia dữ liệu tùy thuộc vào giá trị k được truyền. Với tập train là $(k-1)/k$ của dữ liệu và tập test là $1/k$ của dữ liệu. Trong bài này dữ liệu được chia thành 10 phần (10-fold cross-validation) để đảm bảo tính tổng quát hóa của mô hình, thế nên mỗi fold sẽ gồm 90% train và 10% test. Lựa chọn tham số estimator là 500 cây để thử nghiệm trong RF và GBC để đạt độ chính xác cao hơn. Các phương pháp XAI được áp dụng trên mẫu đầu tiên của từng tập con.

5. Mô Hình Hộp Đen (Blackbox Model)

Các mô hình RF và GBC được xem như "hộp đen," với khả năng đưa ra dự đoán chính xác nhưng không dễ dàng để hiểu rõ lý do tại sao nó đưa ra những dự đoán đó. Tiếp đó tập trung vào việc mở hộp đen này bằng các kỹ thuật XAI để hiểu cách thức dự đoán được tạo ra.

6. Giải thích AI (XAI)

Các phương pháp như LIME, ALIME, SHAP và DiCE được tùy chỉnh với các siêu tham số phù hợp. Điều này giúp khai thác chi tiết sự ảnh hưởng của từng đặc trưng lên kết quả dự đoán.

7. Giải thích mô hình (Explanation for Model)

Sau khi mô hình được huấn luyện, các phương pháp giải thích được áp dụng để làm rõ cách thức các đặc trưng quan trọng ảnh hưởng đến kết quả chẩn đoán. Kết quả từ các phương pháp XAI cho thấy rõ ràng các đặc trưng quan trọng nhất và mức độ ảnh hưởng của chúng là tốt hay xấu với mẫu đầu tiên. Cùng với đó là các trọng số thể hiện cách đặc trưng ảnh hưởng đến kết quả dự đoán. Điều này giúp hiểu sâu hơn về quyết định của mô hình và cung cấp thông tin chẩn đoán trực quan hơn.

8. Tương tác với người dùng (User)

Kết quả cuối cùng được trình bày dưới dạng báo cáo trực quan, dễ hiểu. Người dùng có thể sử dụng các thông tin này để hỗ trợ việc chẩn đoán và ra quyết định.

Nhìn chung cách tiếp cận này không chỉ tập trung vào việc xây dựng mô hình AI mạnh mẽ, đạt được độ chính xác cao trong dự đoán mà còn nhấn mạnh vào việc cung cấp các giải thích hữu ích, góp phần thúc đẩy sự chấp nhận và ứng dụng AI trong thực tế cụ thể là lĩnh vực y sinh học.

3.1.1 LIME

LIME là một công cụ phổ biến giúp giải thích các quyết định của các mô hình ML. Nói đơn giản LIME là phương pháp đưa việc to hóa nhỏ, thay vì giải thích cho toàn cục thì ta đưa sự việc về cục bộ, và biểu thị ra phần nào trong dữ liệu ảnh hưởng nhiều nhất tới dự đoán của mô hình, cho phép chúng ta hiểu rõ hơn về quyết định dự đoán của mô hình với từng trường hợp cụ thể. LIME còn là một phương pháp giải thích kết quả của mô hình “hộp đen” bằng cách xây dựng một mô hình cục bộ xung quanh điểm cần giải thích và các biến đổi của điểm này¹. Phương pháp LIME được giới thiệu lần đầu tiên năm 2016 trong một bài báo của 3 data scientists tại ĐH Washinton là Marco Tulio Ribeiro, Sameer Singh và Carlos Guestrin [73]. LIME có thể được sử dụng để giải thích trong mẫu dữ liệu cụ thể đặc trưng nào ảnh hưởng nhiều đến mô hình, đặc trưng nào có khả năng gây bệnh. Điều này giúp nhà nghiên cứu hiểu rõ hơn về các đặc điểm nào quan trọng trong quá trình phân tích dữ liệu metagenomic. Không những thế, LIME có thể được sử dụng để kiểm tra các dự đoán của mô hình. Thông qua việc cung cấp giải thích chi tiết, LIME giúp nhà nghiên cứu điều chỉnh mô hình để tăng độ chính xác và độ tin cậy của quá trình huấn luyện. Bằng cách làm rõ các quyết định của mô hình, LIME giúp tăng cường tính minh bạch và giảm thiểu tính “hộp đen” trong quá trình phân tích dữ liệu metagenomic số với bệnh ung thư đại trực tràng. Framework của LIME là có sẵn²

Dưới đây là ưu và nhược điểm của LIME³:

Ưu điểm:

- Lime là áp dụng cho nhiều loại dữ liệu như văn bản, hình ảnh và dữ liệu số.
- Lime không phụ thuộc vào bản chất của mô hình, thậm chí nó không dùng đến (và không cần biết) cơ chế bên trong của mô hình. Do đó, LIME có thể áp dụng cho mọi mô hình, từ Naive Bayes, KNN cho đến RF hay NN. Tính độc lập cho phép LIME hoạt động tại mọi thời điểm, cho mọi phiên bản của mô hình.
- Lime cung cấp giải thích chi tiết quanh một điểm cụ thể trong dữ liệu làm các quyết định của mô hình máy học trở nên dễ hiểu, giúp chúng ta hiểu rõ hơn về quyết định mô hình.


Nhược điểm

¹<https://cran.r-project.org/web/packages/lime/lime.pdf>

²<https://github.com/marcotcr/lime>

³(<https://www.toolify.ai/vi/ai-news-vn/lime-cho-nlp-ai-c-th-gii-thch-476042>)

- Độ ổn định thấp do tính độc lập nên kết quả có thể khác nhau khi chạy nhiều lần trên cùng một dữ liệu.
- Việc lựa chọn các tham số phù hợp cũng là một thách thức.
- LIME tạo ra các mô hình đơn giản, có thể không đáp ứng đầy đủ các khía cạnh phức tạp của các mô hình AI.



Hình 3.2. Các bước chính của LIME.

Quy trình sử dụng LIME trên hình 3.2 giúp biến một mô hình phức tạp thành một mô hình đơn giản và dễ hiểu ở phạm vi cục bộ, giúp người dùng hiểu được cách mà mô hình đưa ra dự đoán cho từng điểm dữ liệu cụ thể. Biểu đồ luồng này thể hiện rõ các bước từ việc chọn mô hình như trong bài luận văn này lựa chọn hai mô hình đó là GBC và RF. Tiếp theo là chọn một mẫu cụ thể từ tập dataset muốn giải thích kết quả xấp xỉ mô hình phức tạp f trong vùng lân cận của điểm dữ liệu x qua dự đoán của mô hình cho điểm này. LIME sẽ tạo dữ liệu giả lập xung quanh điểm cần giải thích. Đối với một điểm dữ liệu cụ thể, LIME tạo ra nhiều điểm dữ liệu giả lập bằng cách thêm nhiễu vào các đặc tính của điểm dữ liệu đó. Những điểm dữ liệu này nằm gần xung quanh điểm cần giải thích, tạo thành một đám mây dữ liệu cục bộ. Ví dụ với dữ liệu số, LIME sẽ tạo mẫu mới bằng cách thay đổi giá trị của các đặc trưng, còn đối với dữ liệu ảnh LIME tạo mẫu mới bằng cách thay đổi các siêu điểm ảnh. Sau đó các khoảng cách giữa các điểm giả lập và điểm dữ liệu gốc được tính toán. Khoảng cách này sau đó được chuyển đổi thành trọng số, cho thấy sự tương đồng của các điểm giả lập so với điểm dữ liệu gốc. Những điểm gần điểm gốc hơn sẽ có trọng số cao hơn. LIME sẽ dựa vào trọng số chọn ra một số lượng nhỏ các đặc trưng quan trọng nhất giúp giải thích sự khác biệt giữa các điểm dữ liệu giả lập và điểm dữ liệu gốc. Tiếp theo, LIME huấn luyện một mô hình tuyến tính đơn giản trên các mẫu giả này, để tìm ra những đặc trưng quan trọng nhất ảnh hưởng đến dự đoán của mô hình. Mô hình này được sử dụng để giải thích kết quả của mô hình phức tạp tại điểm dữ liệu cụ thể. Kết quả của mô hình đơn giản được sử dụng để giải thích quyết định của mô hình phức tạp. Các hệ số trọng số của mô hình đơn giản cho thấy mức độ ảnh hưởng của từng đặc tính đến kết quả dự đoán. Nếu hệ số trọng số dương, giá trị của đặc tính đó ủng hộ cho kết quả; nếu hệ số trọng số âm, giá trị của đặc tính đó chống lại kết quả.

LIME tìm một mô hình đơn giản g (thường là tuyến tính) . Công thức cơ bản được biểu diễn ở 3.1 như sau:

$$\xi(x) = \operatorname{argmin}_{g \in G} [\mathcal{L}(f, g, \pi_x) + \Omega(g)] \quad (3.1)$$

Trong đó:

- f : Mô hình phức tạp cần giải thích.
- g : Mô hình đơn giản dùng để xấp xỉ f trong vùng lân cận.
- G : Không gian các mô hình đơn giản.
- $\mathcal{L}(f, g, \pi_x)$: Hàm đo lường mức độ khác biệt giữa f và g , với π_x là hàm trọng số tập trung vào các điểm gần x .
- $\Omega(g)$: Hàm phạt độ phức tạp, đảm bảo g đơn giản và dễ hiểu.

LIME tối ưu hàm mục tiêu để cân bằng giữa độ chính xác và độ đơn giản của mô hình g .

Như vậy, LIME giúp chúng ta hiểu rõ hơn về cách một mô hình phức tạp đưa ra quyết định, bằng cách tập trung vào những vùng nhỏ xung quanh điểm dữ liệu cụ thể và sử dụng các mô hình đơn giản để diễn giải. Bài báo của tác giả Damien Garreau cung cấp phân tích lý thuyết đầu tiên về LIME [77]. Kết quả cho thấy các hệ số của mô hình có thể diễn giải trong LIME tỷ lệ thuận với gradient của hàm cần giải thích, giúp LIME phát hiện các đặc trưng quan trọng.

3.1.2 ALIME

Trong những năm gần đây, nhiều nhà nghiên cứu đã phân tích các hạn chế của LIME và đề xuất nhiều phương pháp mở rộng hoặc cải tiến. Mặc dù LIME đã mang lại những cải tiến đáng kể trong việc giải thích mô hình học máy, tuy nhiên việc sử dụng không gian tiềm ẩn của Autoencoder trong ALIME (Autoencoder-based Local Interpretable Model-agnostic Explanations) mang lại một bước đột phá, giúp tăng cường tính ổn định và giảm phức tạp tính toán trong quá trình giải thích. Vậy Autoencoder là gì? Autoencoder là một mạng neuron truyền thẳng học không giám sát (unsupervised feedforward neural network). Mục đích của Autoencoder là cố gắng tái tạo dữ liệu đầu vào sao cho giống nhất, gọn nhất có thể, nhưng vẫn giữ được thông tin quan trọng. ⁴ Các tác giả của ALIME [74] đã thay thế phương pháp gán trọng số bằng một autoencoder tính toán khoảng cách trong không gian tiềm ẩn và chứng minh rằng ALIME có thể đạt được sự ổn định cao hơn so với LIME. Trong ALIME, trọng số đặc trưng được tính thông qua các mẫu đối kháng được tạo từ không gian tiềm ẩn của autoencoder để xác định các đặc trưng quan trọng. Mặc dù tất cả các phương

⁴<https://tuanio.github.io/posts/autoencoder/>

pháp này đều sử dụng mô hình tuyến tính để tạo ra các giải thích, không phương pháp nào đánh giá chất lượng và tính hữu dụng của các giải thích từ góc nhìn con người [78]. Thế nên mục tiêu chính của ALIME này là tạo ra các giải thích dễ hiểu đối với con người.

Dưới đây là ưu và nhược điểm của ALIME:

Ưu điểm

- Sử dụng autoencoder giúp lọc và chọn lọc các điểm dữ liệu phù hợp hơn, cải thiện độ chính xác trong việc xác định đặc trưng quan trọng cho từng dự đoán.
- Giảm thiểu nhiễu nhờ không gian nhúng của autoencoder, tăng độ ổn định và nhất quán của các giải thích cục bộ.
- ALIME là một phương pháp giải thích độc lập với mô hình học máy, nghĩa là có thể sử dụng với bất kỳ mô hình phức tạp nào mà không cần thay đổi hoặc tái huấn luyện mô hình gốc.

Nhược điểm

- Quá trình huấn luyện autoencoder và tạo không gian nhúng yêu cầu tài nguyên tính toán lớn hơn LIME, đặc biệt với tập dữ liệu lớn.
- ALIME yêu cầu cấu hình autoencoder và các tham số phức tạp hơn.
- Kết quả giải thích của ALIME phụ thuộc lớn vào độ chính xác của autoencoder. Nếu autoencoder không được huấn luyện tốt, giải thích của ALIME có thể thiếu chính xác.



Hình 3.3. Các bước chính của ALIME.

Từ hình 3.3 ALIME được triển khai qua các bước sau: Đầu tiên, lựa chọn mô hình học máy cần giải thích, đã được huấn luyện và lưu trữ. Tiếp theo chọn mẫu dữ liệu cần giải thích (ở đây là mẫu đầu tiên của mỗi bộ dữ liệu) và trích xuất các đặc trưng của mẫu đó. Sau đó, sử dụng Autoencoder để tạo embeddings (chuyển đổi từ dữ liệu rời rạc sang dạng liên tục hoặc giảm chiều) cho dữ liệu, giúp xây dựng không gian nhúng cho dữ liệu. Dữ

liệu giả lập gần mẫu cần giải thích được sinh ra từ phân phối Gaussian và tính toán khoảng cách trong không gian nhúng, đảm bảo các điểm giả lập có tính đại diện cao. Các điểm này sau đó được gán trọng số dựa trên khoảng cách Euclidean tới mẫu gốc, với các điểm gần mẫu gốc hơn nhận trọng số cao hơn. Sau khi thu thập các điểm dữ liệu giả lập và gán trọng số, xây dựng một mô hình hồi quy tuyến tính đơn giản trên dữ liệu giả lập để đánh giá tầm quan trọng của các đặc trưng. Cuối cùng, ALIME sẽ phân nhóm các đặc trưng thành "gây bệnh" hoặc "không gây bệnh" dựa trên ảnh hưởng của chúng và trực quan hóa kết quả thông qua các biểu đồ, giúp người dùng dễ dàng hiểu rõ cách thức các đặc trưng ảnh hưởng đến quyết định của mô hình.

ALIME sử dụng một phương pháp kết hợp autoencoder để tạo ra embeddings cho dữ liệu và sau đó xây dựng một mô hình hồi quy tuyến tính dựa trên các trọng số gần nhất. Sau khi tính toán các embeddings cho điểm cần giải thích, nó sẽ thu thập các điểm dữ liệu gần nhất và huấn luyện một mô hình hồi quy tuyến tính để ước tính tầm quan trọng của các đặc trưng. Mục đích chính của ALIME là tạo ra một giải thích cho mô hình trong không gian đặc trưng đã được học thông qua autoencoder, từ đó xác định tầm quan trọng của các đặc trưng đối với một ví dụ cụ thể.

Dựa trên thuật toán ALIME được thiết kế, ALIME sử dụng một mạng autoencoder để tạo ra các biểu diễn tiềm ẩn. Quá trình thuật toán diễn ra theo hai giai đoạn chính:

- **Tiền xử lý và tính toán biểu diễn tiềm ẩn:** Huấn luyện autoencoder trên tập dữ liệu D_{train} để học các biểu diễn tiềm ẩn dạng vector số của dữ liệu. Sau đó, tạo tập dữ liệu mẫu D_{sample}^m từ phân phối Gaussian và tính biểu diễn tiềm ẩn cho các điểm trong tập mẫu này bằng cách sử dụng autoencoder đã huấn luyện.
- **Tính toán tầm quan trọng của đặc trưng:** Với một mẫu cần giải thích x , tính khoảng cách giữa biểu diễn tiềm ẩn của x và biểu diễn tiềm ẩn của các điểm trong D_{sample}^m . Chọn các điểm gần nhất, gán trọng số theo khoảng cách, và sử dụng các điểm này để huấn luyện một mô hình tuyến tính. Trọng số của mô hình tuyến tính biểu thị tầm quan trọng của các đặc trưng đối với mẫu x .

Sau khi thực nghiệm với ALIME, đây là phân tích của đề tài này về sự khác trình bày ở bảng 3.1 và giống nhau của hai phương pháp XAI ALIME và LIME được như sau: *

- Điều nhằm mục đích giải thích các mô hình học máy theo cách dễ hiểu, giúp người sử dụng có thể hiểu được vì sao mô hình đưa ra dự đoán nhất định cho các mẫu cụ thể.
- Cả LIME và ALIME có thể được sử dụng với bất kỳ mô hình học máy nào mà không phụ thuộc vào cấu trúc của mô hình. Điều này có nghĩa là cả hai đều có thể giải thích các mô hình học máy khác nhau mà không yêu cầu thay đổi trong chính các mô hình đó.
- Điều tạo ra các mẫu ngẫu nhiên từ dữ liệu đầu vào để phân tích và xây dựng các mô hình giải thích cục bộ.

Algorithm 1: ALIME

Input: D_{train} with K features, model M , instance x , number of points used n ,
number of points sampled m

Output: Feature importance at x

```

1 # Precompute embeddings using autoencoder
2 begin
3 # Train autoencoder model
4  $AE \leftarrow \text{AutoEncoder.fit}(D_{\text{train}})$ 
5 # Sample new dataset from Gaussian distribution
6  $D_{\text{sample}}^m \leftarrow \text{Gaussian}(K)$ 
7 # Calculate embeddings for  $D_{\text{sample}}$ 
8  $E \leftarrow [AE(y) \mid y \in D_{\text{sample}}]$ 
9 end
10 # Given  $x$ , calculate feature importance
11 begin
12 # Calculate distances from  $x$  in embedded space
13  $d \leftarrow |E - E(x)|$ 
14 # Find  $n$ -th minimum distance in  $d$ 
15  $d_{\min} \leftarrow \min(n, d)$ 
16 # Collect  $n$  closest points into a local dataset
17  $D \leftarrow \{y \in D_{\text{train}} \text{ such that } |d_x - d_y| < d_{\min}\}$ 
18 # Calculate weights
19  $W \leftarrow [e^{-y} \mid y \in D]$ 
20 # Fit linear model
21  $L \leftarrow \text{LinearModel.fit}(D, W)$ 
22 # Return weights of the linear model
23 return  $LW$ 
24 end

```

Bảng 3.1. Điểm khác nhau của LIME và ALIME

	LIME	ALIME
Cách tạo dữ liệu giả	LIME tạo ra các mẫu dữ liệu giả xung quanh điểm cần giải thích và huấn luyện mô hình đơn giản trên chúng.	Trước tiên, ALIME sử dụng một autoencoder để tạo ra các dữ liệu "embedding", từ đó tính toán khoảng cách trong không gian "embedding" và chọn các điểm gần nhất
Chọn điểm gần	Tạo các mẫu ngẫu nhiên từ không gian gốc mà không cần bước chọn các điểm gần nhau.	ALIME tính toán khoảng cách giữa điểm cần giải thích và các điểm khác trong không gian "embedding" để chọn nhóm điểm gần nhất, từ đó cải thiện độ chính xác của giải thích.
Phương pháp tạo mẫu	Sử dụng các mẫu ngẫu nhiên trong không gian dữ liệu gốc để tạo dữ liệu giả lập.	Tạo dữ liệu mẫu từ phân phối Gaussian và sử dụng các "embedding" (đặc trưng đã được mã hóa) thay vì sử dụng trực tiếp dữ liệu gốc.

ALIME có thể được coi là một sự mở rộng của LIME, kết hợp giữa không gian tiềm ẩn của Autoencoder và phương pháp giải thích cục bộ của LIME, nhằm tạo ra các giải thích chính xác và ổn định hơn, đặc biệt là đối với dữ liệu phức tạp. Tuy nhiên, điều này đòi hỏi sử dụng nhiều tài nguyên tính toán hơn. Một điểm mạnh của ALIME là khả năng cải thiện tính ổn định so với LIME. Thay vì tạo dữ liệu ngẫu nhiên mỗi lần như LIME, ALIME tạo ra một số lượng lớn điểm dữ liệu từ phân phối Gaussian trước khi thực hiện giải thích. Điều này giúp giảm phức tạp tính toán và tăng tính ổn định của quá trình giải thích. Hơn nữa, ALIME sử dụng Autoencoder, đặc biệt là Denoising Autoencoder, để xây dựng không gian nhúng, giữ lại những điểm dữ liệu gần gũi nhất với điểm cần giải thích. Cách tiếp cận này giúp cải thiện độ chính xác trong việc chọn lọc dữ liệu phù hợp và giảm nhiễu. Cuối cùng, trong ALIME, trọng số đặc trưng được tính dựa trên khoảng cách trong không gian nhúng, thay vì không gian đầu vào ban đầu, giúp giảm thiểu ảnh hưởng của nhiễu và nâng cao tính chính xác trong giải thích cục bộ.

3.1.3 SHAP

Trong quá trình ra quyết định, điều quan trọng là phải nhận ra lý do tại sao các quyết định được đưa ra mặc dù các mô hình học máy phức tạp nhưng chúng khó diễn giải. Để cung cấp khả năng diễn giải và tầm quan trọng của tính năng, tức là đóng góp của từng tính năng vào kết quả, Scott M. Lundberg và Su-In Lee vào năm 2017 đã đề xuất sử dụng phương pháp SHapley Additive exPlanation (SHAP) [75]. SHAP là phương pháp sử dụng kiến thức từ Lý thuyết trò chơi và Thống kê để đưa ra được mức độ đóng góp hay ảnh hưởng của các đặc trưng vào kết quả của mô hình [79]. Trong bài viết của tác giả I. Elizabeth Kumar,

SHAP được biết đến là một phương pháp phổ biến để đo lường tầm quan trọng của biến trong các mô hình học máy [80]. SHAP không phụ thuộc vào mô hình, nghĩa là nó không bị giới hạn ở một loại mô hình nhất định. Một trong những ưu điểm lớn nhất của SHAP là nó cung cấp cả giải thích cục bộ và toàn cục, tức là giải thích ảnh hưởng của từng đặc trưng lên dự đoán của từng mẫu và đưa ra tổng hợp các thông tin về tầm quan trọng trung bình của các đặc trưng trên toàn bộ dữ liệu ⁵. Giá trị Shapley là một cách tiếp cận phổ biến trong lý thuyết trò chơi hợp tác và có các tính chất mong muốn. Trong đó, các giá trị đặc trưng của một dữ liệu đầu vào được coi như các "người chơi" trong một liên minh. Giá trị Shapley thể hiện đóng góp cận biên trung bình của một giá trị đặc trưng qua tất cả các liên minh có thể xảy ra. Hãy tưởng tượng một nhóm người chơi cùng làm việc để hoàn thành một trò chơi vậy làm thế nào để phần thưởng cuối cùng được chia sẻ nếu mỗi người chơi đóng góp khác nhau? Giá trị Shapley có thể được sử dụng trong tình huống này để đảm bảo rằng phần thưởng được phân phối công bằng cho từng người chơi bằng cách tính toán đóng góp cận biên của mỗi người [81].

SHAP có tiềm năng được áp dụng trong lĩnh vực y tế bằng cách phân tích sự đóng góp của các dấu ấn sinh học hoặc các đặc trưng lâm sàng đến một kết quả bệnh cụ thể. Các nghiên cứu mới đã phát triển các thuật toán nhanh hơn và trực quan hơn để tính toán giá trị Shapley, chẳng hạn như TreeSHAP cải thiện và tối ưu hóa cho các mô hình cây quyết định, giảm đáng kể thời gian tính toán. Còn KernelSHAP thì tổng quát sử dụng hàm hạt nhân để tính giá trị Shapley, áp dụng được cho nhiều mô hình khác nhau. Các phương pháp mới được đề xuất cho thấy hiệu suất tính toán cải thiện và tính nhất quán tốt hơn với trực giác của con người so với các phương pháp trước đây. Các giá trị SHAP đã được chứng minh là nhất quán và các biểu đồ tóm tắt SHAP cung cấp tổng quan hữu ích về mô hình. Trong bài luận văn này framework của SHAP được tham khảo tại ⁶

Dưới đây là ưu và nhược điểm của SHAP ⁷:

Ưu điểm

- SHAP sử dụng giá trị Shapley từ lý thuyết trò chơi, đảm bảo rằng mỗi đặc trưng được đánh giá một cách công bằng dựa trên mức đóng góp của nó vào đầu ra của mô hình. Điều này giúp các giải thích trực quan, nhất quán và dễ hiểu hơn.
- SHAP có thể được sử dụng với nhiều loại mô hình học máy khác nhau, từ các mô hình đơn giản như hồi quy tuyến tính đến các mô hình phức tạp như mạng nơ-ron và cây quyết định.
- SHAP có thể cung cấp cả giải thích cục bộ (cho từng dự đoán) và toàn cục (đánh giá chung mức độ quan trọng của các đặc trưng trên toàn bộ tập dữ liệu).
- SHAP có thể giúp nhận diện những đặc trưng quan trọng trong các bộ dữ liệu có rất nhiều đặc trưng, giúp cải thiện khả năng hiểu và tối ưu hóa mô hình.

⁵https://xai-tutorials.readthedocs.io/en/latest/_model_agnostic_xai/shap.html

⁶<https://github.com/shap/shap>

⁷<https://www.toolify.ai/vi/ai-news-vn/gii-thch-ai-d-hiu-4-shap-2668906>

Nhược điểm

- Do yêu cầu tính toán giá trị Shapley cho từng đặc trưng, SHAP có thể tốn rất nhiều thời gian và tài nguyên khi làm việc với các mô hình lớn hoặc tập dữ liệu có nhiều đặc trưng.
- Với các mô hình phi tuyến hoặc mô hình rất phức tạp, việc tính toán giá trị Shapley có thể trở nên rất phức tạp, đòi hỏi các phương pháp xấp xỉ và có thể dẫn đến mất chính xác.



Hình 3.4. Các bước chính của SHAP.

Quy trình sử dụng SHAP trên hình 3.4 bắt đầu bằng việc chọn một mẫu cụ thể từ tập dữ liệu gốc, bao gồm cả các trường hợp bệnh và không bệnh. Sau đó, dữ liệu nền được tạo ra bằng cách sử dụng mô hình dự đoán để ước tính giá trị của các đặc trưng trên các mẫu mà mô hình chưa tiếp xúc, thường là một tập hợp các mẫu ngẫu nhiên từ cùng phân phối dữ liệu như tập dữ liệu chính. Dữ liệu nền sẽ giúp tính toán đóng góp của từng đặc trưng khi chúng được thêm hoặc loại bỏ. Explainer SHAP được khởi tạo, ở đây sử dụng hai mô hình RF và GB nên lựa chọn TreeExplainer, phù hợp cho các mô hình dựa trên cây. Giá trị SHAP được tính dựa trên lý thuyết Shapley, đo lường đóng góp của từng đặc trưng vào dự đoán của mô hình. Sau đó, giá trị SHAP tuyệt đối trung bình được tính để xác định mức độ ảnh hưởng tổng thể của các đặc trưng mà không phân biệt đến hướng tác động, điều này giúp lọc ra các đặc trưng quan trọng nhất. Mô hình dự đoán nhãn của mẫu và tính xác suất dự đoán, đồng thời lọc ra các đặc trưng quan trọng dựa trên giá trị SHAP cao nhất. Dựa vào giá trị SHAP, các đặc trưng được phân thành nhóm tăng xác suất gây bệnh (SHAP dương cao) và giảm xác suất gây bệnh (SHAP âm lớn). Kết quả là các giá trị SHAP cho phép xác định tầm quan trọng của mỗi đặc trưng trong việc dự đoán kết quả bệnh lý, giúp xác định các đặc trưng gây bệnh và không gây bệnh một cách rõ ràng. Cuối cùng, các giá trị SHAP được sử dụng để trực quan hóa tác động của từng đặc trưng, từ đó giúp các chuyên gia y tế đưa ra quyết định chẩn đoán và điều trị một cách chính xác và cá nhân hóa hơn.

Công thức chính của SHAP ở 3.2 như sau:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)] . \quad (3.2)$$

Công thức này tính trung bình đóng góp của đặc trưng i vào dự đoán của mô hình trong tất cả các trường hợp có thể. Cụ thể, ϕ_i là giá trị Shapley của đặc trưng i , với F là tập hợp tất cả các đặc trưng và $S \subseteq F \setminus \{i\}$ là các tập con của F không chứa đặc trưng i . Trọng số $\frac{|S|!(|F|-|S|-1)!}{|F|!}$ được sử dụng để biểu diễn cách đặc trưng i đóng góp trong mọi thứ tự sắp xếp có thể. Khi thêm đặc trưng i vào tập S , mô hình sẽ đưa ra dự đoán $f_{S \cup \{i\}}(x_{S \cup \{i\}})$, trong khi với tập S ban đầu, dự đoán là $f_S(x_S)$. Sự khác biệt giữa hai giá trị này, được biểu diễn bởi $[f_{S \cup \{i\}} - f_S]$, chính là đóng góp của đặc trưng i trong ngữ cảnh của tập S . Khi lấy trung bình đóng góp này trên tất cả các tập con S , ta thu được giá trị Shapley ϕ_i của đặc trưng i .

Có thể thấy cách thức hoạt động của SHAP là phân tích đầu ra của mô hình theo tổng tác động của từng tính năng. SHAP tính toán một giá trị biểu thị sự đóng góp của từng tính năng vào kết quả của mô hình. Các giá trị này có thể được sử dụng để hiểu tầm quan trọng của từng tính năng và giải thích kết quả của mô hình cho con người. Giá trị Shapley đảm bảo rằng tổng phần thưởng được phân bổ đầy đủ và không dư thừa hoặc thiếu sót. Trong ứng dụng của XAI, điều này có nghĩa là tổng đóng góp của tất cả các đặc trưng phải bằng tổng giá trị dự đoán của mô hình cho một mẫu cụ thể. Nếu hai đặc trưng có mức đóng góp giống nhau cho kết quả đầu ra, giá trị Shapley đảm bảo rằng chúng nhận được phần đóng góp ngang nhau. Điều này quan trọng trong các mô hình để đảm bảo rằng các đặc trưng tương đương không bị phân biệt đối xử. Một đặc trưng không ảnh hưởng đến dự đoán sẽ có giá trị Shapley bằng 0, giúp đơn giản hóa việc phân tích và loại bỏ các yếu tố không quan trọng.

SHAP có nhiều công dụng đối với các chuyên gia khoa học dữ liệu. Đầu tiên, nó giúp giải thích các dự đoán của mô hình Học máy theo cách mà con người có thể hiểu được. Bằng cách gán giá trị cho từng tính năng đầu vào, nó cho thấy cách thức và mức độ đóng góp của từng tính năng vào kết quả dự đoán cuối cùng. Theo cách này, nhóm có thể hiểu cách mô hình đưa ra quyết định và có thể xác định các tính năng quan trọng nhất. Giá trị Shapley không chỉ đảm bảo tính công bằng trong phân bổ đóng góp mà còn cung cấp một cách tiếp cận mạnh mẽ và trực quan để giải thích các mô hình phức tạp. Trong y học, ứng dụng của SHAP không chỉ giúp nâng cao độ tin cậy của các mô hình dự đoán mà còn hỗ trợ việc đưa ra quyết định lâm sàng chính xác và cá nhân hóa hơn.

3.1.4 DiCE

DiCE là một phương pháp trong lĩnh vực XAI giúp cung cấp các giải thích trực quan và dễ hiểu cho các dự đoán của mô hình học máy. Không giống như các phương pháp truyền thống tập trung vào việc phân tích tầm quan trọng của từng đặc trưng, DiCE tạo ra các phản chứng đa dạng, tức là các điểm dữ liệu giả lập gần với mẫu gốc nhưng có kết quả dự đoán khác biệt. Mục tiêu chính của DiCE là giải thích các dự đoán của mô hình học máy được sử dụng để hỗ trợ ra quyết định trong các lĩnh vực quan trọng đối với xã hội như tài chính, y tế, giáo dục và tư pháp hình sự. Trong những lĩnh vực này, việc cung cấp giải thích cho tất cả các bên liên quan chính tương tác với mô hình học máy là rất quan trọng: nhà thiết kế mô hình, người ra quyết định, đối tượng quyết định và người đánh giá quyết định. Tuy nhiên, hầu hết các kỹ thuật giải thích đều phải đối mặt với một sự đánh đổi nội tại giữa độ

chính xác và khả năng giải thích: một giải thích có độ chính xác cao đối với một mô hình học máy thường sẽ phức tạp và khó giải thích, trong khi một giải thích dễ hiểu lại thường không nhất quán với mô hình học máy mà nó được thiết kế để giải thích. Giải thích phản thực (counterfactual explanations) mang lại một sự thay thế đầy hứa hẹn. Thay vì ước lượng một mô hình học máy hoặc xếp hạng các đặc trưng theo độ quan trọng dự đoán của chúng, một giải thích phản thực "hỏi" mô hình để tìm ra những thay đổi cần thiết có thể thay đổi quyết định của mô hình. Cụ thể, DiCE cung cấp thông tin này bằng cách hiển thị các phiên bản của cùng một đầu vào với các đặc trưng thay đổi, dẫn đến một kết quả khác. Nói cách khác, một giải thích phản thực giúp đối tượng quyết định biết họ cần làm gì tiếp theo để đạt được kết quả mong muốn, thay vì chỉ cung cấp cho họ những đặc trưng quan trọng đã đóng góp vào dự đoán. Như trong bài viết của tác giả Andrea Ferrario đã nói giải thích phản thực tế là một ví dụ nổi bật về các phương pháp diễn giải hậu học trong lĩnh vực nghiên cứu AI có thể giải thích được. Khác với các phương pháp giải thích khác, chúng cung cấp khả năng có thể sử dụng để chống lại các kết quả bất lợi được tính toán bởi các mô hình học máy [82]. Những phản chứng này không chỉ giúp giải thích cách mô hình ra quyết định mà còn cung cấp các gợi ý cụ thể về những thay đổi cần thiết để đạt được kết quả mong muốn. Tuy nhiên một nhược điểm của các phản thực tế là chúng chịu ảnh hưởng của 'hiệu ứng Rashomon'⁸. Cụ thể, phản chứng trong đề tài luận văn này có thể được hiểu là những mẫu giả định được tạo ra để giải thích và phân tích kết quả dự đoán từ mô hình chẩn đoán bệnh. Các phản chứng được hình thành bằng cách thay đổi giá trị của một số đặc trưng trong dữ liệu của một mẫu cụ thể và xem xét liệu kết quả dự đoán bệnh (ví dụ: dự đoán bệnh có hay không) có thay đổi hay không. Từ đó, có thể phân tích được những yếu tố nào trong dữ liệu metagenomics có ảnh hưởng đến kết quả chẩn đoán bệnh, đồng thời đánh giá được độ chính xác và khả năng giải thích của DiCE trong việc tạo ra các phản chứng phù hợp.

Trong bài báo gốc của DiCE tác giả Mothilal [76] đã giải quyết vấn đề đa dạng trong các phản thực (counterfactuals) bằng cách giới thiệu một ràng buộc đa dạng giữa các phản thực được tạo ra ngẫu nhiên. Tuy nhiên trừ các mô hình tuyến tính đơn giản, rất khó để tạo ra các ví dụ CF hoạt động cho bất kỳ mô hình học máy nào. Chính vì thế DiCE đã tạo ra các giải thích phản chứng cho bất kỳ mô hình ML nào. Ý tưởng cốt lõi là thiết lập việc tìm kiếm các giải thích như vậy như một vấn đề tối ưu hóa, tương tự như việc tìm các ví dụ đối nghịch. DiCE còn được cải tiến thuật toán gốc qua bài báo của tác giả Wachter et al để tạo ra các phản chứng [83] bằng cách sinh ra các phản thực đa dạng, tức là những giải thích chỉ ra các kiểu thay đổi đặc trưng khác nhau. Đa dạng được cho là có lợi, vì mỗi cá nhân có thể muốn (hoặc cần) đối mặt với các kịch bản phản chứng khác nhau. Thêm vào đó, các giải thích phản thực từ DiCE cũng hữu ích cho người ra quyết định, vì họ có thể sử dụng chúng để đánh giá độ tin cậy của một dự đoán cụ thể từ mô hình học máy. Tương tự, các giải thích phản thực đối với nhiều đầu vào có thể hữu ích cho người đánh giá quyết định để đánh giá các tiêu chí như tính công bằng, và đối với các nhà phát triển mô hình để gỡ lỗi mô hình và ngăn ngừa sai sót trên dữ liệu mới. DiCE hỗ trợ Python 3+ với phiên bản ổn định của DiCE có sẵn⁹ với framework tại¹⁰.

⁸https://en.wikipedia.org/wiki/Rashomon_effect

⁹<https://pypi.org/project/dice-ml/>

¹⁰<https://github.com/microsoft/DiCE>

Dưới đây là ưu và nhược điểm của DiCE:

Ưu điểm

- DiCE cung cấp các ví dụ phản chứng dễ hiểu, giúp người dùng thấy cách thay đổi các đặc trưng đầu vào có thể thay đổi dự đoán của mô hình.
- DiCE tạo ra nhiều phản chứng khác nhau, giúp người dùng có cái nhìn toàn diện về không gian giải thích.
- DiCE có thể áp dụng cho nhiều loại mô hình học máy.

Nhược điểm

- Việc tìm kiếm nhiều phản chứng có thể tốn thời gian và tài nguyên tính toán.
- Các phản chứng có thể không luôn khả thi hoặc thực tế trong ngữ cảnh của dữ liệu do một dự đoán có thể có nhiều phản chứng.
- DiCE có thể yêu cầu dữ liệu lớn và đa dạng để tạo ra các phản chứng có giá trị và hợp lý.
- Các phản chứng chỉ có thể chính xác khi mô hình dự đoán là chính xác, và có thể bị sai lệch khi mô hình hoạt động không tốt.



Hình 3.5. Các bước chính của DiCE.

Từ hình ảnh 3.5 thể hiện quy trình của DICE bắt đầu bằng việc lựa chọn mô hình học máy đã được huấn luyện. Tiếp theo là khởi tạo Data Interface và Model Interface để kết nối với dữ liệu và mô hình học máy. Sau đó, tạo đối tượng DiCE Explainer để bắt đầu quá trình giải thích các dự đoán của mô hình. Mẫu dữ liệu cụ thể cần giải thích sẽ được chọn, trong bài luận văn này thì là mẫu đầu tiên trong mỗi bộ dữ liệu. Sau khi có mẫu dữ liệu, sử dụng DiCE để tạo ra các phản chứng (các mẫu dữ liệu giả định), thay đổi một số đặc trưng sao cho mô hình đưa ra dự đoán khác với mẫu ban đầu. Ở đây, lựa chọn thực nghiệm với số lượng phản chứng là 5 vì với số lượng phản chứng là 5 có thể thu thập đủ dữ liệu để phân

tích, đồng thời tránh làm tăng độ phức tạp và chi phí tính toán quá mức. Đây cũng là một số lượng hợp lý để đạt được kết quả chính xác mà không làm quá tải quá trình tính toán. Việc tạo ra 5 phản chứng giúp phân tích dễ dàng quan sát và so sánh sự thay đổi trong kết quả dự đoán của mô hình khi có sự thay đổi về đặc trưng. Sau khi tạo phản chứng sẽ tiến hành dự đoán kết quả cho cả mẫu dữ liệu gốc và các phản chứng để kiểm tra sự thay đổi của mô hình khi có sự thay đổi về các đặc trưng. Kết quả dự đoán giữa mẫu gốc và phản chứng sẽ được so sánh để hiểu rõ sự thay đổi trong mô hình khi thay đổi đầu vào. Tiếp theo, tính toán khoảng cách giữa mẫu gốc và phản chứng, thường sử dụng các chỉ số như khoảng cách Euclidean hoặc Cosine để đo lường sự khác biệt giữa chúng. Dựa trên các phản chứng tạo ra, các đặc trưng quan trọng ảnh hưởng đến sự thay đổi dự đoán của mô hình sẽ được xác định. Cuối cùng, trực quan hóa các đặc trưng quan trọng thông qua đồ thị hoặc biểu đồ để phân tích mức độ ảnh hưởng của từng đặc trưng đối với kết quả dự đoán. Trong đó số lượng phản chứng càng lớn, giúp hiểu rõ hơn về cách thức các đặc trưng có thể thay đổi để dẫn đến một kết quả khác. Kiểm tra sự ổn định của các đặc trưng qua nhiều phản chứng cũng là một bước quan trọng; nếu một đặc trưng thường xuyên thay đổi trong các phản chứng, đó là dấu hiệu cho thấy đặc trưng đó có tầm quan trọng cao. Cuối cùng, khi có nhiều phản chứng, tính toán khoảng cách trung bình giữa mẫu gốc và các phản chứng sẽ giúp xác định các đặc trưng ảnh hưởng nhiều nhất, từ đó tăng độ chính xác cho các đặc trưng quan trọng.

Công thức chính của DICE là hàm mục tiêu tối ưu hóa, được thiết kế để cân bằng giữa các yếu tố như độ gần gũi (proximity), độ đa dạng (diversity), và tính khả thi (feasibility) của các phản chứng. Công thức tối ưu hóa được biểu diễn ở 3.3 như sau:

$$C(x) = \arg \min_{c_1, \dots, c_k} \left(\frac{1}{k} \sum_{i=1}^k y_loss(f(c_i), y) + \lambda_1 \frac{1}{k} \sum_{i=1}^k \text{dist}(c_i, x) - \lambda_2 \text{Diversity}(c_1, \dots, c_k) \right) \quad (3.3)$$

Trong đó:

- $y_loss(f(c_i), y)$ là hàm mất mát giữa đầu ra của mô hình $f(c_i)$ và nhãn mục tiêu y .
- λ_1 và λ_2 là các siêu tham số điều khiển sự cân bằng giữa độ gần gũi và độ đa dạng của các phản chứng.
- $\text{dist}(c_i, x)$ là khoảng cách giữa mỗi phản chứng c_i và ví dụ đầu vào gốc x , dùng để đảm bảo tính khả thi của phản chứng (tức là độ gần gũi).
- $\text{Diversity}(c_1, \dots, c_k)$ là chỉ số đo lường sự đa dạng giữa các phản chứng trong tập hợp $\{c_1, c_2, \dots, c_k\}$.

Mục tiêu của công thức này là tìm ra các phản chứng sao cho chúng vừa hợp lý (độ gần gũi với đầu vào gốc), vừa đa dạng (khác biệt với nhau), đồng thời có thể giúp giải thích quyết định của mô hình cho người dùng.

Tóm lại DiCE mang đến một cách tiếp cận mạnh mẽ để giải thích và hiểu rõ hơn về các dự đoán của mô hình học máy. Bằng cách sử dụng phản chứng, ta có thể đánh giá sâu sắc

ảnh hưởng của các đặc trưng đến kết quả dự đoán, đồng thời kiểm tra sự công bằng và tính ổn định của mô hình. Việc tạo ra và phân tích với phản chứng sẽ cung cấp cái nhìn toàn diện về các đặc trưng quan trọng, giúp cải thiện độ chính xác và tính minh bạch của mô hình học máy. Những kết quả này không chỉ hỗ trợ việc giải thích mô hình mà còn giúp tăng cường khả năng đưa ra các quyết định hợp lý và có trách nhiệm trong các ứng dụng học máy thực tế. Song song đó cũng cung cấp một thực nghiệm mới với giải thích AI bằng cách tiếp cận mới lạ bằng phản chứng so với các phương pháp phổ biến như LIME và SHAP.

3.2 Xây dựng các mô hình

Việc lựa chọn các mô hình thử nghiệm cũng vô cùng quan trọng. Như đã nói ở các phần trên, trong nghiên cứu này, sử dụng hai mô hình học máy phổ biến là RF và GBC để huấn luyện, phân tích và dự đoán kết quả chẩn đoán bệnh từ dữ liệu metagenomics. RF là một thuật toán dựa trên cây quyết định, trong khi GBC là một phương pháp học tăng cường (boosting) kết hợp nhiều cây quyết định nhỏ thành một mô hình mạnh mẽ hơn. Cả hai mô hình này được lựa chọn vì khả năng xử lý dữ liệu phức tạp, không yêu cầu xử lý quá nhiều đặc trưng đầu vào như deep learning (DL), và có thể giải thích được các quyết định của mô hình.

3.2.1 RF model

RF là một thuật toán học có giám sát được phát triển bởi Leo Breiman vào năm 2001 [84]. Mô hình này hoạt động bằng cách xây dựng nhiều cây quyết định và kết hợp chúng để đưa ra kết quả cuối cùng. Mỗi cây quyết định trong rừng sẽ được huấn luyện trên một tập con của dữ liệu và dự đoán kết quả, sau đó kết quả của tất cả các cây sẽ được tổng hợp lại (bằng cách lấy trung bình hoặc bỏ phiếu) ¹¹ để đưa ra dự đoán cuối cùng. Trong bài luận văn này đã cấu hình mô hình Random Forest với các tham số ¹² như `n_estimators` là 500 (số lượng cây trong rừng), `max_depth` là 10 (chiều sâu tối đa của mỗi cây), `min_samples_split` là 2 (số lượng mẫu tối thiểu để phân chia một nút), `max_features` là 3 (số lượng tính năng được sử dụng trong mỗi lần phân chia), và `random_state` là None (giữ nguyên giá trị mặc định để không cố định tính ngẫu nhiên).

Các tính năng chính của Random Forest

- Độ chính xác cao: Kết hợp nhiều cây quyết định giúp cải thiện hiệu suất dự đoán.
- Chống overfitting: Tạo mô hình tổng quát tốt hơn, giảm nguy cơ ghi nhớ dữ liệu huấn luyện.
- Xử lý dữ liệu lớn: Phân chia công việc giữa các cây, tăng tốc xử lý.
- Đánh giá biến quan trọng: Xác định các đặc điểm quan trọng thúc đẩy dự đoán.

¹¹<https://www.geeksforgeeks.org/random-forest-algorithm-in-machine-learning/>

¹²<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>

- Xác thực tích hợp: Sử dụng dữ liệu out-of-bag để đánh giá mô hình.
- Xử lý giá trị thiếu: Đưa ra dự đoán đáng tin cậy từ dữ liệu không đầy đủ.
- Tăng tốc song song: Xây dựng cây đồng thời, tối ưu hóa thời gian xử lý.

3.2.2 GBC model

Gradient Boosting là một thuật toán tăng cường phổ biến trong học máy, được sử dụng cho các tác vụ phân loại và hồi quy. Ý tưởng đằng sau việc tăng cường xuất phát từ trực giác rằng những người học yếu (weak learners) có thể được sửa đổi để trở nên tốt hơn. AdaBoost là thuật toán tăng cường đầu tiên, được đúc kết trong khuôn khổ thống kê của Leo Breiman (1997). Nền tảng này đã mở đường cho Jerome H. Friedman phát triển thuật toán tăng cường gradient cho hồi quy [85]. Sau đó, Gradient Boosting đã được mở rộng và ứng dụng vào nhiều lĩnh vực khác của học máy và thống kê, vượt xa các ứng dụng ban đầu trong hồi quy và phân loại. Thuật ngữ “Gradient” trong Gradient Boosting ám chỉ thực tế rằng thuật toán này sử dụng các đạo hàm (gradient) để giảm thiểu hàm mất mát, cụ thể là một thuật toán giảm thiểu lặp bằng cách chọn một hàm hướng đến gradient âm của hàm mất mát – tức một giả thuyết yếu¹³. Trong bài luận văn này đã cấu hình mô hình Gradient Boosting với các tham số¹⁴ như sau: `n_estimators = 500` (số lượng cây trong mô hình), `max_depth = 5` (chiều sâu tối đa của mỗi cây), `min_samples_split = 2` (số lượng mẫu tối thiểu để phân chia mỗi nút), `min_samples_leaf = 1` (số mẫu tối thiểu ở mỗi lá), `learning_rate = 0.05` (tốc độ học giúp điều chỉnh ảnh hưởng của mỗi cây), và `random_state = None` (giữ giá trị mặc định để không cố định tính ngẫu nhiên).

Tính năng và ưu điểm của GBC¹⁵:

- Cập nhật trọng số dựa trên gradient: Gradient Boosting cập nhật trọng số bằng cách tính toán gradient âm của hàm mất mát (loss function) đối với đầu ra dự đoán. Điều này giúp mô hình cải thiện từng bước bằng cách giảm thiểu lỗi dự đoán, nhờ vào thông tin từ gradient.
- Đa dạng mô hình cơ sở: Gradient Boosting có thể sử dụng nhiều loại mô hình cơ sở khác nhau, như cây quyết định (decision trees) và các mô hình tuyến tính. Tuy nhiên, cây quyết định thường được sử dụng phổ biến nhất vì chúng dễ dàng huấn luyện và tương thích tốt với phương pháp boosting.
- Khả năng chống lại các giá trị ngoại lai (outliers): Gradient Boosting có tính ổn định cao hơn, vì việc cập nhật trọng số dựa trên gradient giúp giảm sự ảnh hưởng của các điểm dữ liệu ngoại lai. Điều này khiến Gradient Boosting trở nên ít nhạy cảm với các giá trị ngoại lai hơn so với các thuật toán khác.

¹³<https://www.digitalocean.com/community/tutorials/gradient-boosting-for-classification>

¹⁴<https://scikit-learn.org/dev/modules/generated/sklearn.ensemble.GradientBoostingClassifier.html>

¹⁵https://www.geeksforgeeks.org/ml-gradient-boosting/?ref=header_outind

3.3 Giải pháp cài đặt

Trước khi bắt đầu quá trình nghiên cứu và phân tích bộ dữ liệu, đề tài này tiến hành chuẩn bị các công cụ cần thiết. Đầu tiên, đề tài này cài đặt môi trường trên máy tính cá nhân có tên là MY-PC với các thông số sau. Các thư viện cần thiết bao gồm keras (trong TensorFlow phiên bản 2.9.0), deepmg, numpy, matplotlib,... đã được lưu vào tập tin requirements.txt có sẵn trong mã code. Mã được thực thi trên máy tính chạy hệ điều hành Ubuntu 20.04.6 LTS, trang bị CPU Intel(R) Core(TM) i5-1135G7, bộ nhớ RAM 8GB, và hệ điều hành Windows 10 Home Single Language. Kết quả đầu ra của hệ thống còn phụ thuộc tốc độ mạng. Trong bài luận văn này sử dụng chủ yếu ngôn ngữ lập trình Python.

Chuẩn bị dữ liệu:

- Chuẩn bị dữ liệu metagenomic theo định dạng phù hợp, ở đây sử dụng dữ liệu với định dạng là CSV.

Xây dựng và huấn luyện Mô hình RF và GBC:

- Sử dụng 4 phương pháp XAI gồm LIME, ALIME, SHAP, DiCE để lọc ra 50 đặc trưng quan trọng nhất của mỗi bộ dữ liệu với tất cả mẫu. Sau đó huấn luyện với hai mô hình RF và GBC.

Sử dụng XAI:

- Sau khi có kết quả huấn luyện mô hình, kết hợp với tập dữ liệu của mô hình đó, sử dụng 4 phương pháp XAI trên môi trường Jupyter Notebook để giải thích kết quả tập tin mô hình, trực quan hóa một cách rõ nét kết quả của từng phương pháp và so sánh xem kết quả của XAI và kết quả của mô hình có trùng khớp không để đánh giá độ chính xác của mô hình đã lựa chọn.

3.4 Tổng kết chương

Qua chương này đề tài này đã trình bày các kiến trúc về quy trình xử lý bài toán thông qua sơ đồ và đã xây dựng mô hình phân lớp. Tìm hiểu về cách thức hoạt động của từng phương pháp, các công thức các phương pháp sử dụng và lý giải chúng. Cuối cùng đề tài này đã trình bày các giải pháp để cài đặt công cụ cho quá trình thử nghiệm.

KIỂM THỬ VÀ ĐÁNH GIÁ

4.1	Môi trường thực nghiệm và cách đánh giá	44
4.1.1	Môi trường cài đặt	44
4.1.2	Các độ đo đánh giá hiệu quả	44
4.2	Kịch bản kiểm thử	46
4.3	Kết quả kiểm thử	46
4.3.1	LIME	49
4.3.2	ALIME	64
4.3.3	SHAP	78
4.3.4	DiCE	95
4.4	Thảo luận kết quả	111
4.5	So sánh kết quả với các bài báo trước	114
4.6	Tổng kết chương	116

Trong chương này đề tài này sẽ trình bày các nội dung về kết quả thực nghiệm trên các tập dữ liệu được thu thập, được thực nghiệm trên cả ba hướng tiếp cận. Đầu tiên các kết quả sau khi huấn luyện của từng phương pháp với hai mô hình sẽ được so sánh để tìm ra phương pháp có AUC cao. Sau đó sử dụng các phương pháp XAI để giải thích cho từng kết quả mô hình và thu thập các đặc trưng quan trọng nhất thuộc nhóm bệnh và không bệnh bằng hai cách tiếp cận dựa trên mẫu đầu tiên và dựa trên 50 mẫu ngẫu nhiên. Sau đó xét đến yếu tố địa lý để tìm ra các đặc trưng nào bị ảnh hưởng bởi yếu tố này và tổng hợp các kết quả.

4.1 Môi trường thực nghiệm và cách đánh giá

4.1.1 Môi trường cài đặt

Hệ thống sử dụng các thư viện phổ biến như scikit-learn, numpy, pandas, math, keras, deepmg, matplotlib,... để triển khai các bước xử lý và phân tích. Các mô hình học máy như RF và GBC cũng được áp dụng để xây dựng và huấn luyện các mô hình dự đoán. Ngoài ra, các công cụ giải thích mô hình như LIME (lime), DICE (dice-ml) cũng được sử dụng để cung cấp các giải thích giải thích được cho quyết định của mô hình. Các thư viện hỗ trợ khác như joblib (để lưu trữ mô hình), tracemalloc (theo dõi bộ nhớ), và datetime (xử lý thời gian) được tích hợp để tối ưu hóa quá trình tính toán và ghi chép kết quả. Các phương pháp đánh giá mô hình như accuracy, log loss, roc_auc_score, confusion matrix, và classification_report được sử dụng để đánh giá hiệu suất của mô hình. Môi trường phát triển gồm Ubuntu, Jupyter Notebook. Phiên bản Python là 3.8.19 (khuyến nghị sử dụng phiên bản Python 3.6 trở lên để đảm bảo tương thích với các thư viện cần thiết)

4.1.2 Các độ đo đánh giá hiệu quả

Trong bài toán này sử dụng nhiều độ đo khác nhau nhưng chủ yếu sử dụng độ đo AUC để đánh giá mô hình phân lớp sau khi đã trích chọn các đặc trưng theo các hướng tiếp cận. Dựa trên độ đo AUC được xem là mô hình hoàn hảo thường có AUC bằng 1, có thể cho rằng độ AUC càng cao thì khả năng phân lớp càng tốt. Công thức để tính độ đo AUC này được trình bày trong công thức 4.1 như sau:

$$AUC = \int_0^1 TPR(FPR) d(FPR) \quad (4.1)$$

Hàm mất mát này đo lường sự khác biệt giữa giá trị thực tế và giá trị dự đoán của mô hình, và mục tiêu là giảm thiểu giá trị của hàm mất mát trong quá trình huấn luyện mô hình. Công thức của phương pháp này được trình bày trong công thức 4.2.

$$\text{Loss} = -\frac{1}{N} \sum_{i=1}^N (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)) \quad (4.2)$$

Cuối cùng, đề tài này đánh giá trên độ đo MCC, với độ đo này theo như khảo sát sẽ có ba mức giá trị nhận được là -1, 0, và 1 kéo dài từ -1 đến 1. Trong đó với giá trị là 1 kết quả cho thấy là mô hình tối ưu, với 0 kết quả này ở mức ngẫu nhiên, và mức giá trị là -1 cho thấy mô hình kém hiệu quả. Đề tài này cũng dựa trên độ đo này để đánh giá độ hiệu quả được thử nghiệm trên mô hình, công thức của độ đo MCC này được trình bày trong công thức 4.3 như sau:

$$MCC = \frac{(TP \cdot TN) - (FP \cdot FN)}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (4.3)$$

Trong đó:

- TP(True Positive) là những dự đoán mà mô hình cho là dương tính và kết quả là dương tính (dương tính thật).
- FP (False Positive) là những dự đoán mà mô hình cho là dương tính nhưng kết quả lại là âm tính (còn gọi là dương tính giả).
- FN (False Negative) là những dự đoán mà mô hình cho là âm tính nhưng kết quả lại là dương tính (còn được gọi là âm tính giả).
- TN(True Negative) là những dự đoán mà mô hình cho là âm tính và kết quả là âm tính (âm tính thật).
- TPR(True Positive Rate) tỉ lệ mô hình cho là dương tính và kết quả là dương tính.
- FPR(False Positive Rate) tỉ lệ mô hình cho là dương tính nhưng kết quả lại là âm tính.
- N : Số lượng mẫu.
- y_i : Nhãn thực tế của mẫu i , có giá trị 0 hoặc 1.
- $\hat{y}_i$: Xác suất mà mô hình dự đoán mẫu i thuộc lớp 1.

Song song đó em cũng có tìm hiểu thêm về khái niệm dương tính giả và âm tính giả trong y khoa. Đo lường dương tính giả và âm tính giả trong xét nghiệm lâm sàng có thể được hiểu như sau ¹:

Tỷ lệ dương tính giả (False Positive Rate - FPR)

Tỷ lệ dương tính giả (FPR) là tỷ lệ xét nghiệm cho kết quả dương tính nhưng thực tế bệnh nhân không mắc bệnh. Nói rõ hơn FPR cho biết tỷ lệ sai lầm khi xét nghiệm cho kết quả dương tính ở người không mắc bệnh. Nó được tính bằng công thức 4.4:

$$FPR = \frac{FP}{FP + TN} \quad (4.4)$$

Tỷ lệ âm tính giả (False Negative Rate - FNR)

Tỷ lệ âm tính giả (FNR) là tỷ lệ xét nghiệm cho kết quả âm tính nhưng thực tế bệnh nhân có bệnh. FNR sẽ cho biết tỷ lệ sai lầm khi xét nghiệm cho kết quả âm tính ở người có bệnh. Công thức tính ở 4.5 là:

$$FNR = \frac{FN}{FN + TP} \quad (4.5)$$

¹<https://publish.kne-publishing.com/index.php/JCHR/article/view/12659>

Bảng 4.1. Bảng giá trị AUC của mô hình RF

AUC	LIME	ALIME	SHAP	DiCE	raw
yu	0,79178	0,78781	0,75180	0,46256	0,66280
feng	0,69691	0,73041	0,80621	0,57723	0,72771
zeller	0,80874	0,78267	0,83976	0,62013	0,78616
vogtmann	0,77728	0,80172	0,76065	0,61456	0,62532


Bảng 4.2. Bảng giá trị AUC của mô hình GBC

AUC	LIME	ALIME	SHAP	DiCE	raw
yu	0,72828	0,77640	0,63586	0,72689	0,63010
feng	0,66203	0,58978	0,84301	0,58429	0,74089
zeller	0,84479	0,85592	0,86918	0,75560	0,72652
vogtmann	0,69690	0,70876	0,87377	0,73332	0,55207

4.2 Kịch bản kiểm thử

Để kiểm thử, lọc ra 50 đặc trưng quan trọng nhất của mỗi bộ dữ liệu bằng 4 phương pháp XAI là LIME, ALIME, SHAP, DICE rồi huấn luyện chúng với các mô hình AI là RF và GBC trên dữ liệu metagenomics để phân loại bệnh ung thư đại trực tràng. Sau đó, áp dụng các phương pháp XAI như LIME, ALIME, SHAP và DICE để giải thích các đặc trưng quan trọng trong dữ liệu. Quá trình thực nghiệm được thực hiện trên mẫu đầu tiên và 50 mẫu ngẫu nhiên để đánh giá tính ổn định của các đặc trưng quan trọng. Kết quả giữa các mô hình AI và phương pháp XAI được so sánh để tìm ra phương pháp và mô hình tối ưu. Mục tiêu kiểm thử là đảm bảo tính chính xác của mô hình AI, khả năng giải thích của XAI, và tính ổn định của các đặc trưng quan trọng trong phân tích bệnh ung thư từ dữ liệu metagenomics. Song song đó là xác định được các đặc trưng gây bệnh hoặc không gây bệnh đối với mỗi phương pháp XAI và mỗi mô hình huấn luyện.


4.3 Kết quả kiểm thử

**Hình 4.1.** Biểu đồ minh họa giá trị AUC của RF và GBC trên 4 phương pháp XAI

Từ bảng 4.1, bảng 4.2 và hình 4.1 có thể thấy được hầu như phương pháp XAI của SHAP đạt giá trị cao nhất trên AUC của cả 2 mô hình RF và GBC. Với mô hình RF, AUC đạt giá

trị cao nhất đến 0.83976. Còn với mô hình GBC, AUC đạt giá trị cao nhất là 0.8737 tương ứng với phương pháp SHAP. Điều đó cho thấy rằng SHAP một phương pháp XAI hiệu quả và ổn định, đạt hiệu quả cao cũng như dự đoán về khả năng giải thích và tối ưu hóa mô hình mạnh mẽ của SHAP, đặc biệt khi áp dụng trên dữ liệu phức tạp của bệnh CRC. Cùng với đó có vẻ phương pháp LIME và ALIME phù hợp với mô hình RF vì nó có kết quả cao ở mô hình này. Còn phương pháp SHAP và DiCE thì lại phù hợp với mô hình GBC hơn khi có giá trị AUC của mô hình GBC cao hơn mô hình RF.


Độ biến thiên của đặc trưng với giá trị AUC với dữ liệu gốc



Hình 4.2. Biểu đồ biến thiên giá trị AUC của dữ liệu gốc với mô hình RF

Trong hình 4.2, chúng ta có thể thấy rõ biểu đồ có dấu hiệu tăng dần. Mặc dù biểu đồ có sự dao động nhỏ, riêng với dataset Vogtmann có sự dao động mạnh mẽ hơn các dataset khác, nhưng xu hướng tổng thể vẫn là tăng dần. Giá trị AUC tăng lên khi thêm nhiều feature

hơn, điều này cho thấy rằng các đặc trưng mới đang cung cấp thêm thông tin hữu ích cho mô hình, cũng có nghĩa là các đặc trưng này không trùng lặp thông tin và giúp mô hình có thêm nhiều thông tin để dự đoán chính xác hơn.




Hình 4.3. Biểu đồ biến thiên giá trị AUC của dữ liệu gốc với mô hình GBC

Với các biểu đồ thể hiện độ biến thiên của bộ dữ liệu bệnh CRC cho toàn bộ đặc trưng với mô hình GBC như trong hình 4.3, có thể thấy biểu đồ cũng có dấu hiệu tăng khi thêm nhiều đặc trưng tuy nhiên so với mô hình RF thì GBC lại biến động mạnh mẽ, có dấu hiệu tăng rồi giảm liên tục. Đặc biệt là 2 dataset Vogtmann và Zeller, hiệu suất của GBC dao động mạnh khi thêm nhiều đặc trưng vào mô hình. Điều này cho thấy GBC là một mô hình nhạy cảm hơn so với RF, dễ bị ảnh hưởng bởi các đặc trưng không quan trọng hoặc dễ bị gây nhiễu.

4.3.1 LIME

4.3.1.1 Mô hình RF

Phân tích kết quả với 50 đặc trưng quan trọng của mẫu đầu tiên được lựa chọn bằng các phương pháp XAI




Hình 4.4. Biểu đồ Min-Max trọng số LIME của 50 đặc trưng quan trọng

Trong hình 4.4 này, các giá trị trọng số đã được sắp xếp theo thứ tự giảm dần. Việc chọn lọc 50 đặc trưng quan trọng nhất cho toàn bộ các sample trong dataset trước khi huấn luyện nhằm giảm chiều dữ liệu. Dựa theo độ dốc của đồ thị. Rõ ràng nhất là Yu có độ dốc lớn ở giá trị dương và Feng độ dốc lớn ở giá trị âm cho thấy phương pháp LIME hầu như có thể xác định sự chênh lệch về tầm quan trọng của giá trị giữa các đặc trưng. Đặc biệt giá trị trọng số dương cao nhất là 0.01832 thuộc về dataset của Yu còn giá trị âm thấp nhất ở dataset của Feng với giá trị là 0.01793.

Với các biểu đồ phân phối trong hình 4.5 này, các trọng số của 50 đặc trưng quan trọng nhất trong mỗi bộ dữ liệu đều có xu hướng phân phối lệch phải. Các trọng số tập trung mạnh ở giá trị rất nhỏ gần 0, với một số ít các đặc trưng có trọng số cao hơn. Điều này cho thấy hầu hết các đặc trưng quan trọng có ảnh hưởng rất nhỏ, ngoại trừ một số đặc trưng có ảnh hưởng lớn hơn một chút. Với Feng và vogtmann, hai bộ dataset này có phân phối trọng số rộng hơn so với 2 bộ còn lại, một số đặc trưng có giá trị lớn (lên đến 0.1). Tuy nhiên đa phần vẫn tập trung gần 0.

Sau khi tiến hành biểu diễn các kết quả được thu thập như hình 4.6 thông qua quá trình thực nghiệm trên 10 fold, kết quả trên 4 tập dataset được hiển thị, trong hình 4.6a tập Yu cho thấy giá trị AUC nhất đạt 0.86496 với 5 đặc trưng đầu giá trị tăng vọt sau đó tăng dần




Hình 4.5. Biểu đồ phân phối trọng số LIME 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC


đều khi càng thêm nhiều đặc trưng. Tiếp theo là tập Feng được hiển thị trong hình 4.6b với kết quả AUC cao nhất được thực nghiệm là 0.80929, các giá trị tăng dần đều liên tục từ 1 đến 50 đặc trưng chứng tỏ các đặc trưng quan trọng ở đây đều có ích cho mô hình. Kế tiếp là tập Zeller có kết quả thu được cao nhất được trình bày trong hình 4.6c với giá trị AUC là 0.86276 giá trị ban đầu mặc dù có giảm đột ngột tuy nhiên đã dần ổn định và tăng vọt ở các đặc trưng cuối. Điều đó cho thấy càng về sau các đặc trưng dần có đóng góp nhiều hơn hẳn. Cuối cùng là tập Vogtmann kết quả thực nghiệm được trình bày trong hình 4.6d có giá trị AUC cao nhất sau quá trình thử nghiệm là 0.84758, kết quả có bước nhảy vọt ở 5 đặc trưng đầu nhưng rồi giảm và tăng dần đều cho đến 50 đặc trưng. Trong tất cả bộ dữ liệu, giá trị AUC của phương pháp LIME đều có xu hướng tăng khi số lượng đặc trưng quan trọng tăng, nhưng độ ổn định của AUC có sự khác biệt giữa các bộ. Ở tập dữ liệu zeller và vogtmann thì sự tăng này không rõ rệt. Các outliers (các giá trị bất thường trong tập dữ liệu) tập trung nhiều ở bộ dữ liệu như zeller và Vogtmann cho thấy tính không ổn định của mô hình có thể do đặc trưng không ổn định hoặc nhiễu, trong khi các dataset còn lại có độ ổn định cao hơn.

Từ hình 4.7, giải thích LIME với mô hình RF cho thấy rằng dự đoán của LIME hoàn toàn trùng khớp với dự đoán mô hình, điều đó chứng minh rằng LIME đã mô phỏng một cách chính xác cách mà mô hình đưa ra quyết định cho mẫu đầu tiên của mỗi tập dataset.


Với tập Yu, mô hình và LIME đều dự đoán nhãn là 1 với xác suất 0.56, cho thấy rằng mặc dù trọng số cao nhất thuộc về đặc trưng dự đoán giảm gây bệnh tuy nhiên các đặc trưng dương góp phần đáng kể vào việc dự đoán ra nhãn 1. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:




(a) Yu



(b) Feng



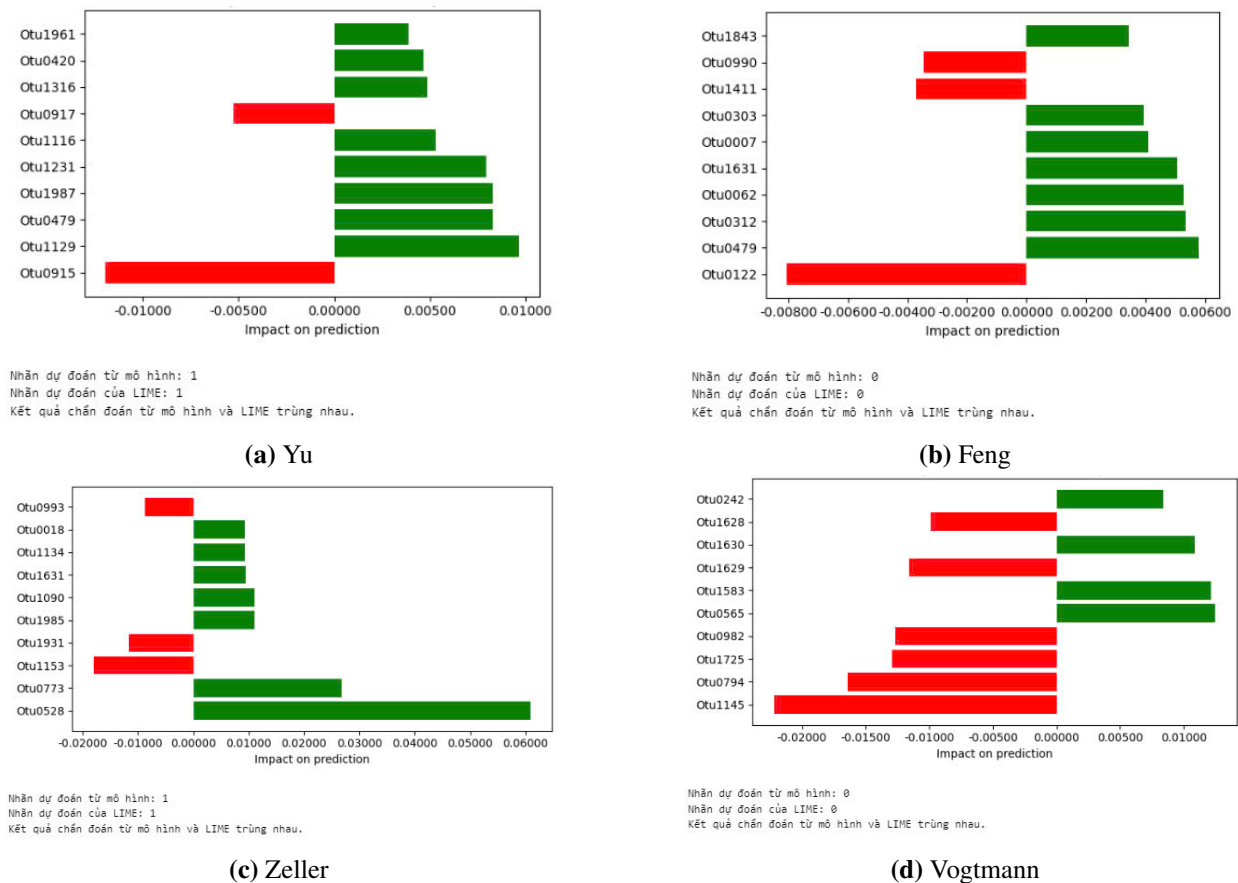
(c) Zeller



(d) Vogtmann

Hình 4.6. Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên

Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu1129, Otu0479, Otu1987, Otu1231

**Hình 4.7.** Dự đoán của LIME với bộ dataset của bệnh CRC

Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0915

Với tập Feng, mô hình và LIME đều dự đoán nhãn là 0 với xác suất 0.52700. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu0122

Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0479, Otu0312, Otu0062, Otu1631

Với tập Zeller, mô hình và LIME đều dự đoán nhãn là 1 với xác suất 0.67200. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu0528, Otu0773, Otu1985

Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu1153, Otu1931

Với tập Vogtmann, mô hình và LIME đều dự đoán nhãn là 0 với xác suất 0.53800. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu1145, Otu0794, Otu1725, Otu0982.

Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0565

Tóm lại với dự đoán bằng phương pháp LIME kết hợp với mô hình RF đã có 2 đặc trưng


xuất hiện nhiều lần gồm Otu0479 và Otu1631. Otu1631 xuất hiện trong nhóm tăng khả năng thuộc nhóm không bệnh. Đặc trưng Otu0479 ở tập Yu xuất hiện ở nhóm tăng khả năng thuộc nhóm bệnh với trọng số gần bằng 0.01, tuy nhiên trong tập Feng lại xuất hiện trong nhóm tăng khả năng thuộc nhóm không bệnh với trọng số rất thấp gần bằng 0.006.

Phân tích kết quả với 50 mẫu ngẫu nhiên

Từ hình 4.8 chúng ta có thể thấy với bộ dữ liệu của bệnh CRC thì có 2 đặc trưng có tần suất xuất hiện nhiều nhất ở cả 5 bộ dataset là Otu0479 và Otu1612. Tuy nhiên sự xuất hiện của chúng lại nằm ở hai nhóm khác nhau. Cụ thể đặc trưng Otu0479 trong tập Yu là nhóm tăng khả năng thuộc nhóm không bệnh, còn trong tập Feng lại là nhóm tăng khả năng thuộc nhóm bệnh. Với đặc trưng Otu1612 trong tập Zeller đều thuộc nhóm không bệnh.


Các biểu đồ boxplot trong hình 4.9 cho thấy sự phân bố độ quan trọng của các đặc trưng gây bệnh và không gây bệnh khác nhau. Với một số đặc trưng có phạm vi rộng và nhiều giá trị Outliers, cho thấy rằng có sự biến thiên lớn trong mức độ quan trọng giữa các đặc trưng. Một số đặc trưng có độ quan trọng ổn định hơn, trong khi các đặc trưng khác có sự phân bố rộng hơn, thể hiện sự biến động trong dữ liệu. Cụ thể trong tập Yu ở hình 4.9a, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0917 với giá trị lớn hơn 0.020, thấp nhất là Otu1316, Otu1231 với giá trị gần bằng 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0915 với giá trị lớn hơn 0.05 và giá trị nhỏ nhất là gần bằng 0.0000 thuộc về đặc trưng Otu0917. Tiếp theo tập Feng ở hình 4.9b, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0062 với giá trị lớn hơn 0.020, thấp nhất là Otu0918, Otu0312 với giá trị gần bằng 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0122 với giá trị lớn hơn 0.020 và giá trị nhỏ nhất là gần bằng 0.010 thuộc về đặc trưng Otu1678. Tập Zeller trong hình 4.9c có độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu1612 với giá trị lớn hơn 0.35, thấp nhất là Otu1061 với giá trị gần bằng 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1612 với giá trị lớn hơn 0.30 và giá trị nhỏ nhất dưới 0.05 thuộc về đặc trưng Otu0431. Và cuối cùng tập Votgmann ở hình 4.9d độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu1630 với giá trị lớn hơn 0.030, thấp nhất là Otu1628 với giá trị thấp hơn 0.010. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1145 với giá trị lớn hơn 0.0250 và giá trị nhỏ nhất hơn 0.0100 thuộc về đặc trưng Otu0565.

Song song đó có thể thấy một số đặc trưng thuộc cả nhóm tăng khả năng bệnh và tăng khả năng không bệnh. Vì trong một số trường hợp, đặc trưng đó có thể có ảnh hưởng tích cực hoặc tiêu cực tùy thuộc vào các mẫu hoặc tùy thuộc vào cách giải thích của LIME. Dù vậy thì một đặc trưng có thể xuất hiện trong cả hai nhóm, nhưng độ quan trọng của nó thì khác nhau. Có đặc trưng có thể có tác động mạnh mẽ trong nhóm gây bệnh và tác động yếu hơn trong nhóm không gây bệnh, hoặc ngược lại. Điều này dẫn đến sự xuất hiện của đặc trưng trong cả hai nhóm nhưng với phân bố độ quan trọng khác nhau. Từ Hình 9 và 10 có thể thấy tần suất xuất hiện của đặc trưng nhiều hay ít cũng không ảnh hưởng đến mức độ quan trọng cũng như mức độ ảnh hưởng của nó đến việc dự đoán mô hình XAI. Có những đặc trưng xuất hiện rất nhiều lần với nhiều mẫu, tuy nhiên giá trị trọng số rất nên không ảnh hưởng đến kết quả. Các đặc trưng vừa có tần suất xuất hiện thường xuyên vừa có độ



Hình 4.8. Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên

quan trọng cao bao gồm:



Hình 4.9. Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên

+ Các đặc trưng tăng khả năng bệnh: Otu0915, otu1145

+ Các đặc trưng tăng khả năng không bệnh: Otu0479, Otu1129, Otu1617, Otu0062, Otu0312, Otu0565, Otu0302, Otu1612, Otu0294.


Các đặc trưng thu thập được ở cả lần thực nghiệm LIME với mẫu đầu tiên của mỗi tập dữ liệu và với 50 mẫu ngẫu nhiên chi tiết như sau:

+ Các đặc trưng gây bệnh: Otu0420, Otu1316, Otu1231, Otu0122, Otu1145, Otu1628.

+ Các đặc trưng không gây bệnh: Otu0915, Otu0479, Otu0917, Otu0062, Otu0312, Otu0303.

4.3.1.2 Mô hình GBC


Phân tích kết quả với 50 đặc trưng quan trọng của mẫu đầu tiên được lựa chọn bằng các phương pháp XAI



Hình 4.10. Biểu đồ Min-Max trọng số LIME của 50 đặc trưng quan trọng

Trong hình 4.10 này, các giá trị trọng số đã được sắp xếp theo thứ tự giảm dần. Dựa theo độ dốc của đồ thị, dataset Yu có độ dốc lớn với giá trị dương, còn Feng và vogtmann có độ dốc lớn với giá trị âm. Trong cả 5 bộ dataset, giá trị trọng số dao động lớn nhất trong khoảng từ 0.3 đến -0.3. Cụ thể giá trị trọng số dương cao nhất là 0.34973 thuộc về tập Yu còn giá trị âm thấp nhất là của tập Feng với giá trị là 0.33175.

Với các biểu đồ phân phối trong hình 4.11 này, tương tự như RF model, các trọng số của 50 đặc trưng quan trọng nhất trong mỗi bộ dữ liệu đều có xu hướng phân phối lệch phải. Các trọng số tập trung mạnh ở giá trị rất nhỏ gần 0, với một số ít các đặc trưng có trọng số cao hơn. Điều này cho thấy hầu hết các đặc trưng quan trọng có ảnh hưởng rất nhỏ, ngoại




Hình 4.11. Biểu đồ phân phối trọng số LIME 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC


trừ một số đặc trưng có ảnh hưởng lớn hơn một chút. Với dataset của Feng có phân phối trọng số rộng hơn so với các bộ còn lại, một số đặc trưng có giá trị lớn (lên đến 0.0175). Tuy nhiên đa phần vẫn tập trung gần 0.

Sau khi tiến hành biểu diễn các kết quả được thu thập như hình 4.12 thông qua quá trình thực nghiệm trên 10 fold, kết quả trên 4 tập dataset được hiển thị, trong hình 4.12a tập Yu cho thấy giá trị AUC nhất đạt 0.84036 khi có giá trị tăng dần ở các đặc trưng đầu và cuối. Tiếp theo là tập Feng được hiển thị trong hình 4.12b với kết quả AUC cao nhất được thực nghiệm là 0.82179 các giá trị trung bình tăng liên tục chứng tỏ với dữ liệu này, mỗi đặc trưng được thêm vào đều có đóng góp cho mô hình. Kế tiếp là tập Zeller có kết quả thu được cao nhất được trình bày trong hình 4.12c với giá trị AUC là 0.88558 mặc dù ở 5 đặc trưng đầu các giá trị có dấu hiệu giảm nhưng sau đó dần ổn định và tăng ít về cuối. Cuối cùng là tập Vogtmann kết quả thực nghiệm được trình bày trong hình 4.12d có giá trị AUC cao nhất sau quá trình thử nghiệm là 0.78200 với các giá trị liên tục tăng cho thấy mỗi đặc trưng khi được thêm vào đều có những lợi ích tích cực cho mô hình. Trong tất cả bộ dữ liệu, giá trị AUC của phương pháp LIME đều có xu hướng tăng khi số lượng đặc trưng quan trọng tăng, nhưng độ ổn định của AUC có sự khác biệt giữa các bộ. Ở tập zeller và vogtmann thì sự tăng này không rõ rệt. Các outliers (các giá trị bất thường trong tập dữ liệu) tập trung nhiều ở bộ dữ liệu như Yu và Vogtmann cho thấy tính không ổn định của mô hình có thể do đặc trưng không ổn định hoặc nhiễu, trong khi các tập dataset còn lại có độ ổn định cao hơn.


Từ hình 4.13, giải thích LIME với mô hình GBC cho thấy rằng dự đoán của LIME hoàn toàn trùng khớp với dự đoán mô hình, điều đó chứng minh rằng LIME đã mô phỏng một




(a) Yu



(b) Feng



(c) Zeller




(d) Vogtmann

Hình 4.12. Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên


cách chính xác cách mà mô hình đưa ra quyết định cho mẫu đầu tiên của mỗi dataset.

Với dataset Yu, mô hình và LIME đều dự đoán nhãn là 1 với xác suất 0.99351. Dưới đây




Nhãn dự đoán từ mô hình: 1
 Nhãn dự đoán của LIME: 1
 Kết quả chẩn đoán từ mô hình và LIME trùng nhau.

(a) Yu




Nhãn dự đoán từ mô hình: 0
 Nhãn dự đoán của LIME: 0
 Kết quả chẩn đoán từ mô hình và LIME trùng nhau.

(b) Feng



Nhãn dự đoán từ mô hình: 1
 Nhãn dự đoán của LIME: 1
 Kết quả chẩn đoán từ mô hình và LIME trùng nhau.

(c) Zeller



Nhãn dự đoán từ mô hình: 0
 Nhãn dự đoán của LIME: 0
 Kết quả chẩn đoán từ mô hình và LIME trùng nhau.

(d) Vogtmann

Hình 4.13. Dự đoán của LIME với bộ dataset của bệnh CRC

là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu1550, Otu0217, Otu0793, Otu0915

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu1136

Với dataset Feng, mô hình và LIME đều dự đoán nhãn là 0 với xác suất 0.94546. Mặc dù trọng số cao nhất thuộc về đặc trưng dự đoán tăng khả năng bệnh tuy nhiên các đặc trưng có giá trị dương góp phần đáng kể vào việc dự đoán ra nhãn 0. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu1612, Otu0294

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0302, Otu1061, Otu1631

Với dataset Zeller, mô hình và LIME đều dự đoán nhãn là 1 với xác suất tuyệt đối là 1.00000. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu1833, Otu0565

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0918, Otu0353, Otu1521

Với dataset Vogtmann, mô hình và LIME đều dự đoán nhãn là 0 với xác suất cao 0.98828. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu1629


+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu1310, Otu0990, Otu1363, Otu1727

Tóm lại với dự đoán bằng phương pháp LIME kết hợp với mô hình RF đã có 7 đặc trưng xuất hiện nhiều lần gồm Otu0993, Otu0217, Otu1136, Otu0990, Otu1644. Trong đó Otu0993 xuất hiện trong nhóm tăng khả năng thuộc nhóm bệnh, Otu1644 xuất hiện trong nhóm tăng khả năng thuộc nhóm không bệnh. Đặc trưng Otu0217 ở dataset yu xuất hiện ở nhóm tăng khả năng thuộc nhóm bệnh với trọng số lớn hơn 0.1, tuy nhiên trong dataset zeller lại xuất hiện trong nhóm tăng khả năng thuộc nhóm không bệnh với trọng số rất thấp gần bằng 0.005. Đặc trưng Otu1136 ở dataset yu xuất hiện ở nhóm tăng khả năng thuộc nhóm không bệnh với trọng số lớn hơn 0.1, tuy nhiên trong dataset Vogtmann lại xuất hiện trong nhóm tăng khả năng thuộc nhóm bệnh với trọng số rất thấp chưa đến 0.05. Đặc trưng Otu0990 ở dataset Feng xuất hiện ở nhóm tăng khả năng thuộc nhóm bệnh với trọng số rất thấp, tuy nhiên trong dataset Vogtmann lại xuất hiện trong nhóm tăng khả năng thuộc nhóm không bệnh với trọng số gần bằng 0.06.

Phân tích kết quả với 50 mẫu ngẫu nhiên


Từ hình 4.14 chúng ta có thể thấy với bộ dữ liệu của bệnh CRC thì có 5 đặc trưng có tần suất xuất hiện nhiều nhất ở cả 5 bộ dataset là Otu0217, Otu0993, Otu1777, Otu0302 và Otu1612. Tuy nhiên sự xuất hiện của chúng lại nằm ở hai nhóm khác nhau. Cụ thể đặc trưng Otu0993 trong Zeller là nhóm tăng khả năng thuộc nhóm bệnh, còn trong Yu và Vogtmann lại là nhóm tăng khả năng thuộc nhóm không bệnh. Với đặc trưng Otu1612, trong dataset của Crc và zeller đều thuộc nhóm không bệnh. Otu1777 trong Crc thuộc nhóm bệnh còn với Vogtmann lại thuộc nhóm không bệnh. Otu 0217 thuộc nhóm bệnh với dataset của Zeller, còn thuộc nhóm không bệnh ở dataset của Yu.

Tương tự phương pháp LIME với RF, LIME với GBC cho ra các biểu đồ boxplot trong hình 4.15 với sự phân bố độ quan trọng của các đặc trưng gây bệnh và không gây bệnh khác nhau. Với một số đặc trưng có phạm vi rộng và nhiều giá trị outliers, cho rằng có sự biến thiên lớn trong mức độ quan trọng giữa các đặc trưng. Một số đặc trưng có độ quan trọng ổn định hơn, trong khi các đặc trưng khác có sự phân bố rộng hơn, thể hiện sự biến động trong dữ liệu. Cụ thể trong tập Yu ở hình 4.15a, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0847 với giá trị lớn hơn 0.150, thấp nhất là Otu0217 với giá trị gần bằng 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0915 với giá trị lớn hơn 0.5 và giá trị nhỏ nhất là gần bằng 0.0000 thuộc về đặc trưng Otu0217. Tiếp theo tập Feng ở hình 4.15b, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu1612 với giá trị lớn hơn 0.30, thấp nhất là Otu1061 với giá trị gần bằng 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1612 với giá trị lớn hơn 0.30 và giá trị nhỏ nhất dưới 0.05 thuộc về đặc trưng Otu0431. Tập Zeller trong hình 4.15c có độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu1636 với giá trị xấp xỉ 0.0200, thấp nhất là Otu1705 với giá



Hình 4.14. Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên

trị gần bằng 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1855 với giá trị thấp hơn 0.030 và giá trị nhỏ nhất gần bằng 0.00000



Hình 4.15. Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên

thuộc về đặc trưng Otu1855 và Otu0217. Và cuối cùng tập Vogtmann ở hình 4.15d độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu1310 với giá trị lớn hơn 0.35,

thấp nhất là Otu1644 với giá trị gần bằng 0.00000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1310 với giá trị lớn hơn 0.7 và giá trị nhỏ nhất gần bằng 0.00000 thuộc về đặc trưng Otu1363.

Một số đặc trưng có thể đồng thời xuất hiện trong cả nhóm tăng khả năng gây bệnh và nhóm tăng khả năng không gây bệnh. Điều này xuất phát từ việc những đặc trưng này có thể tác động theo hai hướng, tích cực hoặc tiêu cực, tùy thuộc vào từng mẫu hoặc vào cách giải thích của LIME. Tuy nhiên, mức độ quan trọng của chúng trong hai nhóm thường không giống nhau. Cụ thể, một đặc trưng có thể thể hiện mức ảnh hưởng mạnh mẽ trong nhóm gây bệnh nhưng lại có tác động yếu hơn trong nhóm không gây bệnh, hoặc ngược lại. Điều này dẫn đến sự xuất hiện của đặc trưng trong cả hai nhóm nhưng với phân bố độ quan trọng khác nhau. Các đặc trưng vừa có tần suất xuất hiện thường xuyên vừa có độ quan trọng cao bao gồm:

+ Các đặc trưng tăng khả năng bệnh: Otu1440, Otu0217, Otu1385

+ Các đặc trưng tăng khả năng không bệnh: Otu0915, Otu0847, Otu0793, Otu1612, Otu0302, Otu0294, Otu1833, Otu0217, Otu0993, Otu1310.

Các đặc trưng thu thập được ở cả lần thực nghiệm LIME với mẫu đầu tiên của mỗi tập dữ liệu và với 50 mẫu ngẫu nhiên chi tiết như sau:

+ Các đặc trưng gây bệnh: Otu0793, Otu1440, Otu0217, Otu1550, Otu1612, Otu0294, Otu1636.

+ Các đặc trưng không gây bệnh: Otu0847, Otu0217, Otu0302, Otu0431, Otu1521, Otu1310, Otu1727, Otu1363.

Tóm lại

Tóm lại với phương pháp LIME cho cả 2 mô hình RF ở phần 4.3.1.1 và GBC ở phần 4.3.1.2, LIME dự đoán tốt hơn khi kết hợp với mô hình GBC với dự đoán gần như tuyệt đối. Cả 2 mô hình khi kết hợp với LIME đều dự đoán chính xác so với mô hình. Sau khi thực nghiệm LIME với mô hình RF và GBC ở 2 cách thức tiếp cận là trên mẫu đầu tiên và trên 50 mẫu ngẫu nhiên, đề tài thu thập được các đặc trưng sau đây:

+ Các đặc trưng tăng khả năng bệnh: Otu0420, Otu1316, Otu1231, Otu0122, Otu1145, Otu1628, Otu1440, Otu1385, Otu1550, Otu1636, Otu1140, Otu1644.


+ Các đặc trưng tăng khả năng không bệnh: Otu0479, Otu1129, Otu1617, Otu0062, Otu0312, Otu0565, Otu0302, Otu0917, Otu0303, Otu0847, Otu1833, Otu1310, Otu0431, Otu1521, Otu1727, Otu1363, Otu1631, Otu0847.

Các đặc trưng thuộc cả 2 nhóm bệnh và không bệnh: Otu0915, Otu1612, Otu0565, Otu0217, Otu0793, Otu0294, Otu0993, Otu0990

4.3.2 ALIME

4.3.2.1 Mô hình RF

Phân tích kết quả với 50 đặc trưng quan trọng của mẫu đầu tiên được lựa chọn bằng các phương pháp XAI




Hình 4.16. Biểu đồ Min-Max trọng số ALIME của 50 đặc trưng quan trọng

Từ hình 4.16 trên, các giá trị trọng số đã được sắp xếp theo thứ tự giảm dần. Dựa theo độ dốc của đồ thị, dataset Yu và Vogtmann ở giá trị dương có độ dốc cao cho thấy ALIME có thể xác định sự chênh lệch rõ rệt về tầm quan trọng của giá trị dương giữa các đặc trưng. Trong khi đó dataset Zeller và Feng lại có xu hướng có độ dốc cao ở giá trị âm thể nên với 2 tập dataset này ALIME cho thấy sự chênh lệch giá trị trọng số rõ ràng ở giá trị âm giữa các đặc trưng quan trọng. Đặc biệt giá trị trọng số dương cao nhất là 0.01827 thuộc về tập của Yu còn giá trị âm thấp nhất ở tập của Zeller với giá trị là 0.01647.

Nhìn vào hình 4.17, có thể thấy các trọng số của 50 đặc trưng quan trọng nhất trong mỗi bộ dữ liệu đều có xu hướng phân phối lệch phải. Các trọng số tập trung mạnh ở giá trị rất nhỏ gần 0, với một số ít các đặc trưng có trọng số cao hơn. Điều này cho thấy hầu hết các đặc trưng quan trọng có ảnh hưởng rất nhỏ, ngoại trừ một số đặc trưng có ảnh hưởng lớn hơn một chút. Riêng dataset của Vogtmann, có thể thấy rõ sự phân phối trọng số rộng hơn so với 3 bộ còn lại nhưng giá trị rất thấp, còn với Feng tuy phân phối không nhiều nhưng giá trị trọng số có giá trị lớn (lên đến 0.08). Dù vậy thì các giá trị đa phần vẫn tập trung gần 0.


Sau khi tiến hành biểu diễn các kết quả được thu thập như Hình 4.18 thông qua quá trình thực nghiệm trên 10 fold, kết quả trên 4 tập dataset được hiển thị, trong Hình 4.18a tập Yu




Hình 4.17. Biểu đồ phân phối trọng số ALIME 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC

cho thấy giá trị AUC nhất đạt 0.84905 các giá trị tăng dần khi càng thêm nhiều đặc trưng cho thấy các đặc trưng được thêm vào có đóng góp cho mô hình. Tiếp theo là tập Feng được hiển thị trong Hình 4.18b với kết quả AUC cao nhất được thực nghiệm là 0.87548 dù tầm 4 đặc trưng đầu có dấu hiệu ổn định nhưng càng về sau các đặc trưng được thêm vào nhiều hơn thì biểu đồ càng có xu hướng tăng mạnh về cuối. Kế tiếp là tập Zeller có kết quả thu được cao nhất được trình bày trong Hình 4.18c với giá trị AUC là 0.85231 mặc dù tăng chậm nhưng các giá trị đã tăng liên tục từ 1 đến 50 đặc trưng. Cuối cùng là tập Vogtmann kết quả thực nghiệm được trình bày trong Hình 4.18d có giá trị AUC cao nhất sau quá trình thử nghiệm là 0.86750, các giá trị tăng mạnh đến 10 đặc trưng thì có sự ổn định cho thấy rằng hầu như các đặc trưng sau được thêm vào không có đóng góp quan trọng. Trong tất cả bộ dữ liệu, giá trị AUC của phương pháp ALIME đều có xu hướng tăng khi số lượng đặc trưng quan trọng tăng, nhưng độ ổn định của AUC có sự khác biệt giữa các bộ. Ở tập dữ liệu vogtmann thì sự tăng này không rõ rệt thậm chí có dấu hiệu giảm và tập trung nhiều Outliers cho thấy tính không ổn định của mô hình có thể do đặc trưng không ổn định hoặc nhiễu, trong khi các tập còn lại có độ ổn định cao hơn.


Từ hình 4.19, giải thích ALIME với mô hình RF cho thấy chỉ có 2 tập Feng và Vogtmann là ALIME dự đoán trùng khớp với mô hình, tuy nhiên, đối với các tập Yu và Zeller, dự đoán của ALIME không trùng khớp, điều này có thể chỉ ra rằng ALIME có thể hoạt động tốt hơn với một số loại dữ liệu hoặc tập con dữ liệu cụ thể, trong khi ở những tập dữ liệu khác, dự đoán của ALIME không chính xác. Rõ ràng với mô hình RF, ALIME đã dự đoán không tốt bằng LIME. ALIME kết hợp autoencoder với LIME để tạo ra các giải thích dựa trên không gian nén của autoencoder. Tuy nhiên, việc nén dữ liệu đã có thể làm mất đi một số thông tin quan trọng mà LIME có thể khai thác trực tiếp từ dữ liệu gốc.




(a) Yu



(b) Feng




(c) Zeller




(d) Vogtmann

Hình 4.18. Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên


Với tập Yu, mô hình dự đoán nhãn là 1 trong khi ALIME lại dự đoán là nhãn 0. Với giải thích của ALIME, xác suất 0.552, cho thấy rằng mặc dù trọng số cao nhất thuộc về đặc trưng trong nhóm giảm khả năng dự đoán tuy nhiên đặc trưng dương góp phần đáng kể vào




(a) Yu



(b) Feng



(c) Zeller



(d) Vogtmann

Hình 4.19. Dự đoán của ALIME với bộ dataset của bệnh CRC

việc dự đoán ra nhãn 0. Vì sau khi dự đoán kết quả hầu hết đều ra các đặc trưng tăng khả năng gây bệnh nên dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất gây bệnh và kèm theo đó là đặc trưng có góp phần vào nhóm không gây bệnh như sau:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu1204, Otu0915, Otu0479, Otu0677, Otu1859.

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0089.

Với tập Feng, mô hình và ALIME đều dự đoán nhãn là 0 với xác suất 0.52. Vì sau khi dự đoán kết quả hầu hết đều ra các đặc trưng tăng khả năng gây bệnh nên dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất gây bệnh và kèm theo đó là đặc trưng có góp phần vào nhóm không gây bệnh như sau:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu0923, Otu0042, Otu0562, Otu0565, Otu1947

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0309

Với tập Zeller, mô hình dự đoán nhãn là 1 trong khi ALIME lại dự đoán là nhãn 0. Với giải thích của ALIME, xác suất 0.576 nghiêng về dự đoán không bệnh. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu0639, Otu1457

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0550, Otu0760,

Otu1882 Với tập Vogtmann, mô hình và ALIME đều dự đoán nhãn là 0 với xác suất 0.66200. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu0228, Otu1919, Otu0770

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0565, Otu1116


Tóm lại với dự đoán bằng phương pháp ALIME kết hợp với mô hình RF có duy nhất 1 đặc trưng xuất hiện nhiều lần là Otu0565. Đặc trưng Otu0565 ở tập Feng xuất hiện ở nhóm tăng khả năng thuộc nhóm gây bệnh với trọng số gần bằng 0.0075, tuy nhiên trong tập Vogtmann lại xuất hiện trong nhóm tăng khả năng thuộc nhóm không bệnh với trọng số xấp xỉ 0.02.

Phân tích kết quả với 50 mẫu ngẫu nhiên

Từ hình 4.20 chúng ta có thể thấy với bộ dữ liệu của bệnh crc thì có 1 đặc trưng có tần suất xuất hiện nhiều nhất ở cả 5 bộ dataset là Otu1116 tuy nhiên ở tập Yu lại xuất hiện ở nhóm gây bệnh còn ở tập Vogtmann xuất hiện trong nhóm không gây bệnh. Còn lại 5 đặc trưng cũng xuất hiện nhiều nhưng lại nằm cùng 1 tập dữ liệu chỉ là khác nhóm gồm Otu1204, Otu0550, Otu0639, Otu0770, Otu0228.


Các biểu đồ boxplot trong hình 4.21 cho thấy sự phân bố độ quan trọng của các đặc trưng gây bệnh và không gây bệnh khác nhau. Với một số đặc trưng có phạm vi rộng và nhiều giá trị Outliers, cho thấy rằng có sự biến thiên lớn trong mức độ quan trọng giữa các đặc trưng. Một số đặc trưng có độ quan trọng ổn định hơn, trong khi các đặc trưng khác có sự phân bố rộng hơn, thể hiện sự biến động trong dữ liệu. Cụ thể trong tập Yu ở hình 4.21a, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0917 với giá trị thấp hơn 0.020, thấp nhất là Otu0672, Otu1116 với giá trị gần bằng 0.01. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1118 với giá trị thấp hơn 0.00000 và giá trị nhỏ nhất là gần bằng -0.06 thuộc về đặc trưng Otu0915. Tiếp theo tập Feng ở hình 4.21b, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0923 với giá trị lớn hơn 0.04, thấp nhất là Otu1952 với giá trị gần bằng -0.03. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1947 với giá trị lớn hơn 0.020 và giá trị nhỏ nhất là gần bằng -0.015 thuộc về đặc trưng Otu0042. Tập Zeller trong hình 4.21c có độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0639 với giá trị lớn hơn 0.011, thấp nhất là Otu1324 với giá trị gần bằng 0.0040. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0550 với giá trị thấp hơn -0.004 và giá trị nhỏ nhất dưới -0.009 thuộc về đặc trưng Otu1457. Và cuối cùng tập Vogtmann ở hình 4.21d độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0664 với giá trị lớn hơn 0.0100, thấp nhất là Otu0357 với giá trị thấp hơn -0.025. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0228 với giá trị lớn hơn 0.0300 và giá trị nhỏ nhất hơn 0.0100 thuộc về đặc trưng Otu1550.

Song song đó có thể thấy một số đặc trưng thuộc cả nhóm tăng khả năng bệnh và tăng khả năng không bệnh. Vì trong một số trường hợp, đặc trưng đó có thể có ảnh hưởng tích cực hoặc tiêu cực tùy thuộc vào các mẫu hoặc tùy thuộc vào cách giải thích của ALIME.



Hình 4.20. Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên

Dù vậy thì một đặc trưng có thể xuất hiện trong cả hai nhóm, nhưng độ quan trọng của nó thì khác nhau. Có đặc trưng có thể có tác động mạnh mẽ trong nhóm gây bệnh và tác động yếu hơn trong nhóm không gây bệnh, hoặc ngược lại. Điều này dẫn đến sự xuất hiện của đặc trưng trong cả hai nhóm nhưng với phân bố độ quan trọng khác nhau. Từ Hình 4.20 và 4.21 có thể thấy tần suất xuất hiện của đặc trưng nhiều hay ít cũng không ảnh hưởng đến mức độ quan trọng cũng như mức độ ảnh hưởng của nó đến việc dự đoán mô hình XAI. Có những đặc trưng xuất hiện rất nhiều lần với nhiều mẫu, tuy nhiên giá trị trọng số rất nên



Hình 4.21. Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên

không ảnh hưởng đến kết quả. Các đặc trưng vừa có tần suất xuất hiện thường xuyên vừa có độ quan trọng cao bao gồm:

+ Các đặc trưng tăng khả năng bệnh: Otu0672, otu0917, Otu1204, Otu1116, Otu1952, Otu0923, Otu1784, Otu0944, Otu0309, Otu0639, Otu0760, Otu0406, Otu1249, Otu0664, Otu0357, Otu0770, Otu0228, Otu1915.

+ Các đặc trưng tăng khả năng không bệnh: Otu0677, Otu1204, Otu0915, Otu1118, Otu0280, Otu1947, Otu0562, Otu0042, Otu0048, Otu1776, Otu1457, Otu0639, Otu0062, Otu1882, Otu0550, Otu0565, Otu1116, Otu0228, Otu0770, Otu1550.


Các đặc trưng thu thập được ở cả lần thực nghiệm ALIME với mẫu đầu tiên của mỗi tập dữ liệu và với 50 mẫu ngẫu nhiên chi tiết như sau:

+ Các đặc trưng gây bệnh: Otu1204, Otu1118, Otu1116, Otu1952, Otu0923, Otu0639, Otu0406, Otu1324, Otu0357.

+ Các đặc trưng không gây bệnh: Otu1882, Otu0550, Otu0228, Otu0770, Otu1550.

4.3.2.2 Mô hình GBC


Phân tích kết quả với 50 đặc trưng quan trọng của mẫu đầu tiên được lựa chọn bằng các phương pháp XAI



Hình 4.22. Biểu đồ Min-Max trọng số LIME của 50 đặc trưng quan trọng

Trong Hình 4.22 này, các giá trị trọng số đã được sắp xếp theo thứ tự giảm dần. Rõ ràng nhất là tập Yu và Zeller có độ dốc lớn ở giá trị dương và Feng với Votgmman độ dốc lớn ở giá trị âm cho thấy phương pháp ALIME hầu như có thể xác định sự chênh lệch về tầm quan trọng của giá trị giữa các đặc trưng. Đặc biệt giá trị trọng số ALIME dương cao nhất là 0.36401 thuộc về dataset của Yu còn giá trị âm thấp nhất ở dataset của Feng với giá trị là 0.32831.

Với các biểu đồ phân phối trong hình 4.23 này, các trọng số của 50 đặc trưng quan trọng nhất trong mỗi bộ dữ liệu đều có xu hướng phân phối lệch phải. Các trọng số tập trung mạnh ở giá trị rất nhỏ gần 0, với một số ít các đặc trưng có trọng số cao hơn. Điều này cho




Hình 4.23. Biểu đồ phân phối trọng số LIME 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC


thấy hầu hết các đặc trưng quan trọng có ảnh hưởng rất nhỏ, ngoại trừ một số đặc trưng có ảnh hưởng lớn hơn một chút. Với tập Feng có sự phân phối thấp hơn hẳn so với 3 tập còn lại, một số đặc trưng có giá trị lớn (lên đến 0.0175). Tuy nhiên đa phần vẫn tập trung gần 0.

Sau khi tiến hành biểu diễn các kết quả được thu thập như Hình 4.24 thông qua quá trình thực nghiệm trên 10 fold, kết quả trên 4 tập dataset được hiển thị, trong Hình 4.24a tập Yu cho thấy giá trị AUC nhất đạt 0.86980 giá trị AUC tăng mạnh ở các đặc trưng đầu và các đặc trưng cuối cho thấy các đặc trưng được thêm vào góp phần cải thiện hiệu suất. Tiếp theo là tập Feng được hiển thị trong Hình 4.24b với kết quả AUC cao nhất được thực nghiệm là 0.79560 với giá trị bắt đầu tăng mạnh từ 40 đặc trưng. Kế tiếp là tập Zeller có kết quả thu được cao nhất được trình bày trong Hình 4.24c với giá trị AUC là 0.91098 mặc dù ban đầu giá trị các đặc trưng giảm mạnh nhưng sau đó đã tăng dần đều cho thấy hiệu suất phân loại được cải thiện khi các đặc trưng được thêm vào liên tục. Cuối cùng tục là tập Vogtmann kết quả thực nghiệm được trình bày trong Hình 4.24d có giá trị AUC cao nhất sau quá trình thử nghiệm là 0.86650, mặc dù ban đầu giá trị giảm mạnh nhưng đến khoảng 12 đặc trưng thì giá trị đã bắt đầu tăng dần. Trong tất cả bộ dữ liệu, giá trị AUC của phương pháp ALIME đều có xu hướng tăng khi số lượng đặc trưng quan trọng tăng, nhưng độ ổn định của AUC có sự khác biệt giữa các bộ. Riêng ở tập vogtmann có dao động mạnh mẽ tuy nhiên nhìn chung các giá trị AUC vẫn tăng. Chứng minh rằng dù thêm nhiều đặc trưng nhưng các đặc trưng mới vẫn đang cung cấp thêm thông tin hữu ích cho mô hình.


Từ hình 4.25, giải thích ALIME với mô hình GBC cho thấy rằng dự đoán của ALIME hoàn toàn trùng khớp với dự đoán mô hình, điều đó chứng minh rằng ALIME đã mô phỏng một cách chính xác cách mà mô hình đưa ra quyết định cho mẫu đầu tiên của mỗi tập




(a) Yu



(b) Feng



(c) Zeller




(d) Vogtmann

Hình 4.24. Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên

dataset.

Với tập Yu, mô hình và ALIME đều dự đoán nhãn là 1 với xác suất rất cao $9.99588460e-$



Hình 4.25. Dự đoán của ALIME với bộ dataset của bệnh CRC

01. Vì sau khi dự đoán kết quả hầu hết đều ra các đặc trưng tăng khả năng gây bệnh nên dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất gây bệnh và kèm theo đó là đặc trưng cao nhất có góp phần vào nhóm không gây bệnh như sau:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu1116, Otu1455, Otu0345, Otu1779, Otu1776

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu0551

Với tập Feng, mô hình và ALIME đều dự đoán nhân là 0 với xác suất 0.98324172. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu0283, Otu1971, Otu0876

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu1142, Otu0089

Với tập Zeller, mô hình và ALIME đều dự đoán nhân là 1 với xác suất 9.99988687e-01. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:

+ Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu0493, Otu1877, Otu0029, Otu0528

+ Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu1771

Với tập Vogtmann, mô hình và ALIME đều dự đoán nhân là 1 với xác suất 0.5586602. Dưới đây là chi tiết top 5 các đặc trưng ảnh hưởng nhất:


- + Các đặc trưng tăng khả năng thuộc nhóm bệnh bao gồm: Otu1288, Otu1915, Otu1980
- + Các đặc trưng tăng khả năng thuộc nhóm không bệnh bao gồm: Otu1064, Otu0868

Tóm lại với dự đoán bằng phương pháp ALIME kết hợp với mô hình GBC đã có 2 đặc trưng xuất hiện nhiều lần gồm Otu1116, Otu1644. Otu1116 xuất hiện trong nhóm tăng khả năng thuộc nhóm bệnh với tập Yu và Votgman với trọng số lần lượt cao hơn 0.2 và dưới 0.1, nhưng với tập Zeller lại trong nhóm không gây bệnh với trọng số dưới 0.05. Đặc trưng Otu1644 ở tập Vogtmann xuất hiện ở nhóm tăng khả năng thuộc nhóm bệnh với trọng số gần bằng 0.05, tuy nhiên trong tập Zeller lại xuất hiện trong nhóm tăng khả năng thuộc nhóm không bệnh với trọng số rất thấp gần bằng 0.075.

Phân tích kết quả với 50 mẫu ngẫu nhiên

Từ hình 4.26 chúng ta có thể thấy với bộ dữ liệu của bệnh crc thì 5 đặc trưng xuất hiện với tần xuất nhiều nhưng lại nằm cùng 1 tập dữ liệu chỉ là khác nhóm gồm Otu0233, Otu0915, Otu1911, Otu1600, Otu1877, Otu0493, Otu0528, Otu1134, Otu1203, Otu0987. Điều này cho thấy chúng có vai trò linh hoạt, có thể là vi khuẩn cộng sinh bình thường nhưng trở thành tác nhân gây bệnh khi môi trường thay đổi.


Các biểu đồ boxplot trong hình 4.27 cho thấy sự phân bố độ quan trọng của các đặc trưng gây bệnh và không gây bệnh khác nhau. Với một số đặc trưng có phạm vi rộng và nhiều giá trị Outliers, cho thấy rằng có sự biến thiên lớn trong mức độ quan trọng giữa các đặc trưng. Một số đặc trưng có độ quan trọng ổn định hơn, trong khi các đặc trưng khác có sự phân bố rộng hơn, thể hiện sự biến động trong dữ liệu. Cụ thể trong tập Yu ở hình 4.27a, Otu1116 dẫn đầu về tầm quan trọng với giá trị trung bình cao nhất (khoảng 0.2) và phạm vi dao động lớn, chứng tỏ đây là đặc trưng nổi bật nhất trong việc gây bệnh. Các đặc trưng còn lại chúng có mức độ quan trọng thấp nhất trong nhóm, với giá trị trung bình gần 0 và phạm vi dao động rất hẹp. Điều này gợi ý rằng, dù liên quan đến bệnh, ảnh hưởng của chúng có thể mang tính cục bộ hoặc phụ thuộc vào các đặc trưng khác. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0233 với giá trị lớn hơn 0.001 và giá trị nhỏ nhất là gần bằng -0.0005 thuộc về đặc trưng Otu0915. Tiếp theo tập Feng ở hình 4.27b, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu1971 với giá trị thấp hơn 0.00000, thấp nhất là Otu1600 với giá trị gần bằng -0.100000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1142 với giá trị lớn hơn 0.0800 và giá trị nhỏ nhất là gần bằng 0.0200 thuộc về đặc trưng Otu1911. Tập Zeller trong hình 4.27c có độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0493 với giá trị xấp xỉ 0.30000, thấp nhất là Otu1134 với giá trị thấp hơn -0.10000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1877 với giá trị thấp hơn 0.200000 và giá trị nhỏ nhất gần bằng -0.2000 cũng thuộc về đặc trưng Otu1877. Otu1877 là một đặc trưng đặc biệt trong top 5 vì vừa có giá trị cao nhất vừa thấp nhất, cho thấy nó có thể đóng vai trò linh hoạt và phụ thuộc nhiều vào ngữ cảnh. Đặc trưng này có thể vừa mang tác động tích cực (tăng khả năng không gây bệnh ở một số mẫu) vừa tác động tiêu cực (giảm khả năng không gây bệnh ở các mẫu khác). Tuy nhiên trong khi các đặc trưng khác trong top 5 có giá trị quan trọng ổn định hơn (dao động hẹp hơn), Otu1877 lại thể hiện sự biến thiên vượt trội, làm nổi bật vai trò tiềm năng nhưng không ổn định của



Hình 4.26. Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên

nó trong nhóm không gây bệnh. Và cuối cùng tập Vogtmann ở hình 4.27d độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0917 với giá trị lớn hơn 0.10000, thấp nhất là Otu1288 với giá trị thấp hơn -0.10000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1988 với giá trị lớn hơn 0.10000 và giá trị xấp xỉ -0.15000 thuộc về đặc trưng Otu1064.

Song song đó có thể thấy một số đặc trưng thuộc cả nhóm tăng khả năng bệnh và tăng



Hình 4.27. Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên

khả năng không bệnh. Vì trong một số trường hợp, đặc trưng đó có thể có ảnh hưởng tích cực hoặc tiêu cực tùy thuộc vào các mẫu hoặc tùy thuộc vào cách giải thích của ALIME. Dù vậy thì một đặc trưng có thể xuất hiện trong cả hai nhóm, nhưng độ quan trọng của nó thì khác nhau. Có đặc trưng có thể có tác động mạnh mẽ trong nhóm gây bệnh và tác động yếu hơn trong nhóm không gây bệnh, hoặc ngược lại. Điều này dẫn đến sự xuất hiện của đặc trưng trong cả hai nhóm nhưng với phân bố độ quan trọng khác nhau. Từ Hình 4.26 và 4.27 có thể thấy tần suất xuất hiện của đặc trưng nhiều hay ít cũng không ảnh hưởng đến

mức độ quan trọng cũng như mức độ ảnh hưởng của nó đến việc dự đoán mô hình XAI. Có những đặc trưng xuất hiện rất nhiều lần với nhiều mẫu, tuy nhiên giá trị trọng số rất nên không ảnh hưởng đến kết quả. Các đặc trưng vừa có tần suất xuất hiện thường xuyên vừa có độ quan trọng cao bao gồm:

+ Các đặc trưng tăng khả năng bệnh: Otu1116, otu0994, Otu0345, Otu0915, Otu0233, Otu0283, Otu1971, Otu0302, Otu1911, Otu1600, Otu0029, Otu1877, Otu0493, Otu0528, Otu1134, Otu1288, Otu0868, Otu1203, Otu0987, Otu0917.

+ Các đặc trưng tăng khả năng không bệnh: Otu0183, Otu0280, Otu0233, Otu1136, Otu0915, Otu1142, Otu0089, Otu1600, Otu0193, Otu1911, otu0493, Otu1134, Otu1771, Otu1877, Otu0528, Otu1980, Otu1064, Otu0987, Otu1644.

Các đặc trưng thu thập được ở cả lần thực nghiệm ALIME với mẫu đầu tiên của mỗi tập dữ liệu và với 50 mẫu ngẫu nhiên chi tiết như sau:

+ Các đặc trưng gây bệnh: Otu0345, Otu0283, Otu1116, Otu1971, Otu0302, Otu0029, Otu1877, Otu0493, Otu0528, Otu1288, Otu0987.

+ Các đặc trưng không gây bệnh: Otu0233, Otu1142, Otu0089, Otu1600, Otu0193, Otu1134, Otu1771, Otu1203, Otu1064.

Tóm lại

Tóm lại với phương pháp ALIME cho cả 2 mô hình RF ở mục 4.3.2.1 và GBC 4.3.2.2, ALIME dự đoán tốt hơn khi kết hợp với mô hình GBC với dự đoán gần như tuyệt đối, còn đối với RF, ALIME cho ra kết quả dự đoán khác với mô hình ở một số tập dữ liệu. Sau khi thực nghiệm ALIME với cả mô hình RF và GBC ở 2 cách thức tiếp cận là trên mẫu đầu tiên và trên 50 mẫu ngẫu nhiên, thu thập được các đặc trưng sau đây:

+ Các đặc trưng tăng khả năng bệnh: Otu0672, Otu0917, Otu0923, Otu1784, Otu0944, Otu0309, Otu0760, Otu0406, Otu1249, Otu0664, Otu0357, Otu1915, Otu1952, Otu1324, Otu0345, Otu1971, Otu0302, Otu0029, Otu0868, Otu0283, Otu1288


+ Các đặc trưng tăng khả năng không bệnh: Otu0677, Otu0915, Otu0280, Otu1947, Otu0562, Otu0042, Otu0048, Otu1776, Otu1457, Otu0062, Otu1882, Otu0550, Otu0565, Otu1550, Otu0183, Otu1136, Otu1142, Otu0089, Otu0193, Otu1771, Otu1644, Otu1064

+ Các đặc trưng thuộc cả 2 nhóm bệnh và không bệnh: Otu1116, Otu0493, Otu0528, Otu1134, Otu1600, Otu1203, Otu0868, Otu1204, Otu0639, Otu0770, Otu0228, Otu1118, Otu0233, Otu1911, Otu0493, Otu0528, Otu1980, Otu0987, Otu1877, Otu1203

4.3.3 SHAP


4.3.3.1 Mô hình RF

Phân tích kết quả với 50 đặc trưng quan trọng của mẫu đầu tiên được lựa chọn bằng các phương pháp XAI



Hình 4.28. Biểu đồ Min-Max trọng số SHAP của 50 đặc trưng quan trọng

Trong Hình 4.28 này, các giá trị trọng số đã được sắp xếp theo thứ tự giảm dần. Tất cả các giá trị trọng số ở các tập dữ liệu đều dương, rõ ràng nhất là tập Feng và Zeller có độ dốc lớn ở những giá trị cao nhất, cho thấy phương pháp SHAP hầu như có thể xác định sự chênh lệch về tầm quan trọng của giá trị giữa các đặc trưng. Đặc biệt giá trị trọng số cao nhất là 0.01010 và giá trị thấp nhất là 0.00116 đều thuộc tập Feng.




Hình 4.29. Biểu đồ phân phối trọng số SHAP 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC

Dựa vào hình 4.29 phân bố trọng số SHAP của các đặc trưng trong bốn bộ dữ liệu (Yu,


Feng, Zeller, Vogtmann), ta có thể nhận thấy rằng phân bố trọng số SHAP trong mỗi bộ dữ liệu có sự khác biệt rõ rệt. Bộ dữ liệu Yu và Vogtmann có trọng số SHAP phân bố rộng hơn so với các bộ dữ liệu khác, với nhiều đặc trưng có trọng số cao hơn 0.0025, cho thấy sự ảnh hưởng đa dạng của các đặc trưng. Bộ dữ liệu Feng lại có trọng số SHAP chủ yếu tập trung ở mức thấp dưới 0.002, phản ánh rằng phần lớn các đặc trưng không có ảnh hưởng mạnh, với chỉ một số ít đặc trưng có trọng số cao hơn 0.004. Trong khi đó, bộ dữ liệu Zeller có sự phân bố lệch phải rõ rệt, với nhiều đặc trưng có trọng số thấp dưới 0.003 và một vài đặc trưng có trọng số đáng kể gần bằng 0.006. Nhìn chung, các bộ dữ liệu đều có sự chênh lệch về tầm quan trọng của các đặc trưng, với Yu và Vogtmann hầu như có sự phân bố rộng nhất và Feng với Zeller lại có sự tập trung vào các trọng số thấp, cho thấy sự khác biệt rõ rệt trong cấu trúc dữ liệu và mức độ ảnh hưởng của các đặc trưng.

Sau khi tiến hành biểu diễn các kết quả được thu thập như Hình 4.30 thông qua quá trình thực nghiệm trên 10 fold, kết quả trên 4 tập dataset được hiển thị, với bộ dữ liệu Yu trong hình 4.30a, giá trị AUC cao nhất đạt 0.80657, giá trị AUC tăng dần từ 1 đến khoảng 30 đặc trưng, sau đó dao động nhẹ và đạt sự ổn định. Điều này cho thấy rằng việc thêm các đặc trưng từ 1 đến 30 có tác động lớn nhất đến việc cải thiện hiệu suất phân loại. Bộ dữ liệu Feng trong hình 4.30b cho thấy giá trị AUC khá ổn định và tăng chậm hơn, phản ánh rằng các đặc trưng bổ sung sau giai đoạn đầu không cải thiện đáng kể hiệu suất, kết quả AUC cao nhất được thực nghiệm là 0.84119. Đối với Zeller, AUC tăng đáng kể từ 1 đến 15 đặc trưng và có xu hướng ổn định từ đặc trưng thứ 20 trở đi, cho thấy rằng hiệu suất phân loại chủ yếu phụ thuộc vào một nhóm đặc trưng quan trọng ở giai đoạn đầu, có kết quả thu được cao nhất được trình bày trong Hình 4.30c với giá trị AUC là 0.87183. Cuối cùng, với Vogtmann, giá trị AUC tăng dần và khá đều, cho thấy hiệu suất phân loại được cải thiện khi các đặc trưng được thêm vào liên tục, kết quả thực nghiệm được trình bày trong Hình 4.30d có giá trị AUC cao nhất sau quá trình thử nghiệm là 0.82550. Nhìn chung, so với ALIME và LIME có vẻ SHAP không thể hiện quá rõ mức độ tăng AUC khi thêm đặc trưng mới khác nhau giữa các bộ dữ liệu, cho thấy có ít sự khác biệt về tầm quan trọng và mức độ ảnh hưởng của các đặc trưng trong từng bộ dữ liệu. Các outliers tập trung nhiều ở bộ dữ liệu Yu cho thấy tính không ổn định của mô hình có thể do đặc trưng không ổn định hoặc nhiễu, trong khi các dataset còn lại có độ ổn định cao hơn.


Biểu đồ SHAP ở hình 4.31a cho thấy các đặc trưng quan trọng nhất trong dự đoán. Ở đây đề tài nhận xét top 5 đặc trưng ảnh hưởng nhất như sau với Otu0847 có ảnh hưởng lớn nhất, phân bố giá trị SHAP rộng tập trung chúng yếu ở giá trị SHAP âm cho thấy nó thuộc nhóm gây bệnh. Otu0580 hoàn toàn thuộc nhóm đặc trưng gây bệnh bởi các giá trị tập trung ở SHAP âm. Các đặc trưng thuộc nhóm không bệnh rõ rệt nhất là Otu0801, Otu1372. Riêng Otu1899, đặc trưng này không cố định thuộc nhóm bệnh hay không bệnh. Thay vào đó khi giá trị cao (đỏ) nó sẽ thuộc với nhóm không bệnh còn khi giá trị thấp (xanh) sẽ thuộc nhóm bệnh. Ở biểu đồ hình 4.31b cho thấy tỷ lệ đóng góp của các đặc trưng đã được sắp xếp từ cao đến thấp, Otu0847 có tỷ lệ đóng góp lớn nhất (khoảng 4%), tiếp theo là Otu0801 và Otu1372. Đường tỷ lệ tích lũy tăng dần, cho thấy 10 đặc trưng này chiếm 20% tổng trọng số, tập trung chủ yếu vào các đặc trưng hàng đầu.. Kết quả dự đoán của mô hình và SHAP nhất quán, khi nhân dự đoán và giá trị SHAP đều xác định nhãn là 0 với kết quả dự đoán là 0.52192727.




(a) Yu



(b) Feng




(c) Zeller




(d) Vogtmann

Hình 4.30. Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên


Biểu đồ SHAP ở hình 4.32a cho thấy các đặc trưng quan trọng nhất trong dự đoán. Ở đây đề tài nhận xét top 5 đặc trưng ảnh hưởng nhất như sau với Otu1566 có ảnh hưởng lớn




(a) SHAP value (impact on model output)



(b) Composition Ratio and Cumulative Ratio of Top SHAP Features

Hình 4.31. Biểu đồ dự đoán SHAP với bộ dữ liệu Yu.

(a) SHAP value (impact on model output)




(b) Composition Ratio and Cumulative Ratio of Top SHAP Features

Hình 4.32. Biểu đồ dự đoán SHAP với bộ dữ liệu Feng.


nhất (phân bố giá trị SHAP rộng và cân đối ở cả hai phía dương và âm), tuy giá trị cao của đặc trưng này giảm khả năng dự đoán nhãn 0 nhưng nhìn chung nó vẫn thuộc nhóm không gây bệnh với giá trị SHAP thấp. Otu0994 hoàn toàn thuộc nhóm đặc trưng không gây bệnh. Các đặc trưng thuộc nhóm gây bệnh rõ rệt nhất là Otu1501, Otu1853, Otu0307. Ở biểu đồ hình 4.32b cho thấy tỷ lệ đóng góp của các đặc trưng đã được sắp xếp từ cao đến thấp, với Otu1566 chiếm tỷ lệ cao nhất (khoảng 6%), theo sau bởi Otu0994 và Otu1501. Đường tỷ lệ tích lũy tăng dần, cho thấy 10 đặc trưng hàng đầu đóng góp hơn 20% vào tổng dự đoán. Kết quả dự đoán của mô hình và SHAP nhất quán, khi nhãn dự đoán và giá trị SHAP đều xác định nhãn là 0 với kết quả dự đoán là 0.508.

Biểu đồ SHAP ở hình 4.33a cho thấy các đặc trưng quan trọng nhất trong dự đoán của tập dữ liệu của Zeller. Ở đây đề tài nhận xét top 5 đặc trưng ảnh hưởng nhất như sau với Otu0029, Otu1247 và Otu0292 có ảnh hưởng lớn nhất nhưng thể hiện rõ rệt việc thuộc nhóm không gây bệnh với giá trị SHAP có cả cao lẫn thấp. Otu1211 tuy có giá trị cao ở SHAP âm nhưng vẫn thuộc nhóm đặc trưng gây bệnh với giá trị thấp. Otu1586 hoàn toàn thuộc nhóm gây bệnh. Ở biểu đồ hình 4.33b cho thấy tỷ lệ đóng góp của các đặc trưng đã được sắp xếp từ cao đến thấp, với Otu0029 chiếm tỷ lệ cao nhất (khoảng 4%), theo sau bởi Otu0994 và Otu1501. Đường tỷ lệ tích lũy tăng dần, cho thấy 10 đặc trưng hàng đầu đóng góp hơn 20%



Hình 4.33. Biểu đồ dự đoán SHAP với bộ dữ liệu Zeller.

vào tổng dự đoán. Kết quả dự đoán của mô hình và SHAP nhất quán, khi nhận dự đoán và giá trị SHAP đều xác định nhãn là 1 với kết quả dự đoán là 0.59196721.




Hình 4.34. Biểu đồ dự đoán SHAP với bộ dữ liệu Vogtmann.


Biểu đồ SHAP ở hình 4.34a của tập dữ liệu Vogtmann cho thấy các đặc trưng quan trọng nhất trong dự đoán. Ở đây đề tài nhận xét top 5 đặc trưng ảnh hưởng nhất như sau các đặc trưng thuộc nhóm không gây bệnh được phân bố một cách rõ ràng bao gồm Otu1749, Otu1547, Otu1584, Otu0982. Đặc trưng Otu1816 thuộc nhóm gây bệnh khi các giá trị thấp lẫn cao đều tập trung ở SHAP âm. Ở biểu đồ hình 4.34b cho thấy tỷ lệ đóng góp của các đặc trưng đã được sắp xếp từ cao đến thấp, với Otu1749 chiếm tỷ lệ cao nhất (khoảng 4%), theo sau bởi Otu1547 và Otu1584. Đường tỷ lệ tích lũy tăng dần, cho thấy 10 đặc trưng hàng đầu đóng góp hơn 20% vào tổng dự đoán. Kết quả dự đoán của mô hình và SHAP nhất quán, khi nhận dự đoán và giá trị SHAP đều xác định nhãn là 0 với kết quả dự đoán là 0.732.

Tóm lại từ các hình 4.31, 4.32, 4.33 và 4.34 với dự đoán bằng phương pháp SHAP kết hợp với mô hình RF đã có duy nhất 1 đặc trưng xuất hiện nhiều là Otu1547. Otu1547 xuất hiện trong nhóm không gây bệnh ở tập Feng và Vogtmann với giá trị thấp, được thể hiện qua màu xanh dương chiếm ưu thế. Tuy nhiên nó đều nằm ở top đầu những đặc trưng không gây bệnh.


Phân tích kết quả với 50 mẫu ngẫu nhiên




(a) Yu



(b) Feng



(c) Zeller



(d) Vogtmann

Hình 4.35. Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên


Từ hình 4.35 chúng ta có thể thấy với bộ dữ liệu của bệnh CRC thì không có bất kỳ đặc trưng nào nằm ở top đầu các đặc trưng có tần suất xuất hiện nhiều nhất ở cả 4 tập dataset. Mặc dù các đặc trưng đều có tần suất xuất hiện rất cao, với các đặc trưng ở top 5 đặc trưng xuất hiện nhiều nhất ở nhóm bệnh và không bệnh đều có tần suất trong khoảng 40 đến 50 lần khi thực nghiệm với 50 mẫu ngẫu nhiên. Điều đó cho thấy các đặc trưng quan trọng được lựa chọn bởi phương pháp SHAP kết hợp với mô hình RF có tính đặc thù cao đối với từng bộ dữ liệu.

Các biểu đồ boxplot trong hình 4.36 cho thấy sự phân bố độ quan trọng của các đặc trưng gây bệnh và không gây bệnh khác nhau. Với một số đặc trưng có phạm vi rộng và nhiều giá trị Outliers, cho thấy rằng có sự biến thiên lớn trong mức độ quan trọng giữa các đặc trưng. Một số đặc trưng có độ quan trọng ổn định hơn, trong khi các đặc trưng khác có sự phân bố rộng hơn, thể hiện sự biến động trong dữ liệu. Cụ thể trong tập Yu ở hình 4.36a, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0580 với giá trị lớn hơn 0.025, thấp nhất là Otu1678 với giá trị gần bằng 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1131 với giá trị gần bằng 0.00000 và giá trị nhỏ nhất là thấp hơn -0.04 thuộc về đặc trưng Otu1372. Tiếp theo tập Feng ở hình 4.36b, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0918 với giá trị lớn hơn 0.025, thấp nhất là Otu1616 với giá trị dưới 0.005. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1987 với giá trị gần bằng 0.0000 và giá trị nhỏ nhất thấp hơn -0.030 thuộc về đặc trưng Otu0994. Tập Zeller trong hình 4.36c có độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu1586 với giá trị lớn hơn 0.0300, thấp nhất là Otu0471 với giá trị cao hơn 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1180 với giá trị xấp xỉ 0.00000 và giá trị nhỏ nhất dưới -0.0400 thuộc về đặc trưng Otu0029. Và cuối cùng tập Votgmann ở hình 4.36d độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0813 với giá trị gần bằng 0.015, thấp nhất là Otu0786 với giá trị gần bằng 0.00000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1374 với giá trị lớn hơn -0.0050 và giá trị nhỏ nhất thấp hơn -0.0200 thuộc về đặc trưng Otu1218.

Từ Hình 4.35 và 4.36 có thể thấy tần suất xuất hiện của đặc trưng nhiều hay ít cũng không ảnh hưởng đến mức độ quan trọng cũng như mức độ ảnh hưởng của nó đến việc dự đoán mô hình XAI. Tuy nhiên với phương pháp SHAP, top 5 tất cả các đặc trưng thuộc cả nhóm có bệnh và không bệnh khi xuất hiện với tần suất nhiều thì cũng tương ứng với độ quan trọng cao. Các đặc trưng thu thập được ở cả lần thực nghiệm SHAP với mẫu đầu tiên của mỗi tập dữ liệu và với 50 mẫu ngẫu nhiên chi tiết như sau:

+ Các đặc trưng gây bệnh: Otu0580, Otu1501, Otu1853, Otu0918, Otu0028, Otu1586, Otu0399.


+ Các đặc trưng không gây bệnh: Otu1547, Otu1372, Otu0994, Otu0029, Otu0292, Otu1218.



Hình 4.36. Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên

4.3.3.2 Mô hình GBC

Phân tích kết quả với 50 đặc trưng quan trọng của mẫu đầu tiên được lựa chọn bằng các phương pháp XAI




Hình 4.37. Biểu đồ Min-Max trọng số SHAP của 50 đặc trưng quan trọng

Trong Hình 4.37 này, các giá trị trọng số đã được sắp xếp theo thứ tự giảm dần. Tất cả các giá trị trọng số ở các tập dữ liệu đều dương, rõ ràng nhất là hầu hết ở các đặc trưng ban đầu, cả 4 tập dữ liệu đều có trọng số SHAP khác biệt thể hiện ở độ dốc lớn ở những giá trị cao nhất, cho thấy phương pháp SHAP hầu như có thể xác định sự chênh lệch về tầm quan trọng của giá trị giữa các đặc trưng. Đặc biệt giá trị trọng số cao nhất là 0.44751 và giá trị thấp nhất là 0.00046 đều thuộc tập Vogtmann.

Với các biểu đồ phân phối trong hình 4.38 này, các trọng số của 50 đặc trưng quan trọng nhất trong mỗi bộ dữ liệu đều có xu hướng phân phối lệch phải. Các trọng số tập trung mạnh ở giá trị rất nhỏ, với tập Yu và Zeller, hầu như các giá trị tập trung ở gần 0.01, còn tập Feng lại tập trung nhiều hơn ở giá trị 0.02 còn Vogman hầu như tập trung ở gần 0, với một số ít các đặc trưng có trọng số cao hơn. Điều này cho thấy hầu hết các đặc trưng quan trọng có ảnh hưởng rất nhỏ, ngoại trừ một số đặc trưng có ảnh hưởng lớn hơn một chút. Trong đó Zeller là tập dữ liệu có phân phối trọng số rộng hơn so với 3 bộ còn lại, còn Feng thì lại có giá trị trọng số phân bố cao nhất (lên đến 0.1).

Sau khi tiến hành biểu diễn các kết quả được thu thập như Hình 4.39 thông qua quá trình thực nghiệm trên 10 fold, kết quả trên 4 tập dataset được hiển thị, trong Hình 4.39a tập Yu cho thấy giá trị AUC tăng mạnh từ đặc trưng 1 đến khoảng đặc trưng thứ 10, sau đó có xu hướng ổn định, giá trị AUC nhất đạt 0.86496. Tiếp theo là tập Feng được hiển thị trong Hình 4.39b AUC tăng nhanh ở các đặc trưng đầu tiên (1-5 đặc trưng), nhưng đạt




Hình 4.38. Biểu đồ phân phối trọng số SHAP 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC


trạng thái ổn định từ đặc trưng thứ 15 trở đi, với kết quả AUC cao nhất được thực nghiệm là 0.80929. Kế tiếp là tập Zeller, biểu đồ có xu hướng ổn định sớm hơn so với các bộ khác, khoảng từ 10 đặc trưng đã thấy mức AUC cao, có kết quả thu được cao nhất được trình bày trong Hình 4.39c với giá trị AUC là 0.86276, tiếp tục là tập Vogtmann AUC tăng chậm hơn so với các bộ khác, nhưng đạt giá trị ổn định khi có khoảng 15-20 đặc trưng, kết quả thực nghiệm được trình bày trong Hình 4.39d có giá trị AUC cao nhất sau quá trình thử nghiệm là 0.84758. Trong tất cả bộ dữ liệu, giá trị AUC của phương pháp SHAP đều có xu hướng tăng mạnh khi thêm các đặc trưng đầu tiên (khoảng 1-20 đặc trưng), nhưng sau đó đạt trạng thái ổn định và không cải thiện đáng kể khi thêm nhiều đặc trưng hơn; đặc trưng đầu tiên có ảnh hưởng lớn đến hiệu năng, trong khi các đặc trưng bổ sung về sau có mức đóng góp giảm dần.

Biểu đồ SHAP ở hình 4.40a của tập dữ liệu Yu cho thấy các đặc trưng quan trọng nhất trong dự đoán. Ở đây có thể thấy rõ top 5 đặc trưng ảnh hưởng nhất đều thuộc nhóm gây bệnh bao gồm Otu1902, Otu1740, Otu0303, Otu0998, Otu0816 vì tất cả giá trị đều tập trung ở SHAP âm. Đến tận top 6 và 7 mới có đặc trưng thuộc nhóm không bệnh là Otu0879 và Otu0169. Dù ở những top đầu đặc trưng không thuộc nhóm không bệnh nhưng vẫn không ảnh hưởng đến dự đoán của mô hình. Ở biểu đồ hình 4.40b cho thấy tỷ lệ đóng góp chiếm tỷ lệ cao nhất (khoảng 4%) thuộc đặc trưng Otu1902, theo sau bởi Otu1704 và Otu0998. Đường tỷ lệ tích lũy tăng dần, cho thấy 10 đặc trưng hàng đầu đóng góp hơn 16% vào tổng dự đoán. Kết quả dự đoán của mô hình và SHAP nhất quán, khi nhân dự đoán và giá trị SHAP đều xác định nhãn là 0 với kết quả dự đoán là 9.99999056e-01.


Biểu đồ SHAP ở hình 4.41a của tập dữ liệu Feng cho thấy các đặc trưng quan trọng nhất trong dự đoán. Ở đây đề tài nhận xét top 5 đặc trưng ảnh hưởng nhất như sau các đặc trưng thuộc nhóm không gây bệnh được phân bố một cách rõ ràng bao gồm Otu1289, Otu0205, Otu1586. Đặc trưng Otu0276 thuộc nhóm gây bệnh khi các giá trị thấp tập trung nhiều ở




(a) Yu



(b) Feng




(c) Zeller




(d) Vogtmann

Hình 4.39. Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên


SHAP âm trong khi chỉ có vài giá trị cao nằm ở SHAP dương. Với đặc trưng Otu0186 đều thuộc cả 2 nhóm khi giá trị cao sẽ thuộc nhóm gây bệnh và giá trị thấp sẽ thuộc nhóm




(a) SHAP value (impact on model output)



(b) Composition Ratio and Cumulative Ratio of Top SHAP Features

Hình 4.40. Biểu đồ dự đoán SHAP với bộ dữ liệu Yu.


(a) SHAP value (impact on model output)




(b) Composition Ratio and Cumulative Ratio of Top SHAP Features

Hình 4.41. Biểu đồ dự đoán SHAP với bộ dữ liệu Feng.

không bệnh. Ở biểu đồ hình 4.41b cho thấy tỷ lệ đóng góp của các đặc trưng đã được sắp xếp từ cao đến thấp, với Otu1289 chiếm tỷ lệ cao nhất (khoảng 4%), theo sau bởi Otu0205 và Otu0276. Đường tỷ lệ tích lũy tăng dần, cho thấy 10 đặc trưng hàng đầu đóng góp hơn 17.5% vào tổng dự đoán. Kết quả dự đoán của mô hình và SHAP nhất quán, khi nhân dự đoán và giá trị SHAP đều xác định nhãn là 0 với kết quả dự đoán là 9.99716681e-01.




(a) SHAP value (impact on model output)



(b) Composition Ratio and Cumulative Ratio of Top SHAP Features

Hình 4.42. Biểu đồ dự đoán SHAP với bộ dữ liệu Zeller.

Biểu đồ SHAP ở hình 4.42a của tập dữ liệu Zeller cho thấy các đặc trưng quan trọng nhất trong dự đoán. Ở đây đề tài nhận xét top 5 đặc trưng ảnh hưởng nhất như sau các đặc trưng thuộc nhóm không gây bệnh được phân bố một cách rõ ràng là Otu1183, thuộc nhóm gây bệnh là Otu0267. Riêng 3 đặc trưng Otu1041, Otu0703, Otu0721 đều thuộc cả 2 nhóm gây bệnh và không bệnh vì giá trị của nó phân bố đều ở cả SHAP âm lẫn SHAP dương. Ở biểu đồ hình 4.42b cho thấy tỷ lệ đóng góp của các đặc trưng đã được sắp xếp từ cao đến thấp, với Otu1041 chiếm tỷ lệ cao nhất (hơn 4%), theo sau bởi Otu0703 và Otu0267. Đường tỷ lệ tích lũy tăng dần, cho thấy 10 đặc trưng hàng đầu đóng góp hơn 16% vào tổng dự đoán. Kết quả dự đoán của mô hình và SHAP nhất quán, khi nhãn dự đoán và giá trị SHAP đều xác định nhãn là 1 với kết quả dự đoán là 9.99998538e-01.




Hình 4.43. Biểu đồ dự đoán SHAP với bộ dữ liệu Vogtmann.

Biểu đồ SHAP ở hình 4.43a của tập dữ liệu Vogtmann cho thấy các đặc trưng quan trọng nhất trong dự đoán. Ở đây đề tài nhận xét top 5 đặc trưng ảnh hưởng nhất như sau các đặc trưng thuộc nhóm không gây bệnh được phân bố một cách rõ ràng là Otu1800, còn các đặc trưng gây bệnh bao gồm Otu0768, Otu1984, Otu1224. Riêng đặc trưng Otu1759 nằm cả 2 nhóm gây bệnh và không bệnh vì các giá trị thấp rải đều cho SHAP âm và SHAP dương. Ở biểu đồ hình 4.43b cho thấy tỷ lệ đóng góp của các đặc trưng đã được sắp xếp từ cao đến thấp, với Otu0768 chiếm tỷ lệ cao nhất (khoảng 4%), theo sau bởi Otu1984 và Otu1800. Đường tỷ lệ tích lũy tăng dần, cho thấy 10 đặc trưng hàng đầu đóng góp gần 20% vào tổng dự đoán. Kết quả dự đoán của mô hình và SHAP nhất quán, khi nhãn dự đoán và giá trị SHAP đều xác định nhãn là 1 với kết quả dự đoán là 0.94759107.

Tóm lại từ hình 4.40, 4.41, 4.42 và 4.43 với dự đoán bằng phương pháp SHAP kết hợp với mô hình GBC không có đặc trưng nào xuất hiện nhiều lần. Tất cả đặc trưng trong 4 tập đều chỉ xuất hiện 1 lần duy nhất. Điều này có thể do cơ chế hoạt động của GBC, GBC xây dựng các cây tuần tự, mỗi cây tối ưu hóa dựa trên lỗi còn lại của các cây trước đó. Vì vậy, GBC có xu hướng sử dụng nhiều đặc trưng khác nhau trong mỗi cây, dẫn đến các đặc trưng quan trọng phân tán hơn.

Phân tích kết quả với 50 mẫu ngẫu nhiên


Từ hình 4.44 chúng ta có thể thấy với bộ dữ liệu của bệnh CRC thì không có bất kỳ đặc trưng nào nằm ở top đầu các đặc trưng có tần suất xuất hiện nhiều nhất ở cả 4 tập dataset. Mặc dù các đặc trưng đều có tần suất xuất hiện rất cao, với các đặc trưng ở top 5 đặc trưng




Hình 4.44. Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên

xuất hiện nhiều nhất ở nhóm bệnh và không bệnh đều có tần xuất trong khoảng 45 đến 50 lần khi thực nghiệm với 50 mẫu ngẫu nhiên. Điều đó cho thấy các đặc trưng quan trọng


được lựa chọn bởi phương pháp SHAP kết hợp với mô hình GBC có tính đặc thù cao đối với từng bộ dữ liệu.




(a) Yu



(b) Feng



(c) Zeller



(d) Vogtmann

Hình 4.45. Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên

Các biểu đồ boxplot trong hình 4.45 cho thấy sự phân bố độ quan trọng của các đặc trưng gây bệnh và không gây bệnh khác nhau. Với một số đặc trưng có phạm vi rộng và nhiều giá trị Outliers, cho thấy rằng có sự biến thiên lớn trong mức độ quan trọng giữa các đặc trưng. Một số đặc trưng có độ quan trọng ổn định hơn, trong khi các đặc trưng khác có sự phân bố rộng hơn, thể hiện sự biến động trong dữ liệu. Cụ thể trong tập Yu ở hình 4.45a, độ quan trọng cao và thấp nhất của nhóm các đặc trưng gây bệnh là của Otu0879 với giá trị cao lớn hơn 2.00000 và giá trị thấp là dưới 0.0000. Otu0879 là một đặc trưng đặc biệt trong top 5 vì vừa có giá trị cao nhất vừa thấp nhất, cho thấy nó có thể đóng vai trò linh hoạt và phụ thuộc nhiều vào ngữ cảnh. Đặc trưng này có thể vừa mang tác động tích cực (tăng khả năng không gây bệnh ở một số mẫu) vừa tác động tiêu cực (giảm khả năng không gây bệnh ở các mẫu khác). Tuy nhiên trong khi các đặc trưng khác trong top 5 có giá trị quan trọng ổn định hơn (dao động hẹp hơn), Otu0879 lại thể hiện sự biến thiên vượt trội, làm nổi bật vai trò tiềm năng nhưng không ổn định của nó trong nhóm gây bệnh. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1707 với giá trị gần bằng 0.00000 và giá trị nhỏ nhất là thấp hơn -6 thuộc về đặc trưng Otu1902. Tiếp theo tập Feng ở hình 4.45b, độ quan trọng cao và thấp nhất đều là của đặc trưng Otu1289 với giá trị lớn hơn 7 và giá trị thấp dưới -1. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0925 với giá trị gần bằng 0.0000 và giá trị nhỏ nhất thấp hơn -1.5 thuộc về đặc trưng Otu1853. Tập Zeller trong hình 4.45c có độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0267 với giá trị lớn hơn 3.5, thấp nhất là Otu0782 với giá trị cao hơn 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1967 với giá trị xấp xỉ 0.00000 và giá trị nhỏ nhất dưới -1.5 thuộc về đặc trưng Otu0827. Và cuối cùng tập Votgmann ở hình 4.45d độ quan trọng cao và thấp nhất của nhóm các đặc trưng gây bệnh là của Otu1982 với giá trị cao hơn 1.5, giá trị thấp khoảng dưới -0.25 cho thấy Otu1982 là một đặc trưng đặc biệt trong top 5 vì vừa có giá trị cao nhất vừa thấp nhất, cho thấy nó có thể đóng vai trò linh hoạt và phụ thuộc nhiều vào ngữ cảnh. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0407 với giá trị gần bằng 0.00000 và giá trị nhỏ nhất thấp hơn -2 thuộc về đặc trưng Otu1800.

Từ Hình 4.44 và 4.45 có thể thấy tần suất xuất hiện của đặc trưng nhiều hay ít cũng không ảnh hưởng đến mức độ quan trọng cũng như mức độ ảnh hưởng của nó đến việc dự đoán mô hình XAI. Tuy nhiên với phương pháp SHAP, top 5 tất cả các đặc trưng thuộc cả nhóm có bệnh và không bệnh khi xuất hiện với tần suất nhiều đều tương ứng với độ quan trọng cao. Các đặc trưng thu thập được ở cả lần thực nghiệm SHAP với mẫu đầu tiên của mỗi tập dữ liệu và với 50 mẫu ngẫu nhiên chi tiết như sau:

+ Các đặc trưng gây bệnh: Otu0267.

+ Các đặc trưng không gây bệnh: Otu0302, Otu0827, Otu1568, Otu1800, Otu1455.

Tóm lại Tóm lại với phương pháp SHAP cho cả 2 mô hình RF và GBC, SHAP dự đoán tốt hơn khi kết hợp với mô hình GBC với dự đoán gần như tuyệt đối. Tuy nhiên so với 2 phương pháp trước đó là LIME và ALIME thì có vẻ SHAP khi kết hợp với 2 mô hình này đã trở nên nhạy hơn vì thế mà các đặc trưng quan trọng với nhóm gây bệnh và nhóm không bệnh đã được tìm thấy nhiều hơn. Sau khi thực nghiệm SHAP với cả mô hình RF và GBC

ở 2 cách thức tiếp cận là trên mẫu đầu tiên và trên 50 mẫu ngẫu nhiên, thu thập được các đặc trưng sau đây:

+ Các đặc trưng thuộc nhóm tăng khả năng bệnh: Otu0267, Otu0580, Otu1501, Otu1853, Otu0918, Otu0028, Otu1586, Otu0399


+ Các đặc trưng thuộc nhóm tăng khả năng không bệnh: Otu0302, Otu1547, Otu0827, Otu1568, Otu1800, Otu1455, Otu1372, Otu0994, Otu0029, Otu0292, Otu1218.

+ Các đặc trưng thuộc cả 2 nhóm bệnh và không bệnh: Otu1902, Otu0998, Otu0816, Otu0879, Otu1289, Otu1853, Otu0969.

4.3.4 DiCE


4.3.4.1 Mô hình RF

Phân tích kết quả với 50 đặc trưng quan trọng của mẫu đầu tiên được lựa chọn bằng các phương pháp XAI



Hình 4.46. Biểu đồ Min-Max trọng số DiCE của 50 đặc trưng quan trọng


Trong Hình 4.46 này, có thể thấy rõ các giá trị trọng số DiCE đều bằng 1.0 ở cả 4 tập dữ liệu. Do RF là một tập hợp của nhiều cây quyết định độc lập thể nên một số đặc trưng quan trọng có thể được sử dụng lặp đi lặp lại trong nhiều cây. Điều này làm cho các đặc trưng quan trọng nhất xuất hiện rất nhiều và ảnh hưởng mạnh đến kết quả tổng hợp của RF. Khi RF chọn ra 50 đặc trưng quan trọng nhất, những đặc trưng thực sự nổi bật thường được gán trọng số DiCE = 1.0, phản ánh mức độ ảnh hưởng ổn định của chúng trong mô hình. Đặc trưng ít quan trọng hơn có thể không được chọn.



Hình 4.47. Biểu đồ phân phối trọng số DiCE 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC


Với các biểu đồ phân phối trong hình 4.47 này, các trọng số của 50 đặc trưng quan trọng nhất trong mỗi bộ dữ liệu đều có xu hướng phân phối lệch phải. Các trọng số tập trung mạnh ở giá trị rất nhỏ gần 0, với một số ít các đặc trưng có trọng số cao hơn. Điều này cho thấy hầu hết các đặc trưng quan trọng có ảnh hưởng rất nhỏ, ngoại trừ một số đặc trưng có ảnh hưởng lớn hơn một chút. Tập dữ liệu Vogtmann có phân phối trọng số rộng hơn so với 3 bộ còn lại, còn tập Yu lại là tập có sự phân phối với giá trị trọng số cao nhất (lên đến 0.12). Tuy nhiên đa phần vẫn tập trung gần 0.

Sau khi tiến hành biểu diễn các kết quả được thu thập như Hình 4.48 thông qua quá trình thực nghiệm trên 10 fold, kết quả trên 4 tập dataset được hiển thị, trong Hình 4.48a tập Yu cho thấy giá trị AUC tăng mạnh từ đặc trưng 1 đến khoảng đặc trưng thứ 3, sau đó có xu hướng ổn định, giá trị AUC nhất đạt 0.52508. Tiếp theo là tập Feng được hiển thị trong Hình 4.48b AUC giảm đột ngột ở đặc trưng thứ 2 nhưng sau đó tăng chậm ở các đặc trưng tiếp theo, đến khoảng đặc 40 đặc trưng thì mới có xu hướng tăng nhanh, với kết quả AUC cao nhất được thực nghiệm là 0.77589. Kế tiếp là tập Zeller, biểu đồ có xu hướng tăng giảm lúc đầu, nhưng khoảng từ 30 đặc trưng đã thấy mức AUC cao và tăng liên tục, có kết quả thu được cao nhất được trình bày trong Hình 4.48c với giá trị AUC là 0.72540. Tiếp tục là tập Vogtmann AUC có xu hướng tăng đến khoảng từ 10 đặc trưng sau đó có dấu hiệu ổn định, kết quả thực nghiệm được trình bày trong Hình 4.48d có giá trị AUC cao nhất sau quá trình thử nghiệm là 0.68600. Trong hầu hết các bộ dữ liệu, giá trị AUC của phương pháp DiCE đều có xu hướng tăng nhẹ ở phần đầu nhưng sau đó đạt trạng thái ổn định và không cải thiện đáng kể khi thêm nhiều đặc trưng hơn; đặc trưng đầu tiên có ảnh hưởng lớn đến hiệu năng, trong khi các đặc trưng bổ sung về sau có mức đóng góp giảm dần.




Hình 4.48. Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên

Kết quả dự đoán của mô hình và DiCE nhất quán, khi nhân dự đoán và giá trị DiCE đều xác định nhân là 0 với kết quả dự đoán là 0.81406965. Đồng thời dự đoán 5 phản chứng với




(a) Difference of original sample with counterfactual




(b) Features that influence prediction

Hình 4.49. Biểu đồ dự đoán DiCE với bộ dữ liệu Yu.

các nhãn lần lượt là 1, 1, 1, 1, và 1. Kết quả cho thấy dự đoán của mô hình và tất cả các phản chứng đều không trùng nhau. Từ hình 4.49a có thể thấy sự chênh lệch giữa mẫu ban đầu với các phản chứng cho từng mẫu, trong đó Otu0005 là đặc trưng có sự chênh lệch nhiều nhất với các phản chứng được tạo ra. Sự khác biệt này cho thấy chúng đóng vai trò quan trọng trong việc xác định nhãn của mẫu nên đã thay đổi các đặc trưng quan trọng để làm thay đổi nhãn. Đây là minh chứng rằng các đặc trưng này thực sự có ý nghĩa quyết định trong dự đoán của mô hình. Trong hình 4.49b đã thể hiện top 10 đặc trưng có giá trị ảnh hưởng cao, trong đó Otu0005 là đặc trưng ảnh hưởng cao nhất, với giá trị trung bình khoảng 0.0016. Các đặc trưng khác như Otu0055 và Otu0032 cũng đóng góp tương đối lớn với giá trị lần lượt là 0.0015 và 0.0014 và giảm dần cho các đặc trưng tiếp theo.




(a) Difference of original sample with counterfactual




(b) Features that influence prediction

Hình 4.50. Biểu đồ dự đoán DiCE với bộ dữ liệu Feng.

Kết quả dự đoán của mô hình và DiCE nhất quán, khi nhãn dự đoán và giá trị DiCE đều xác định nhãn là 1 với kết quả dự đoán là 0.726. Đồng thời dự đoán 5 phản chứng với các nhãn lần lượt là 1, 0, 1, 1, và 0. Kết quả cho thấy dự đoán của mô hình trùng với phản chứng 1,3 và 4. Từ hình 4.50a có thể thấy sự chênh lệch giữa mẫu ban đầu với các phản chứng cho từng mẫu, trong đó Otu0185 là đặc trưng có sự chênh lệch nhiều nhất so với các phản chứng được tạo ra. Sự khác biệt này cho thấy chúng đóng vai trò quan trọng trong việc xác định nhãn của mẫu. Đây cũng là minh chứng rằng các đặc trưng này thực sự có ý nghĩa quyết định trong dự đoán của mô hình. Trong hình 4.50b đã thể hiện top 10 đặc trưng có giá trị ảnh hưởng cao, trong đó Otu0185 là đặc trưng ảnh hưởng cao nhất, với giá trị trung bình thấp hơn 0.0016. Các đặc trưng khác như Otu0170 và Otu0176 cũng đóng góp tương đối lớn với giá trị lần lượt là khoảng 0.0014 và 0.0013 và giảm dần cho các đặc trưng tiếp theo.




(a) Difference of original sample with counterfactual




(b) Features that influence prediction

Hình 4.51. Biểu đồ dự đoán DiCE với bộ dữ liệu Zeller.

Kết quả dự đoán của mô hình và DiCE nhất quán, khi nhãn dự đoán và giá trị DiCE đều xác định nhãn là 1 với kết quả dự đoán là 0.904. Đồng thời dự đoán 5 phản chứng với các nhãn lần lượt là 0, 1, 0, 0, và 1. Kết quả cho thấy dự đoán của mô hình và phản chứng 2,5 trùng nhau. Từ hình 4.51a có thể thấy sự chênh lệch giữa mẫu ban đầu với các phản chứng cho từng mẫu, trong đó Otu0770 là đặc trưng có sự chênh lệch nhiều nhất với các phản chứng được tạo ra. Sự khác biệt này cho thấy chúng đóng vai trò quan trọng trong việc xác định nhãn của mẫu nên đã thay đổi các đặc trưng quan trọng để làm thay đổi nhãn. Đây là minh chứng rằng các đặc trưng này thực sự có ý nghĩa quyết định trong dự đoán của mô hình. Trong hình 4.51b đã thể hiện top 10 đặc trưng có giá trị ảnh hưởng cao, trong đó Otu0770 là đặc trưng ảnh hưởng cao nhất, với giá trị trung bình khoảng 0.0016. Các đặc trưng khác như Otu0784 và Otu0403 cũng đóng góp tương đối lớn với giá trị lần lượt là xấp xỉ 0.0012 và giảm dần cho các đặc trưng tiếp theo.



(a) Difference of original sample with counterfactual



(b) Features that influence prediction

Hình 4.52. Biểu đồ dự đoán DiCE với bộ dữ liệu Vogtmann.

Kết quả dự đoán của mô hình và DiCE nhất quán, khi nhãn dự đoán và giá trị DiCE đều xác định nhãn là 0 với kết quả dự đoán là 0.80842308. Đồng thời dự đoán 5 phản chứng với các nhãn lần lượt là 1, 1, 1, 0, và 1. Kết quả cho thấy dự đoán của mô hình và phản chứng 4 trùng nhau. Từ hình 4.52a có thể thấy sự chênh lệch giữa mẫu ban đầu với các phản chứng cho từng mẫu, trong đó Otu0492 là đặc trưng có sự chênh lệch nhiều nhất với các phản chứng được tạo ra. Sự khác biệt này cho thấy chúng đóng vai trò quan trọng trong việc xác định nhãn của mẫu nên đã thay đổi các đặc trưng quan trọng để làm thay đổi nhãn. Đây là minh chứng rằng các đặc trưng này thực sự có ý nghĩa quyết định trong dự đoán của mô hình. Trong hình 4.52b đã thể hiện top 10 đặc trưng có giá trị ảnh hưởng cao, trong đó Otu0492 là đặc trưng ảnh hưởng cao nhất, với giá trị trung bình khoảng 0.00175. Các đặc


trưng khác như Otu0821 và Otu0238 cũng đóng góp tương đối lớn với giá trị lần lượt là trên và dưới 0.00150 và giảm dần cho các đặc trưng tiếp theo.

Tóm lại từ hình 4.49, 4.50, 4.51 và 4.52 với dự đoán bằng phương pháp DiCE kết hợp với mô hình RF đã có duy nhất 1 đặc trưng xuất hiện nhiều là Otu0253 ở tập Zeller và Vogtmann với giá trị xấp xỉ 0.001. Ở đây DiCE không phân loại trực tiếp đặc trưng thuộc bệnh hay không bệnh, thay vào đó DiCE chỉ chỉ ra những thay đổi trong giá trị đặc trưng dẫn đến thay đổi nhãn dự đoán. Các đặc trưng trong tập Yu và Vogtmann ở hình... có thể nằm trong nhóm gây bệnh vì nó nằm trong top 10 các đặc trưng có thể thay đổi nhãn dự đoán 0. Các đặc trưng trong tập Feng và Zeller ở hình... có thể nằm trong nhóm không gây bệnh vì nó nằm trong top 10 các đặc trưng có thể thay đổi nhãn dự đoán 1.

Phân tích kết quả với 50 mẫu ngẫu nhiên


Từ hình 4.53 chúng ta có thể thấy với bộ dữ liệu của bệnh CRC thì có 1 đặc trưng có tần suất xuất hiện nhiều nhất các tập dataset khác nhau là Otu0302. Còn các đặc trưng Otu0361, Otu0169, Otu0236, Otu0468, Otu0800, Otu0383, Otu0779 xuất hiện nhiều lần trong cùng 1 tập dữ liệu chỉ là khác nhóm bệnh và không bệnh. Cụ thể đặc trưng Out0302 trong tập Feng ở nhóm không bệnh tuy nhiên lại xuất hiện ở cả 2 nhóm bệnh và không bệnh của tập Vogtmann.

Các biểu đồ boxplot trong hình 4.54 cho thấy sự phân bố độ quan trọng của các đặc trưng gây bệnh và không gây bệnh khác nhau. Với một số đặc trưng có phạm vi rộng và nhiều giá trị Outliers, cho thấy rằng có sự biến thiên lớn trong mức độ quan trọng giữa các đặc trưng. Một số đặc trưng có độ quan trọng ổn định hơn, trong khi các đặc trưng khác có sự phân bố rộng hơn, thể hiện sự biến động trong dữ liệu. Cụ thể trong tập Yu ở hình 4.54a, độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0453, Out361 với giá trị cao gần 0.1 tuy nhiên Otu0361 lại có độ phân tán cực thấp và giá trị thấp gần bằng 0.0000. Còn với nhóm các đặc trưng không gây bệnh, Otu0049, Otu0236, và Otu0169 đều có độ quan trọng trung bình cao gần 0.1 tuy nhiên phân phối dữ liệu không đều, so với đó Otu0302 tuy có độ quan trọng trung bình thấp hơn nhưng lại có phân tán dữ liệu đều hơn. Tiếp theo tập Feng ở hình 4.54b, độ quan trọng cao thuộc về đặc trưng Otu0029 với giá trị gần bằng 0.25 và độ quan trọng thấp nhất là của các đặc trưng Otu0162, Otu0087, Otu0134 với độ quan trọng trung bình thấp xấp xỉ 0.00000. Còn với nhóm các đặc trưng không gây bệnh, độ quan trọng giá trị lớn nhất là Otu0302 hơn 0.06 và thấp nhất của độ quan trọng là của Otu0218 và Otu0180 với giá trị thấp gần bằng 0.0000 biểu thị vai trò không đáng kể trong phân loại các trường hợp không bệnh. Vì thế trong Feng đặc trưng Otu0302 có phân tán lớn, trong khi các đặc trưng khác có phân tán thấp, hầu hết nằm trong phạm vi hẹp gần giá trị trung bình. Tập Zeller trong hình 4.54c các đặc trưng như Otu0761, Otu0468, Otu0800, và Otu0428 có độ quan trọng rất đồng nhất cao gần 0.1, hầu như không có sự phân tán (không xuất hiện râu trên hoặc râu dưới), ngoại trừ Otu0383. Còn với nhóm các đặc trưng không gây bệnh, các đặc trưng như OTU0008, OTU0026, OTU0469, và OTU0400 có giá trị độ quan trọng phân tán khá đồng đều, với râu trên và râu dưới rõ rệt. Điều đó cho thấy phân phối các đặc trưng này rộng và đồng đều cao xấp xỉ 0.1 riêng Otu0206 có độ phân tán thấp hơn hẳn. Và cuối cùng tập Vogtmann ở hình 4.54d Các đặc trưng như OTU1115, OTU0821, OTU0779, và OTU0268 có độ quan trọng rất thấp và ít phân tán, gần như cố định quanh giá trị 0. Điều



Hình 4.53. Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên

này cho thấy chúng đóng vai trò không đáng kể trong việc gây bệnh và độ phân bố dữ liệu không đồng đều. Trong khi đó đặc trưng OTU0322 có độ quan trọng cao hơn hẳn so với



Hình 4.54. Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên

các đặc trưng khác, Điều này chứng tỏ OTU0322 có tác động đáng kể hơn trong nhóm gây bệnh. Còn với nhóm các đặc trưng không gây bệnh,, Otu0302 tiếp tục có độ quan trọng cao nhất gần 0.12. Các đặc trưng còn lại Otu0779, Otu0017, và Otu0413 có giá trị thấp hơn nhiều và phân tán hẹp. Điều này gợi ý rằng chúng không đóng vai trò quan trọng trong việc không gây bệnh.


Từ Hình 4.53 và 4.54 có thể thấy tần suất xuất hiện của đặc trưng nhiều hay ít cũng

không ảnh hưởng đến mức độ quan trọng cũng như mức độ ảnh hưởng của nó đến việc dự đoán mô hình XAI. Tuy nhiên với phương pháp DiCE, top 5 tất cả các đặc trưng thuộc cả nhóm có bệnh và không bệnh khi xuất hiện với tần xuất nhiều đều tương ứng với độ quan trọng cao. Các đặc trưng thu thập được ở cả lần thực nghiệm DiCE với mẫu đầu tiên của mỗi tập dữ liệu và với 50 mẫu ngẫu nhiên chi tiết như sau:

- + Các đặc trưng gây bệnh: Otu0821.
- + Các đặc trưng không gây bệnh: Otu0218

4.3.4.2 Mô hình GBC


Phân tích kết quả với 50 đặc trưng quan trọng của mẫu đầu tiên được lựa chọn bằng các phương pháp XAI



Hình 4.55. Biểu đồ Min-Max trọng số DiCE của 50 đặc trưng quan trọng

Trong Hình 4.55 này, các giá trị trọng số đã được sắp xếp theo thứ tự giảm dần. Tất cả các giá trị trọng số ở các tập dữ liệu đều dương, rõ ràng nhất là hầu hết ở các đặc trưng ban đầu, tập dữ liệu Yu, Zeller, Vogtmann đều có trọng số DiCE khác biệt thể hiện ở độ dốc lớn ở những giá trị cao nhất, cho thấy phương pháp DiCE hầu như có thể xác định sự chênh lệch về tầm quan trọng của giá trị giữa các đặc trưng. Với tập Feng, các giá trị đầu tiên hầu như đều bằng 1.0 sau đó mới bắt đầu xuất hiện độ dốc. Đặc biệt giá trị trọng số cao nhất là 1.0 thuộc tập Feng và Zeller trong khi giá trị thấp nhất là 0.125 thuộc tập Vogtmann. Vì GBC thường kết hợp nhiều đặc trưng với mức độ ảnh hưởng khác nhau, trọng số DiCE của các đặc trưng thường phân tán và ít có giá trị 1.0 tuyệt đối, mà thay vào đó là các giá trị khác nhau (thấp hơn).


Các trọng số được phân phối như sau:




Hình 4.56. Biểu đồ phân phối trọng số DiCE 50 đặc trưng quan trọng của mẫu đầu tiên về bệnh CRC

Với các biểu đồ phân phối trong hình 4.56 này, các trọng số của 50 đặc trưng quan trọng nhất trong mỗi bộ dữ liệu đều có xu hướng phân phối lệch phải. Điều này cho thấy hầu hết các đặc trưng quan trọng có ảnh hưởng rất nhỏ, ngoại trừ một số đặc trưng có ảnh hưởng lớn hơn một chút. Tập Zeller có vẻ có sự phân phối các giá trị rộng rãi hơn 3 tập còn lại, trong khi tập Yu lại tập trung giá trị trọng số cao nhất so với 3 bộ còn lại (lên đến 0.12).


Sau khi tiến hành biểu diễn các kết quả được thu thập như Hình 4.57 thông qua quá trình thực nghiệm trên 10 fold, kết quả trên 4 tập dataset được hiển thị, với bộ dữ liệu Yu trong hình 4.57a, giá trị AUC cao nhất đạt 0.80933, giá trị AUC tăng dần từ 1 đến khoảng 25 đặc trưng, sau đó dao động nhẹ và đạt sự ổn định. Điều này cho thấy rằng việc thêm các đặc trưng từ 1 đến 25 có tác động lớn nhất đến việc cải thiện hiệu suất phân loại. Bộ dữ liệu Feng trong hình 4.57b cho thấy giá trị AUC khá ổn định và tăng chậm hơn, phản ánh rằng các đặc trưng bổ sung sau giai đoạn đầu không cải thiện đáng kể hiệu suất, kết quả AUC cao nhất được thực nghiệm là 0.66250. Đối với Zeller, AUC tăng đáng kể từ 1 đến 5 đặc trưng đầu sau đó có xu hướng giảm rồi lại tăng và có xu hướng ổn định, cho thấy rằng hiệu suất phân loại chủ yếu phụ thuộc vào một nhóm đặc trưng quan trọng ở giai đoạn đầu, có kết quả thu được cao nhất được trình bày trong Hình 4.57c với giá trị AUC là 0.79233. Cuối cùng, với Vogtmann, giá trị AUC tăng đến khoảng 20 đặc trưng rồi có xu hướng giảm, cho thấy các đặc trưng bổ sung sau giai đoạn sau không cải thiện đáng kể hiệu suất, kết quả thực nghiệm được trình bày trong Hình 4.57d có giá trị AUC cao nhất sau quá trình thử nghiệm là 0.80550. Nhìn chung, so với ALIME, LIME và SHAP thì DiCE không thể hiện quá rõ mức độ tăng AUC khi thêm đặc trưng mới khác nhau giữa các bộ dữ liệu, cho thấy




(a) Yu



(b) Feng



(c) Zeller




(d) Vogtmann


Hình 4.57. Boxplot của giá trị AUC theo số lượng đặc trưng (từ 1 đến 50 đặc trưng quan trọng) của mẫu đầu tiên

có ít sự khác biệt về tầm quan trọng và mức độ ảnh hưởng của các đặc trưng trong từng bộ dữ liệu. Các outliers tập trung nhiều ở bộ dữ liệu Yu cho thấy tính không ổn định của mô hình có thể do đặc trưng không ổn định hoặc nhiễu, trong khi các dataset còn lại có độ ổn

định cao hơn.




(a) Difference of original sample with counterfactual




(b) Features that influence prediction

Hình 4.58. Biểu đồ dự đoán DiCE với bộ dữ liệu Yu.

Kết quả dự đoán của mô hình và DiCE nhất quán, khi nhãn dự đoán và giá trị DiCE đều xác định nhãn là 0 với kết quả dự đoán là $9.99999895e-01$. Đồng thời dự đoán 5 phản chứng với các nhãn lần lượt là 1, 0, 1, 0, và 1. Kết quả cho thấy dự đoán của mô hình trùng với phản chứng 2,4. Từ hình 4.58a có thể thấy sự chênh lệch giữa mẫu ban đầu với các phản chứng cho từng mẫu, trong đó Otu0024 là đặc trưng có sự chênh lệch nhiều nhất với các phản chứng được tạo ra. Sự khác biệt này cho thấy chúng đóng vai trò quan trọng trong việc xác định nhãn của mẫu nên đã thay đổi các đặc trưng quan trọng để làm thay đổi nhãn. Đây là minh chứng rằng các đặc trưng này thực sự có ý nghĩa quyết định trong dự đoán của mô hình. Trong hình 4.58b đã thể hiện top 10 đặc trưng có giá trị ảnh hưởng cao, trong đó Otu0024 là đặc trưng ảnh hưởng cao nhất, với giá trị trung bình cao hơn 0.0014. Các đặc trưng khác như Otu1961 và Otu0268 cũng đóng góp tương đối lớn với giá trị khoảng 0.0014 và giảm dần cho các đặc trưng tiếp theo.



(a) Difference of original sample with counterfactual




(b) Features that influence prediction


Hình 4.59. Biểu đồ dự đoán DiCE với bộ dữ liệu Feng.

Kết quả dự đoán của mô hình và DiCE nhất quán, khi nhãn dự đoán và giá trị DiCE đều xác định nhãn là 1 với kết quả dự đoán là $9.99999983e-01$. Đồng thời dự đoán 5 phản chứng với các nhãn lần lượt là 1, 1, 1, 0, và 0. Kết quả cho thấy dự đoán của mô hình và phản chứng 1,2,3 trùng nhau. Từ hình 4.59a có thể thấy sự chênh lệch giữa mẫu ban đầu với các phản chứng cho từng mẫu, trong đó Otu0005 là đặc trưng có sự chênh lệch nhiều nhất với các phản chứng được tạo ra. Sự khác biệt này cho thấy chúng đóng vai trò quan trọng trong việc xác định nhãn của mẫu nên đã thay đổi các đặc trưng quan trọng để làm thay đổi nhãn. Đây là minh chứng rằng các đặc trưng này thực sự có ý nghĩa quyết định trong dự

đoán của mô hình. Trong hình 4.59b đã thể hiện top 10 đặc trưng có giá trị ảnh hưởng cao, trong đó Otu0954 là đặc trưng ảnh hưởng cao nhất, với giá trị trung bình khoảng 0.0016. Các đặc trưng khác như Otu0247 và Otu0922 cũng đóng góp tương đối lớn với giá trị gần khoảng 0.0014 và giảm dần cho các đặc trưng tiếp theo.




(a) Difference of original sample with counterfactual




(b) Features that influence prediction

Hình 4.60. Biểu đồ dự đoán DiCE với bộ dữ liệu Zeller.

Kết quả dự đoán của mô hình và DiCE nhất quán, khi nhãn dự đoán và giá trị DiCE đều xác định nhãn là 1 với kết quả dự đoán là 9.99999983e-01. Đồng thời dự đoán 5 phản chứng với các nhãn lần lượt là 0, 1, 0, 1, và 0. Kết quả cho thấy dự đoán của mô hình và phản chứng 2,4 trùng nhau. Từ hình 4.60a có thể thấy sự chênh lệch giữa mẫu ban đầu với các phản chứng cho từng mẫu, trong đó Otu0188 là đặc trưng có sự chênh lệch nhiều nhất với các phản chứng được tạo ra. Sự khác biệt này cho thấy chúng đóng vai trò quan trọng trong việc xác định nhãn của mẫu nên đã thay đổi các đặc trưng quan trọng để làm thay đổi nhãn. Đây là minh chứng rằng các đặc trưng này thực sự có ý nghĩa quyết định trong dự đoán của mô hình. Trong hình 4.60b đã thể hiện top 10 đặc trưng có giá trị ảnh hưởng cao, trong đó Otu0188 là đặc trưng ảnh hưởng cao nhất, với giá trị trung bình khoảng 0.0012. Các đặc trưng khác như Otu0781 và Otu0299 cũng đóng góp tương đối lớn nhưng giá trị không quá khác biệt so với đặc trưng ảnh hưởng nhất, giá trị cũng nằm khoảng 0.012 và giảm dần cho các đặc trưng tiếp theo.



(a) Difference of original sample with counterfactual



(b) Features that influence prediction

Hình 4.61. Biểu đồ dự đoán DiCE với bộ dữ liệu Vogtmann.

Kết quả dự đoán của mô hình và DiCE nhất quán, khi nhãn dự đoán và giá trị DiCE đều xác định nhãn là 0 với kết quả dự đoán là 9.99999992e-01. Đồng thời dự đoán 5 phản chứng với các nhãn lần lượt là 1, 1, 1, 0, và 1. Kết quả cho thấy dự đoán của mô hình chỉ có phản chứng 1 là trùng nhau. Từ hình 4.61a có thể thấy sự chênh lệch giữa mẫu ban đầu với


các phản chứng cho từng mẫu, trong đó Otu0606 là đặc trưng có sự chênh lệch nhiều nhất với các phản chứng được tạo ra. Sự khác biệt này cho thấy chúng đóng vai trò quan trọng trong việc xác định nhân của mẫu nên đã thay đổi các đặc trưng quan trọng để làm thay đổi nhân. Đây là minh chứng rằng các đặc trưng này thực sự có ý nghĩa quyết định trong dự đoán của mô hình. Trong hình 4.61b đã thể hiện top 10 đặc trưng có giá trị ảnh hưởng cao, trong đó Out0606 là đặc trưng ảnh hưởng cao nhất, các đặc trưng khác như Otu0214 và Otu1890 cũng ảnh hưởng không kém nên các giá trị trung bình cũng xấp xỉ nhau cao hơn 0.012 và giảm dần cho các đặc trưng tiếp theo.

Tóm lại từ hình 4.58, 4.59, 4.60 và 4.61 với dự đoán bằng phương pháp DiCE kết hợp với mô hình GBC không có đặc trưng nào xuất hiện nhiều lần. Tất cả đặc trưng trong 4 tập đều chỉ xuất hiện 1 lần duy nhất. Điều này có thể do cơ chế hoạt động của GBC, GBC xây dựng các cây tuần tự, mỗi cây tối ưu hóa dựa trên lỗi còn lại của các cây trước đó. Vì vậy, GBC có xu hướng sử dụng nhiều đặc trưng khác nhau trong mỗi cây, dẫn đến các đặc trưng quan trọng phân tán hơn.

Phân tích kết quả với 50 mẫu ngẫu nhiên


Từ hình 4.62 chúng ta có thể thấy với bộ dữ liệu của bệnh CRC thì có 1 đặc trưng có tần suất xuất hiện nhiều nhất các tập dataset khác nhau là Otu0430. Còn các đặc trưng Otu0504, Otu0035, Otu0290, Otu0781, Otu1915, Otu0383, Otu0309 xuất hiện nhiều lần trong cùng 1 tập dữ liệu chỉ là khác nhóm bệnh và không bệnh. Cụ thể đặc trưng Otu0430 trong tập Yu thuộc cả 2 nhóm không bệnh và bệnh còn trong tập Vogtmann thuộc nhóm gây bệnh.

Các biểu đồ boxplot trong hình 4.63 cho thấy sự phân bố độ quan trọng của các đặc trưng gây bệnh và không gây bệnh khác nhau. Với một số đặc trưng có phạm vi rộng và nhiều giá trị Outliers, cho thấy rằng có sự biến thiên lớn trong mức độ quan trọng giữa các đặc trưng. Một số đặc trưng có độ quan trọng ổn định hơn, trong khi các đặc trưng khác có sự phân bố rộng hơn, thể hiện sự biến động trong dữ liệu. Cụ thể trong tập Yu ở hình 4.63a, độ quan trọng cao và thấp nhất của nhóm các đặc trưng gây bệnh là của Otu0879 với giá trị cao lớn hơn 2.00000 và giá trị thấp là dưới 0.0000. Otu0879 là một đặc trưng đặc biệt trong top 5 vì vừa có giá trị cao nhất vừa thấp nhất, cho thấy nó có thể đóng vai trò linh hoạt và phụ thuộc nhiều vào ngữ cảnh. Đặc trưng này có thể vừa mang tác động tích cực (tăng khả năng không gây bệnh ở một số mẫu) vừa tác động tiêu cực (giảm khả năng không gây bệnh ở các mẫu khác). Tuy nhiên trong khi các đặc trưng khác trong top 5 có giá trị quan trọng ổn định hơn (dao động hẹp hơn), Otu0879 lại thể hiện sự biến thiên vượt trội, làm nổi bật vai trò tiềm năng nhưng không ổn định của nó trong nhóm gây bệnh. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu1707 với giá trị gần bằng 0.00000 và giá trị nhỏ nhất là thấp hơn -6 thuộc về đặc trưng Otu1902. Tiếp theo tập Feng ở hình 4.63b, độ quan trọng cao và thấp nhất đều là của đặc trưng Otu1289 với giá trị lớn hơn 7 và giá trị thấp dưới -1. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0925 với giá trị gần bằng 0.0000 và giá trị nhỏ nhất thấp hơn -1.5 thuộc về đặc trưng Otu1853. Tập Zeller trong hình 4.63c có độ quan trọng cao nhất của nhóm các đặc trưng gây bệnh là của Otu0267 với giá trị lớn hơn 3.5, thấp nhất là Otu0782 với giá trị cao hơn 0.0000. Còn với nhóm các đặc trưng không gây bệnh, giá



Hình 4.62. Biểu đồ top 5 đặc trưng xuất hiện nhiều nhất trong 50 mẫu ngẫu nhiên

trị lớn nhất của độ quan trọng là của Otu1967 với giá trị xấp xỉ 0.00000 và giá trị nhỏ nhất dưới -1.5 thuộc về đặc trưng Otu0827. Và cuối cùng tập Vogtmann ở hình 4.63d độ quan



Hình 4.63. Boxplot thể hiện độ quan trọng của các đặc trưng bệnh và không bệnh qua 50 mẫu ngẫu nhiên

trọng cao và thấp nhất của nhóm các đặc trưng gây bệnh là của Otu1982 với giá trị cao hơn 1.5, giá trị thấp khoảng dưới -0.25 cho thấy Otu1982 là một đặc trưng đặc biệt trong top 5 vì vừa có giá trị cao nhất vừa thấp nhất, cho thấy nó có thể đóng vai trò linh hoạt và phụ thuộc nhiều vào ngữ cảnh. Còn với nhóm các đặc trưng không gây bệnh, giá trị lớn nhất của độ quan trọng là của Otu0407 với giá trị gần bằng 0.00000 và giá trị nhỏ nhất thấp hơn -2 thuộc về đặc trưng Otu1800.

Từ Hình 4.63 và 4.62 có thể thấy tần suất xuất hiện của đặc trưng nhiều hay ít cũng không ảnh hưởng đến mức độ quan trọng cũng như mức độ ảnh hưởng của nó đến việc dự đoán mô hình XAI. Tuy nhiên với phương pháp DiCE, top 5 tất cả các đặc trưng thuộc cả nhóm có bệnh và không bệnh khi xuất hiện với tần suất nhiều đều tương ứng với độ quan trọng cao. Các đặc trưng thu thập được ở cả lần thực nghiệm DiCE với mẫu đầu tiên của mỗi tập dữ liệu và với 50 mẫu ngẫu nhiên chi tiết như sau:

- + Các đặc trưng gây bệnh: Otu0024.
- + Các đặc trưng không gây bệnh: Otu1427, Otu0513.

Tóm lại Tóm lại với phương pháp DiCE cho cả 2 mô hình RF và GBC, DiCE dự đoán tốt hơn khi kết hợp với mô hình GBC với dự đoán gần như tuyệt đối. Tuy nhiên so với 2 phương pháp trước đó là LIME và ALIME thì có vẻ SHAP khi kết hợp với 2 mô hình này đã trở nên nhạy hơn vì thế mà các đặc trưng quan trọng với nhóm gây bệnh và nhóm không bệnh đã được tìm thấy nhiều hơn. Sau khi thực nghiệm DiCE với cả mô hình RF và GBC ở 2 cách thức tiếp cận là trên mẫu đầu tiên và trên 50 mẫu ngẫu nhiên, thu thập được các đặc trưng sau đây:

- + Các đặc trưng thuộc nhóm tăng khả năng bệnh: Otu0024, Otu0821.
- + Các đặc trưng thuộc nhóm tăng khả năng không bệnh: Otu1427, Otu0513, Otu0218
- + Các đặc trưng thuộc cả 2 nhóm bệnh và không bệnh: Otu0430, Otu0504, Otu0035, Otu0290, Otu0781, Otu1915, Otu0309, Otu0302, Otu0361, Otu0169, Otu0236, Otu0468, Otu0800, Otu0383, Otu0779, Otu0253, Otu0130

4.4 Thảo luận kết quả

Nhóm bệnh:

- LIME: Otu0420, Otu1316, Otu1231, Otu0122, Otu1145, Otu1628, Otu1440, Otu1385, Otu1550, Otu1636, Otu1140, Otu1644
- ALIME: Otu0672, Otu0917, Otu0923, Otu1784, Otu0944, Otu0309, Otu0760, Otu0406, Otu1249, Otu0664, Otu0357, Otu1915, Otu1952, Otu1324, Otu0994, Otu0345, Otu1971, Otu0302, Otu0029, Otu0868, Otu0283, Otu1288
- SHAP: Otu0267, Otu0580, Otu1501, Otu1853, Otu0918, Otu0028, Otu1586, Otu0399
- DiCE: Otu0024, Otu0821

Nhóm không bệnh:

- LIME: Otu0479, Otu1129, Otu1617, Otu0062, Otu0312, Otu0565, Otu0302, Otu0917, Otu0303, Otu0847, Otu1833, Otu1310, Otu0431, Otu1521, Otu1727, Otu1363, Otu1631, Otu0847

- ALIME: Otu0677, Otu0915, Otu0280, Otu1947, Otu0562, Otu0042, Otu0048, Otu1776, Otu1457, Otu0062, Otu1882, Otu0550, Otu1550, Otu0183, Otu1136, Otu1142, Otu0089, Otu0193, Otu1771, Otu1644, Otu1064
- SHAP: Otu0302, Otu0827, Otu1568, Otu1800, Otu1455, Otu1372, Otu0994, Otu0029, Otu0292, Otu1218, Otu1547.
- DiCE: Otu1427, Otu0513, Otu218

Nhóm thuộc cả hai nhóm bệnh và không bệnh:

- LIME: Otu0915, Otu1612, Otu0565, Otu0217, Otu0793, Otu0294, Otu0993, Otu0990, Otu1136.
- ALIME: Otu1116, Otu0493, Otu0528, Otu1134, Otu1600, Otu1203, Otu0868, Otu1204, Otu0639, Otu0770, Otu0228, Otu1118, Otu0233, Otu1911, Otu0493, Otu0528, Otu1980, Otu0987, Otu1877, Otu1203.
- SHAP: Otu1902, Otu0998, Otu0816, Otu0879, Otu1289, Otu1853, Otu0969.
- DiCE: Otu0430, Otu0504, Otu0035, Otu0290, Otu0781, Otu1915, Otu0309, Otu0302, Otu0361, Otu0169, Otu0236, Otu0468, Otu0800, Otu0383, Otu0779, Otu0253, Otu0130.

Sau khi tổng hợp, các đặc trưng từ LIME, ALIME, SHAP, và DiCE thuộc cả 3 nhóm là:

- LIME: Otu0915 (*Parvimonas_micra*), Otu0565 (*Bacillus_atrophaeus*), Otu0302 (*Porphyromonas_asaccharolytica*).
- ALIME: Otu0302, Otu0994 (*Brucella_ovis*), Otu1915 (*Mycoplasma_canadense*), Otu0915, Otu0565.
- SHAP: Otu0302, Otu0994.
- DiCE: Otu0302, Otu1915.

Dựa trên kết quả trên từ 4 phương pháp (LIME, ALIME, SHAP, DiCE), có thể rút ra một số kết luận như sau: đặc trưng *Parvimonas_micra* thuộc nhóm cả hai (bệnh và không bệnh) theo LIME nhưng được xếp vào nhóm không bệnh theo ALIME, cho thấy vai trò quan trọng trong việc giảm nguy cơ bệnh. Đặc trưng *Bacillus_atrophaeus* cũng được xác định thuộc nhóm không bệnh theo ALIME, nhưng theo LIME, đặc trưng này nằm trong cả hai nhóm, gợi ý tính chất đa chiều của nó trong quá trình phân loại. Riêng *Porphyromonas_asaccharolytica* được xếp vào nhóm không bệnh bởi LIME và SHAP, nhưng trong ALIME, nó lại thuộc nhóm bệnh, đồng thời nằm trong cả hai nhóm theo DiCE, cho thấy đây là một đặc trưng quan trọng liên quan đến cả nguy cơ gây bệnh và an toàn. Đặc trưng *Brucella_ovis* được xác định trong nhóm không bệnh theo SHAP, nhưng theo ALIME, đặc trưng này thuộc nhóm bệnh, gợi ý vai trò mâu thuẫn của đặc trưng trong

hai phương pháp. Cuối cùng, đặc trưng *Mycoplasma_canadense* được xếp vào nhóm bệnh theo ALIME nhưng lại xuất hiện trong cả hai nhóm theo DiCE, điều này nhấn mạnh tính phức tạp và sự ảnh hưởng của đặc trưng này. Nhìn chung, các đặc trưng nổi bật nhất là *Porphyromonas_asaccharolytica*, vì chúng xuất hiện trong cả nhóm bệnh và không bệnh được các phương pháp LIME, ALIME, SHAP và DiCE xác nhận, cho thấy tầm quan trọng lớn trong việc nhận diện và dự đoán nguy cơ bệnh.

Xét theo yếu tố địa lý, đây cũng là một trong những yếu tố cần được chú trọng vì khả năng gây ra bệnh cũng liên quan đến không khí hoặc môi trường sống, thói quen sinh hoạt ở từng địa phương,...

- Đặc trưng riêng của châu Âu: Otu1631 (*Shigella_sp_PAMC_28760*)
- Đặc trưng trùng khớp giữa châu Á và châu Âu: Otu0993(*Brucella_microti*), Otu0217 (*Pseudonocardia_sp_EC080610-09*)
- Đặc trưng trùng khớp giữa châu Á và châu Mỹ: Otu1136(*Rickettsia_heilongjiangensis*), Otu0430(*Chlamydia_trachomatis*)
- Đặc trưng trùng khớp giữa châu Âu và châu Mỹ: Otu0990(*Brucella_canis*), Otu1644 (*Yersinia_frederiksenii*), Otu0565 (*Bacillus_atrophaeus*), Otu1547(*Citrobacter_freundii*), Otu0253(*Streptomyces_sp_S10(2016)*)
- Đặc trưng xuất hiện ở cả ba châu lục (châu Á, châu Âu và châu Mỹ): Otu1116 (*Wolbachia_endosymbiont_of_Drosophila_melanogaster*), Otu0302 (*Porphyromonas_asaccharolytica*)

Đặc trưng riêng của châu Âu là *Shigella_sp_PAMC_28760*, đại diện cho các yếu tố đặc thù như môi trường sống hoặc chế độ ăn uống tại khu vực này. Giữa châu Á và châu Âu, các đặc trưng trùng khớp gồm *Brucella_microti*, *Pseudonocardia_sp_EC080610-09*, có thể phản ánh một số yếu tố tương đồng như lối sống hiện đại hoặc chế độ ăn uống giàu đường (gạo, thực phẩm lên men). Ở châu Á và châu Mỹ, các đặc trưng chung gồm *Rickettsia_heilongjiangensis*, *Chlamydia_trachomatis*, có thể liên quan đến chế độ ăn giàu chất béo hoặc thực phẩm chế biến. Đặc trưng trùng khớp giữa châu Âu và châu Mỹ gồm *Brucella_canis*, *Yersinia_frederiksenii*, *Bacillus_atrophaeus*, *Citrobacter_freundii*, *Streptomyces_sp_S10(2016)*, đại diện cho các yếu tố chung của lối sống kiểu phương Tây, như thực phẩm giàu protein động vật hoặc ít chất xơ. Đáng chú ý, một số đặc trưng như *Shigella_sp_PAMC_28760*, *Bacillus_atrophaeus*, và *Citrobacter_freundii* chỉ xuất hiện ở nhóm không bệnh, có thể đại diện cho trạng thái bảo vệ tự nhiên, trong khi các đặc trưng còn lại xuất hiện ở cả hai nhóm (bệnh và không bệnh), cho thấy vai trò kép phụ thuộc vào sự tương tác giữa môi trường và lối sống. Đặc biệt, *Porphyromonas_asaccharolytica* và *Wolbachia_endosymbiont_of_Drosophila_melanogaster* sự xuất hiện của chúng ở cả ba châu lục cho thấy các đặc trưng này không bị ảnh hưởng bởi yếu tố địa lý, mà nhiều khả năng liên quan đến cơ chế gây bệnh chung. Điều này cho thấy sự xuất hiện riêng biệt của các đặc trưng như *Shigella_sp_PAMC_28760* có thể phản ánh tác động từ môi trường, chế độ ăn, và văn hóa lối sống của một địa phương từ đó có thể giúp xây dựng các biện pháp

Bảng 4.3. Kết quả so sánh độ đo AUC với nghiên cứu trước

	Mô hình	Yu	Feng	Zeller	Vogtmann	Số đặc trưng
LIME	RF	0,79178	0,69691	0,80874	0,77728	50
ALIME	RF	0,78781	0,73041	0,78267	0,80172	50
SHAP	RF	0,75180	0,80621	0,83976	0,76065	50
DiCE	RF	0,46256	0,57723	0,62013	0,61456	50
LIME	GBC	0,72828	0,66203	0,84479	0,69690	50
ALIME	GBC	0,77640	0,58978	0,85592	0,70876	50
SHAP	GBC	0,63586	0,84301	0,86918	0,87377	50
DiCE	GBC	0,72689	0,58429	0,75560	0,73332	50
[72]	SVM	0,84000	0,87000	0,82000	0,83000	994
[86]	RF	0,72000	0,92000	0,79000	0,60000	26
[87]	RF	0,65700	0,69200	0,78500	0,60000	849
[88]	RF	0,78000		0,75000	0,62000	410(Yu), 469(Zeller), 410(Vogtmann)

phòng ngừa hoặc điều trị phù hợp với từng khu vực cụ thể. Trong khi các đặc trưng như *Porphyromonas_asaccharolytica* và *Wolbachia_endosymbiont_of_Drosophila_melanogaster* có ý nghĩa quan trọng trong việc chẩn đoán và nghiên cứu áp dụng trên toàn cầu.

4.5 So sánh kết quả với các bài báo trước

Từ bảng 4.3 có thể thấy các giá trị AUC trong luận văn này hầu như đối với những bài báo có liên quan khác lại có kết quả khả quan hơn. Cụ thể ở tập Yu, giá trị LIME của mô hình RF là 0.79178 gần như lớn hơn các giá trị của các bài còn lại ngoại trừ bài báo của tác giả [72]. Trong tập Feng, giá trị cao nhất trong đề tài này là 0.84301 ở phương pháp SHAP với mô hình GBC lớn hơn giá trị AUC cái bài báo còn lại trừ bài báo của tác giả [86]. Còn ở tập Zeller, phương pháp SHAP với mô hình GBC đạt giá trị cao nhất là 0,86918, kết quả cao hơn tất cả các bài liên quan còn lại. Với tập dữ liệu Vogtmann, đề tài đạt giá trị cao nhất là 0.87377 ở SHAP của mô hình GBC cũng lớn hơn kết quả của các bài báo liên quan khác. Đề tài này đã có được một kết quả khá khả quan so với một số bài báo trước đó với số lượng đặc trưng huấn luyện ít hơn. Điều này cho thấy rằng một số phương pháp và cách thức xử lý dữ liệu trong luận văn này có thể mang lại hiệu quả tốt ngay cả khi số lượng đặc trưng không quá lớn.

Sau khi thực nghiệm với cả 4 phương pháp XAI chẩn đoán và xét cùng với yếu tố địa lí có 3 đặc trưng nổi bật nhất gây ảnh hưởng cả mặt tốt lẫn xấu của bệnh CRC bao gồm: *Porphyromonas asaccharolytica*, *Shigella sp* PAMC 28760, *Wolbachia endosymbiont of Drosophila melanogaster*. Trong đó *Porphyromonas asaccharolytica* được xác định là một dấu hiệu vi sinh vật liên quan đến CRC so với nhóm khỏe mạnh (HC) trong các nghiên cứu có chất lượng cao [89]. Trong nghiên cứu của tác giả Zeller, *Porphyromonas asaccharolytica* được xác định là một dấu hiệu vi sinh vật liên quan đến CRC [71]. Một bài viết khác

của tác giả Kaitlin J. Flynn đã nói rằng các loài thuộc chi *Porphyromonas*, đặc biệt là *P. asaccharolytica*, thường được tìm thấy với mật độ cao hơn trong hệ vi sinh vật đường ruột của bệnh nhân CRC. Điều này cho thấy vi khuẩn này có thể đóng vai trò quan trọng trong sự phát triển của bệnh CRC [90]. Mức độ phong phú của *Porphyromonas asaccharolytica* (tức là sự hiện diện và số lượng của vi khuẩn này trong ruột bệnh nhân), với sự xuất hiện cao hơn 40% ở nhóm những bệnh nhân gặp khó khăn trong quá trình lành vết nổi ở bệnh nhân CRC [91]. Trong bài báo gốc tác giả Zhenwei Dai cũng từng nói đến *Porphyromonas asaccharolytica* là một loại vi khuẩn đã được nghiên cứu và phát hiện có liên quan đến bệnh CRC. Nghiên cứu trước đây chỉ ra rằng vi khuẩn này có thể ảnh hưởng đến các quá trình sinh học trong cơ thể, đặc biệt là các con đường liên quan đến lipopolysaccharide (LPS) có thể gây phản ứng viêm trong cơ thể, viêm mãn tính và các con đường tổng hợp năng lượng [72]. Không chỉ ở người, *Porphyromonas asaccharolytica* cũng đã được chứng minh có vai trò trong sự phát triển khối u đại trực tràng, thông qua việc tiết ra butyrate và gây ra các dấu hiệu lão hóa tế bào trong nghiên cứu của tác giả Shintaro Okumura với thử nghiệm trên chuột [92].

Còn đặc trưng *Shigella* sp. PAMC 28760 là một đặc trưng được lấy từ một loại địa y ở Nam Cực, có khả năng phân giải cellulose, amylase và chuyển hóa glycogen [93]. Trong bài báo của tác giả Fedor Galkin đề cập đến một số loài vi khuẩn, bao gồm *Shigella* sp. PAMC 28760, là một trong các vi khuẩn ít được mô tả trong cộng đồng vi khuẩn đường ruột của con người. những loài vi khuẩn ít nghiên cứu này có thể vẫn cung cấp thông tin hữu ích về sự lão hóa của ruột. Để xác định liệu những loài này có thực sự có tác dụng hay không thì cần được tính toán trên một bộ dữ liệu độc lập có quy mô tương đương với bộ dữ liệu huấn luyện, đồng thời phải tính đến các biến meta khác nhau [94]. Một bài báo khác nói rằng *Shigella* sp. PAMC 28760 là một loại vi khuẩn được tìm thấy nhiều hơn ở những người mắc Hội chứng buồng trứng đa nang (PCOS). Các loại vi khuẩn này có thể gây ra bệnh bằng cách tiết ra các chất độc hại, làm tăng viêm trong cơ thể và ảnh hưởng đến ruột. Chúng có khả năng xâm nhập vào tế bào ruột và gây ra các vấn đề sức khỏe liên quan đến viêm và các rối loạn chuyển hóa [95]. Dù vẫn chưa có bằng chứng trực tiếp về sự ảnh hưởng của *Shigella* sp. PAMC 28760 đối với bệnh CRC, những khả năng tiềm ẩn từ cơ chế gây viêm, thay đổi cộng đồng vi sinh vật và tương tác với hệ miễn dịch có thể mở ra hướng nghiên cứu mới và đóng góp vào việc hiểu rõ hơn về cơ chế gây bệnh CRC. Vì vậy, kết quả nghiên cứu trong bài luận văn này có thể là một phát hiện mới cho nghiên cứu y học về bệnh CRC nói chung và ngành y tế toàn cầu nói riêng.

Wolbachia là một chi vi khuẩn thuộc họ Anaplasmataceae, lớp Alphaproteobacteria. Đây là một loại vi khuẩn nội ký sinh, nghĩa là nó sống trong tế bào của sinh vật chủ, và có mặt trong nhiều loài động vật, mà ở đây là ruồi giấm.² Đây là một đặc trưng ít được nghiên cứu trong cộng đồng vi khuẩn đường ruột của con người, và hầu như không có bài báo đề cập đến nó trong bối cảnh này. *Wolbachia endosymbiont of D. melanogaster* là chủng *Wolbachia* đầu tiên có bộ gen được giải mã hoàn chỉnh. Việc có sẵn bộ gen hoàn chỉnh của *Wolbachia* từ *D. melanogaster* đã giúp phát hiện ra một số biến thể cấu trúc phân biệt các kiểu gen *Wolbachia*, mở ra cơ hội nghiên cứu di truyền quần thể của *Wolbachia* trong

²<https://www.proquest.com/openview/fe232a0419673188b57ec9b756e5d261/1?pq-origsite=gscholar&cbl=18750&diss=y>

D. melanogaster [96]. Tác giả Asem Sanjit Singh đã phát hiện sự gia tăng đáng kể trong sự phong phú của *Wolbachia endosymbiont* của *Drosophila melanogaster* sau khi điều trị bằng kháng sinh. Kết quả của nghiên cứu cho thấy khi ruồi giấm được điều trị với kháng sinh, có sự gia tăng đáng kể về sự hiện diện của *Wolbachia* trong hệ vi sinh vật đường ruột của chúng. *Wolbachia* có thể tác động đến sinh sản, phản ứng miễn dịch và các chức năng sinh học khác của *D. melanogaster*, và sự gia tăng trong sự phong phú của nó có thể làm thay đổi cân bằng vi sinh vật và sức khỏe tổng thể của vật chủ [97]. Nghiên cứu khác của tác giả Ana T Eugénio chỉ ra rằng *Wolbachia endosymbiont* của *Drosophila melanogaster* có thể ảnh hưởng đến hoạt động của các yếu tố di truyền di động trong bộ gen của ruồi. Các yếu tố di truyền này có thể thay đổi vị trí trong bộ gen và gây ra đột biến. Khi ruồi giấm mang *Wolbachia*, số lượng và sự biểu hiện của các yếu tố di truyền này có thể thay đổi, làm ảnh hưởng đến sự đa dạng di truyền của vật chủ [98]. Nghiên cứu của tác giả Jing Chen cũng cho thấy *Wolbachia endosymbiont* của *Drosophila melanogaster* có thể bảo vệ vật chủ khỏi các bệnh nhiễm virus. Mặc dù cơ chế chính xác của sự bảo vệ này chưa được hiểu rõ hoàn toàn, nhưng *Wolbachia* đã được chứng minh có tác dụng bảo vệ vật chủ khỏi các bệnh nhiễm virus thông qua các tác động chuyển hóa [99]. Trong bài báo của tác giả Christine V. Macpherson dù không có thông tin trực tiếp về *Wolbachia endosymbiont* của *Drosophila melanogaster*, tuy nhiên, có một phần nói về nghiên cứu trên *D. melanogaster* liên quan đến ung thư đại tràng và các gen gây ung thư, bao gồm việc sử dụng công nghệ CRISPR-Cas9 để chỉnh sửa các gen có liên quan đến sự hình thành khối u trong ruột giữa của *D. melanogaster*[100].

Dựa trên các nghiên cứu trước đây, đặc trưng *Porphyromonas asaccharolytica* đã được chứng minh có khả năng gây bệnh đường ruột ở người. Trong khi đó, đối với hai đặc trưng còn lại, *Shigella* sp. PAMC 28760, mặc dù chưa có đủ bằng chứng chứng minh mối liên hệ với bệnh CRC, nhưng các nghiên cứu đã chỉ ra rằng đặc trưng này có thể gây hại đến hệ tiêu hóa. Về phía *Wolbachia endosymbiont* of *Drosophila melanogaster*, hiện tại không có nghiên cứu nào cho thấy mối liên quan đến bệnh CRC, mà ngược lại, các bài báo cho rằng đặc trưng này có thể giúp bảo vệ vật chủ khỏi các tác nhân gây hại.

4.6 Tổng kết chương

Chương này trình bày quá trình kiểm thử và đánh giá các phương pháp giải thích mô hình AI đối với chẩn đoán bệnh CRC từ dữ liệu metagenomics, sử dụng các kỹ thuật XAI như LIME, ALIME, SHAP và DiCE kết hợp với các mô hình học máy RF và GBC. Đầu tiên, các kết quả huấn luyện của từng phương pháp với hai mô hình đã được so sánh để xác định phương pháp có AUC cao nhất, qua đó lựa chọn phương pháp hiệu quả nhất cho việc giải thích mô hình. Sau đó, các phương pháp XAI được áp dụng để giải thích các dự đoán của mô hình và thu thập các đặc trưng quan trọng nhất liên quan đến nhóm bệnh và không bệnh, bằng hai cách tiếp cận: dựa trên mẫu đầu tiên và dựa trên 50 mẫu ngẫu nhiên. Kết quả thu được từ các phương pháp này giúp làm rõ vai trò của từng đặc trưng trong quá trình ra quyết định của mô hình. Tiếp theo, yếu tố địa lý đã được đưa vào xem xét để kiểm tra sự ảnh hưởng của nó đến các đặc trưng quan trọng, nhằm xác định liệu có sự khác biệt về đặc trưng giữa các vùng địa lý khác nhau. Các kết quả cho thấy một số đặc trưng có sự khác

biệt rõ rệt giữa các khu vực, trong khi những đặc trưng khác lại có sự phổ biến rộng rãi, không phụ thuộc vào vị trí địa lý.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Trong nghiên cứu này đã áp dụng các kỹ thuật XAI, bao gồm LIME, ALIME, SHAP và DiCE, kết hợp với hai mô hình học máy RF và GBC, để phân tích các đặc trưng quan trọng trong chẩn đoán bệnh ung thư đại trực tràng từ dữ liệu metagenomics. Kết quả AUC cho thấy phương pháp LIME và ALIME hầu như phù hợp với mô hình RF vì chúng có kết quả cao ở mô hình này so với GBC. Còn phương pháp SHAP và DiCE lại phù hợp với mô hình GBC hơn khi kết quả AUC đạt giá trị cao, trong đó SHAP thậm chí có kết quả cao nhất trong cả 4 phương pháp. Kết quả cho thấy LIME và ALIME cung cấp các biểu đồ giải thích trực quan, dễ hiểu, giúp người không chuyên về học máy có thể hiểu được lý do đằng sau các dự đoán của mô hình. LIME xác định các đặc trưng quan trọng và vai trò của chúng trong quyết định của mô hình, từ đó tăng cường khả năng giải thích và độ tin cậy của dự đoán. Tuy nhiên, cả LIME và ALIME đều có xu hướng tạo ra các đặc trưng trùng khớp giữa các mô hình RF và GBC, điều này có thể hạn chế khả năng khám phá các đặc trưng tiềm năng khác. ALIME cải thiện độ chính xác hơn LIME nhờ việc sử dụng Autoencoder, nhưng đôi khi gặp phải sự khác biệt trong dự đoán, chẳng hạn như khi mô hình dự đoán giá trị 0 nhưng ALIME lại dự đoán giá trị 1, điều này ảnh hưởng đến độ tin cậy của kết quả. SHAP đạt độ chính xác cao nhất trong quá trình huấn luyện, cho thấy khả năng giải thích mạnh mẽ và phù hợp với dữ liệu này. Riêng phương pháp DiCE lại nổi bật trong việc dự đoán các đặc trưng mới, ít bị trùng lặp giữa các mô hình, mở ra cơ hội khám phá các yếu tố mới liên quan đến bệnh, từ đó nâng cao hiểu biết về cơ chế gây bệnh.

Kết quả từ việc áp dụng bốn phương pháp phân tích khác nhau cho thấy các đặc trưng quan trọng nhất là *Porphyromonas asaccharolytica*, vì chúng xuất hiện trong tất cả các phương pháp XAI đã thực nghiệm. Điều này nhấn mạnh vai trò quan trọng của chúng trong cơ chế gây bệnh CRC. Các đặc trưng quan trọng khác, như *Bacillus atrophaeus*, *Brucella ovis*, *Parvimonas micra* và *Mycoplasma canadense*, cũng cho thấy mối liên hệ với bệnh, tuy nhiên mức độ phụ thuộc vào từng phương pháp phân tích XAI. Bên cạnh đó, yếu tố địa lý cũng được xem là một khía cạnh quan trọng trong nghiên cứu này. Một số đặc trưng, như *Shigella* sp. PAMC 28760, chỉ xuất hiện ở khu vực châu Âu, trong khi những đặc

trưng khác như *Porphyromonas asaccharolytica* và *Wolbachia endosymbiont of Drosophila melanogaster* xuất hiện ở cả ba châu lục. Điều này cho thấy rằng những đặc trưng này có thể không bị ảnh hưởng bởi yếu tố địa lý, mà thay vào đó, chúng có thể liên quan đến cơ chế gây bệnh chung cho CRC. Sự phân bố khác biệt của các đặc trưng như *Shigella* sp. PAMC 28760 có thể phản ánh ảnh hưởng từ các yếu tố môi trường, chế độ ăn uống và lối sống văn hóa đặc thù của mỗi khu vực, từ đó giúp xây dựng các biện pháp phòng ngừa và điều trị bệnh CRC phù hợp với đặc thù của từng vùng.

Những phát hiện này làm nổi bật tiềm năng của XAI trong việc không chỉ cải thiện khả năng dự đoán bệnh mà còn giúp hiểu sâu hơn về cơ chế gây bệnh và các yếu tố bảo vệ tự nhiên, góp phần mở ra hướng đi mới trong nghiên cứu metagenomics và bệnh CRC. Sau khi kết hợp kết quả từ các phương pháp XAI và xem xét yếu tố địa lý, ba đặc trưng nổi bật là *Porphyromonas asaccharolytica*, *Shigella* sp. PAMC 28760, và *Wolbachia endosymbiont of Drosophila melanogaster* đã được xác định. Các nghiên cứu trước đây cho thấy *Porphyromonas asaccharolytica* có khả năng gây bệnh đường ruột ở người. Còn đối với hai đặc trưng còn lại, mặc dù chưa có bằng chứng rõ ràng về mối liên hệ với bệnh CRC, nhưng các nghiên cứu đã chỉ ra rằng *Shigella* sp. PAMC 28760 có thể gây hại cho hệ tiêu hóa, trong khi *Wolbachia endosymbiont of Drosophila melanogaster* lại được cho là có khả năng bảo vệ vật chủ khỏi các tác nhân gây hại. Những phát hiện mới đề tài này hy vọng sẽ đóng góp vào việc phát triển nghiên cứu y học và mở rộng hiểu biết về metagenomics đường ruột trong tương lai.

5.2 Hạn chế

Hai phương pháp LIME và ALIME tạo ra nhiều đặc trưng trùng khớp hơn giữa các mô hình RF và GBC, giúp củng cố niềm tin vào sự ổn định của các đặc trưng quan trọng. Tuy nhiên, điều này cũng có thể phản ánh tính bảo thủ, dẫn đến bỏ qua các đặc trưng tiềm năng khác. Mặc dù các phương pháp XAI thực nghiệm trên đã cho thấy hiệu quả trong việc giải thích các mô hình học máy, tuy nhiên cả bốn phương pháp vẫn chưa thể tìm ra một đặc trưng chung rõ ràng giữa nhóm bệnh và nhóm không bệnh. Điều này cho thấy rằng việc tìm kiếm các đặc trưng quyết định trong dự đoán bệnh vẫn còn là một thách thức lớn. Với phương pháp DiCE việc khó khăn nhất là lựa chọn số lượng phản chứng, trong bài luận văn này em vẫn chưa tìm được phương pháp tối ưu cho công việc này. Bên cạnh đó, nghiên cứu chưa có đủ thời gian để thực nghiệm thêm với các bộ dữ liệu metagenomics về các bệnh khác làm hạn chế khả năng mở rộng và đa dạng hóa kết quả. Trong quá trình áp dụng các phương pháp XAI để giải thích mô hình từ dữ liệu metagenomic vẫn có một số trường hợp kết quả không đạt được độ chính xác như mong đợi. Sự khác biệt trong cách tiếp cận phân tích và tiền xử lý dữ liệu có thể là nguyên nhân dẫn đến những khác biệt trong kết quả so với các nghiên cứu khác.

5.3 Hướng phát triển

Để tiếp tục mở rộng và cải thiện nghiên cứu, đề tài này cần thêm nhiều bộ dữ liệu metagenomics từ các nguồn đa dạng hơn, bao gồm các dữ liệu liên châu lục hoặc liên

ngành để tăng tính toàn diện và khách quan của kết quả nghiên cứu. Mở rộng thử nghiệm với các phương pháp XAI mới và tiên tiến hơn, nhằm đánh giá khả năng giải thích mô hình từ nhiều góc độ khác nhau, đảm bảo sự bao quát và độ tin cậy của các đặc trưng được phát hiện. Tiếp tục tiến hành phân tích trên hàng trăm bộ đặc trưng khác nhau, từ đó đa dạng hóa các kịch bản thực nghiệm và khai thác tối đa tiềm năng của các phương pháp XAI hiện có. Thử nghiệm và tinh chỉnh nhiều bộ siêu tham số khác nhau để xác định các cấu hình tối ưu nhất, phù hợp với từng phương pháp XAI và mô hình học máy như RF, GBC. Nghiên cứu phát triển hoặc cải tiến các phương pháp XAI để xử lý dữ liệu phức tạp như metagenomics, từ đó cải thiện cả độ chính xác lẫn khả năng giải thích của mô hình. Kết hợp thử nghiệm các mô hình phức tạp hơn như mạng nơ-ron nhân tạo (Neural Networks) và học sâu (Deep Learning) để xử lý dữ liệu metagenomics lớn và phức tạp hơn, mở ra khả năng phát hiện các mối quan hệ phi tuyến tính và tương tác phức tạp giữa các đặc trưng. Tiếp đó sẽ tiến hành thử nghiệm và đánh giá kết quả trên các bộ dữ liệu lớn và đa dạng hơn, bao gồm cả sử dụng dữ liệu hình ảnh (ví dụ ảnh của vi sinh vật,...) để bổ sung thông tin và cải thiện sự phân tích của mô hình. Nghiên cứu mối quan hệ giữa dữ liệu hình ảnh và dữ liệu metagenomics, từ đó xây dựng các hệ thống dự đoán kết hợp mạnh mẽ hơn. Song song đó, việc điều tra và giải quyết các nguyên nhân gây ra sai số trong quá trình dự đoán là cần thiết để tăng cường hiệu suất và chính xác của mô hình. Áp dụng các phát hiện vào chẩn đoán bệnh CRC và mở rộng sang các bệnh liên quan khác, đặc biệt là các bệnh có liên hệ với hệ vi sinh vật đường ruột. Nghiên cứu này đã đưa ra những kết quả quan trọng, đặt nền tảng cho việc ứng dụng AI và XAI trong lĩnh vực metagenomics và chẩn đoán bệnh. Với các cải tiến và hướng phát triển trên hi vọng sẽ góp phần vào việc nâng cao hiệu quả chẩn đoán và điều trị bệnh CRC nói chung và các bệnh khác nói riêng, đồng thời thúc đẩy các nghiên cứu khoa học về mối quan hệ giữa vi sinh vật và sức khỏe con người.

TÀI LIỆU THAM KHẢO

- [1] Jo Handelsman et al. “Molecular biological access to the chemistry of unknown soil microbes: a new frontier for natural products”. In: *Chemistry & Biology* 5.10 (Oct. 1998), R245–R249. ISSN: 1074-5521. DOI: [10.1016/s1074-5521\(98\)90108-9](https://doi.org/10.1016/s1074-5521(98)90108-9). URL: [http://dx.doi.org/10.1016/s1074-5521\(98\)90108-9](http://dx.doi.org/10.1016/s1074-5521(98)90108-9) (Cited on page 2).
- [2] Michelle R. Rondon et al. “Cloning the Soil Metagenome: a Strategy for Accessing the Genetic and Functional Diversity of Uncultured Microorganisms”. In: *Applied and Environmental Microbiology* 66.6 (June 2000), 2541–2547. ISSN: 1098-5336. DOI: [10.1128/aem.66.6.2541-2547.2000](https://doi.org/10.1128/aem.66.6.2541-2547.2000). URL: <http://dx.doi.org/10.1128/AEM.66.6.2541-2547.2000> (Cited on page 2).
- [3] Kevin Chen and Lior Pachter. “Bioinformatics for Whole-Genome Shotgun Sequencing of Microbial Communities”. In: *PLoS Computational Biology* 1.2 (2005), e24. ISSN: 1553-7358. DOI: [10.1371/journal.pcbi.0010024](https://doi.org/10.1371/journal.pcbi.0010024). URL: <http://dx.doi.org/10.1371/journal.pcbi.0010024> (Cited on page 2).
- [4] Volkan Sevim et al. “Shotgun metagenome data of a defined mock community using Oxford Nanopore, PacBio and Illumina technologies”. In: *Scientific Data* 6.1 (Nov. 2019). ISSN: 2052-4463. DOI: [10.1038/s41597-019-0287-z](https://doi.org/10.1038/s41597-019-0287-z). URL: <http://dx.doi.org/10.1038/s41597-019-0287-z> (Cited on page 2).
- [5] Mingyue Cheng, Le Cao, and Kang Ning. “Microbiome Big-Data Mining and Applications Using Single-Cell Technologies and Metagenomics Approaches Toward Precision Medicine”. In: *Frontiers in Genetics* 10 (Oct. 2019). ISSN: 1664-8021. DOI: [10.3389/fgene.2019.00972](https://doi.org/10.3389/fgene.2019.00972). URL: <http://dx.doi.org/10.3389/fgene.2019.00972> (Cited on page 3).
- [6] Svetoslav Nanev Slavov. “Viral Metagenomics for Identification of Emerging Viruses in Transfusion Medicine”. In: *Viruses* 14.11 (Nov. 2022), p. 2448. ISSN: 1999-4915. DOI: [10.3390/v14112448](https://doi.org/10.3390/v14112448). URL: <http://dx.doi.org/10.3390/v14112448> (Cited on page 3).
- [7] Charles Y. Chiu and Steven A. Miller. “Clinical metagenomics”. In: *Nature Reviews Genetics* 20.6 (Mar. 2019), 341–355. ISSN: 1471-0064. DOI: [10.1038/s41576-019-0113-7](https://doi.org/10.1038/s41576-019-0113-7). URL: <http://dx.doi.org/10.1038/s41576-019-0113-7> (Cited on page 3).
- [8] *Metagenomic Analysis for Unveiling Agricultural Microbiome*. MDPI, June 2024. ISBN: 9783725813223. DOI: [10.3390/books978-3-7258-1321-6](https://doi.org/10.3390/books978-3-7258-1321-6). URL: <http://dx.doi.org/10.3390/books978-3-7258-1321-6> (Cited on page 3).

- [9] Kedibone Masenya, Madira Coutlyne Manganyi, and Tshegofatso Bridget Dikobe. “Exploring Cereal Metagenomics: Unravelling Microbial Communities for Improved Food Security”. In: *Microorganisms* 12.3 (Mar. 2024), p. 510. ISSN: 2076-2607. DOI: [10.3390/microorganisms12030510](https://doi.org/10.3390/microorganisms12030510). URL: <http://dx.doi.org/10.3390/microorganisms12030510> (Cited on page 3).
- [10] Vidya Niranjana et al. “Metagenomics to Metabolomics: Integrating Genomic Insights for Mulberry Crop Protection and Enhancement”. In: (May 2024). DOI: [10.1101/2024.05.12.593770](https://doi.org/10.1101/2024.05.12.593770). URL: <http://dx.doi.org/10.1101/2024.05.12.593770> (Cited on page 3).
- [11] Li Tian et al. “Metagenomic approach revealed the mobility and co-occurrence of antibiotic resistomes between non-intensive aquaculture environment and human”. In: *Microbiome* 12.1 (June 2024). ISSN: 2049-2618. DOI: [10.1186/s40168-024-01824-x](https://doi.org/10.1186/s40168-024-01824-x). URL: <http://dx.doi.org/10.1186/s40168-024-01824-x> (Cited on page 3).
- [12] Cátia Santos-Pereira et al. “Metagenomics to unravel the microbial biodiversity and biotechnological potential of extreme high salinity environments”. In: *Functional Metagenomics*. Elsevier, 2024, 77–130. ISBN: 9780323983723. DOI: [10.1016/b978-0-323-98372-3.00011-3](https://doi.org/10.1016/b978-0-323-98372-3.00011-3). URL: <http://dx.doi.org/10.1016/B978-0-323-98372-3.00011-3> (Cited on page 4).
- [13] Elisa Banchi et al. “Genome-resolved metagenomics of Venice Lagoon surface sediment bacteria reveals high biosynthetic potential and metabolic plasticity as successful strategies in an impacted environment”. In: *Marine Life Science & Technology* 6.1 (Nov. 2023), 126–142. ISSN: 2662-1746. DOI: [10.1007/s42995-023-00192-z](https://doi.org/10.1007/s42995-023-00192-z). URL: <http://dx.doi.org/10.1007/s42995-023-00192-z> (Cited on page 4).
- [14] Qiuyue Xie and Zedong Zhang. “Efficient control of dissolved and colloidal substances in raw papermaking whitewater by immobilized thermophilic esterase from a metagenomic library”. In: *Cellulose* 31.7 (Apr. 2024), 4053–4062. ISSN: 1572-882X. DOI: [10.1007/s10570-024-05881-1](https://doi.org/10.1007/s10570-024-05881-1). URL: <http://dx.doi.org/10.1007/s10570-024-05881-1> (Cited on page 4).
- [15] Linjun Gao et al. “Metagenomic analysis reveals the distribution, function, and bacterial hosts of degradation genes in activated sludge from industrial wastewater treatment plants”. In: *Environmental Pollution* 340 (Jan. 2024), p. 122802. ISSN: 0269-7491. DOI: [10.1016/j.envpol.2023.122802](https://doi.org/10.1016/j.envpol.2023.122802). URL: <http://dx.doi.org/10.1016/j.envpol.2023.122802> (Cited on page 4).
- [16] Andréia O. Santos et al. “Application of metagenomics in the field of biotechnological conversion of lignocellulosic residues”. In: *Functional Metagenomics*. Elsevier, 2024, 41–76. ISBN: 9780323983723. DOI: [10.1016/b978-0-323-98372-3.00007-1](https://doi.org/10.1016/b978-0-323-98372-3.00007-1). URL: <http://dx.doi.org/10.1016/B978-0-323-98372-3.00007-1> (Cited on page 4).

- [17] Biniam Moges and Degisew Yinur Mengistu. “Metagenomics approaches for studying the human microbiome”. In: *All Life* 17.1 (May 2024). ISSN: 2689-5307. DOI: [10.1080/26895293.2024.2350166](https://doi.org/10.1080/26895293.2024.2350166). URL: <http://dx.doi.org/10.1080/26895293.2024.2350166> (Cited on page 4).
- [18] Rebeca Martín et al. “The role of metagenomics in understanding the human microbiome in health and disease”. In: *Virulence* 5.3 (Feb. 2014), 413–423. ISSN: 2150-5608. DOI: [10.4161/viru.27864](https://doi.org/10.4161/viru.27864). URL: <http://dx.doi.org/10.4161/viru.27864> (Cited on page 4).
- [19] Kirsty T. T. Kwok et al. “Virus Metagenomics in Farm Animals: A Systematic Review”. In: *Viruses* 12.1 (Jan. 2020), p. 107. ISSN: 1999-4915. DOI: [10.3390/v12010107](https://doi.org/10.3390/v12010107). URL: <http://dx.doi.org/10.3390/v12010107> (Cited on page 4).
- [20] Ruirui Hu et al. “A database of animal metagenomes”. In: *Scientific Data* 9.1 (June 2022). ISSN: 2052-4463. DOI: [10.1038/s41597-022-01444-w](https://doi.org/10.1038/s41597-022-01444-w). URL: <http://dx.doi.org/10.1038/s41597-022-01444-w> (Cited on page 5).
- [21] Alhagie K Cham et al. “Metagenome-enabled models improve genomic predictive ability and identification of herbivory-limiting genes in sweetpotato”. In: *Horticulture Research* 11.7 (May 2024). ISSN: 2052-7276. DOI: [10.1093/hr/uhae135](https://doi.org/10.1093/hr/uhae135). URL: <http://dx.doi.org/10.1093/hr/uhae135> (Cited on page 5).
- [22] Sachiko Masuda et al. “Uncovering microbiomes of the rice phyllosphere using long-read metagenomic sequencing”. In: *Communications Biology* 7.1 (Mar. 2024). ISSN: 2399-3642. DOI: [10.1038/s42003-024-05998-w](https://doi.org/10.1038/s42003-024-05998-w). URL: <http://dx.doi.org/10.1038/s42003-024-05998-w> (Cited on page 5).
- [23] Son Giang Nguyen et al. “Metagenomic investigation of the seasonal distribution of bacterial community and antibiotic-resistant genes in Day River Downstream, Ninh Binh, Vietnam”. In: *Applied Biological Chemistry* 65.1 (Apr. 2022). ISSN: 2468-0842. DOI: [10.1186/s13765-022-00687-w](https://doi.org/10.1186/s13765-022-00687-w). URL: <http://dx.doi.org/10.1186/s13765-022-00687-w> (Cited on page 5).
- [24] Lan-Anh Le et al. “Microbiome dataset analysis from a shrimp pond in Ninh Thuan, Vietnam using shotgun metagenomics”. In: *Data in Brief* 31 (Aug. 2020), p. 105731. ISSN: 2352-3409. DOI: [10.1016/j.dib.2020.105731](https://doi.org/10.1016/j.dib.2020.105731). URL: <http://dx.doi.org/10.1016/j.dib.2020.105731> (Cited on page 5).
- [25] Nguyen To Anh et al. “Viral Metagenomic Analysis of Cerebrospinal Fluid from Patients with Acute Central Nervous System Infections of Unknown Origin, Vietnam”. In: *Emerging Infectious Diseases* 27.1 (Jan. 2021), 205–213. ISSN: 1080-6059. DOI: [10.3201/eid2701.202723](https://doi.org/10.3201/eid2701.202723). URL: <http://dx.doi.org/10.3201/eid2701.202723> (Cited on page 5).
- [26] Dinh Minh Tran. “Rhizosphere microbiome dataset of Robusta coffee (*Coffea canephora* L.) grown in the Central Highlands, Vietnam, based on 16S rRNA metagenomics analysis”. In: *Data in Brief* 42 (June 2022), p. 108106. ISSN: 2352-3409. DOI: [10.1016/j.dib.2022.108106](https://doi.org/10.1016/j.dib.2022.108106). URL: <http://dx.doi.org/10.1016/j.dib.2022.108106> (Cited on page 5).

- [27] Amalio Telenti et al. “Deep learning of genomic variation and regulatory network data”. In: *Human Molecular Genetics* 27.Supplement_R1 (Apr. 2018), R63–R71. ISSN: 1460-2083. DOI: [10.1093/hmg/ddy115](https://doi.org/10.1093/hmg/ddy115). URL: <http://dx.doi.org/10.1093/hmg/ddy115> (Cited on page 6).
- [28] Tom Vermeire et al. “How to Choose an Explainability Method? Towards a Methodical Implementation of XAI in Practice”. In: *Machine Learning and Principles and Practice of Knowledge Discovery in Databases*. Springer International Publishing, 2021, 521–533. ISBN: 9783030937362. DOI: [10.1007/978-3-030-93736-2_39](https://doi.org/10.1007/978-3-030-93736-2_39). URL: http://dx.doi.org/10.1007/978-3-030-93736-2_39 (Cited on page 7).
- [29] Evren Dağlarlı. “Explainable Artificial Intelligence (xAI) Approaches and Deep Meta-Learning Models”. In: *Advances and Applications in Deep Learning*. IntechOpen, Dec. 2020. ISBN: 9781839628795. DOI: [10.5772/intechopen.92172](https://doi.org/10.5772/intechopen.92172). URL: <http://dx.doi.org/10.5772/intechopen.92172> (Cited on page 7).
- [30] Bas H.M. van der Velden et al. “Explainable artificial intelligence (XAI) in deep learning-based medical image analysis”. In: *Medical Image Analysis* 79 (July 2022), p. 102470. ISSN: 1361-8415. DOI: [10.1016/j.media.2022.102470](https://doi.org/10.1016/j.media.2022.102470). URL: <http://dx.doi.org/10.1016/j.media.2022.102470> (Cited on page 7).
- [31] Satya M. Muddamsetty, Mohammad N. S. Jahromi, and Thomas B. Moeslund. “Expert Level Evaluations for Explainable AI (XAI) Methods in the Medical Domain”. In: *Pattern Recognition. ICPR International Workshops and Challenges*. Springer International Publishing, 2021, 35–46. ISBN: 9783030687960. DOI: [10.1007/978-3-030-68796-0_3](https://doi.org/10.1007/978-3-030-68796-0_3). URL: http://dx.doi.org/10.1007/978-3-030-68796-0_3 (Cited on page 7).
- [32] Devam Dave et al. *Explainable AI meets Healthcare: A Study on Heart Disease Dataset*. 2020. DOI: [10.48550/ARXIV.2011.03195](https://doi.org/10.48550/ARXIV.2011.03195). URL: <https://arxiv.org/abs/2011.03195> (Cited on page 7).
- [33] Hamza Ahmed Shad et al. “Exploring Alzheimer’s Disease Prediction with XAI in various Neural Network Models”. In: *TENCON 2021 - 2021 IEEE Region 10 Conference (TENCON)*. IEEE, Dec. 2021, 720–725. DOI: [10.1109/tencon54134.2021.9707468](https://doi.org/10.1109/tencon54134.2021.9707468). URL: <http://dx.doi.org/10.1109/TENCON54134.2021.9707468> (Cited on page 8).
- [34] K. Muthamil Sudar et al. “Alzheimer’s Disease Analysis using Explainable Artificial Intelligence (XAI)”. In: *2022 International Conference on Sustainable Computing and Data Communication Systems (ICSCDS)*. IEEE, Apr. 2022, 419–423. DOI: [10.1109/icscds53736.2022.9760858](https://doi.org/10.1109/icscds53736.2022.9760858). URL: <http://dx.doi.org/10.1109/ICSCDS53736.2022.9760858> (Cited on page 8).
- [35] Firas Ketata et al. “A Methodology for Reliability Analysis of Explainable Machine Learning: Application to Endocrinology Diseases”. In: *IEEE Access* 12 (2024), 101921–101935. ISSN: 2169-3536. DOI: [10.1109/access.2024.3431691](https://doi.org/10.1109/access.2024.3431691). URL: <http://dx.doi.org/10.1109/ACCESS.2024.3431691> (Cited on page 8).

- [36] Mohanad M. Alsaleh et al. “Prediction of disease comorbidity using explainable artificial intelligence and machine learning techniques: A systematic review”. In: *International Journal of Medical Informatics* 175 (July 2023), p. 105088. ISSN: 1386-5056. DOI: [10.1016/j.ijmedinf.2023.105088](https://doi.org/10.1016/j.ijmedinf.2023.105088). URL: <http://dx.doi.org/10.1016/j.ijmedinf.2023.105088> (Cited on page 8).
- [37] Karthik Sekaran et al. “Unraveling the Dysbiosis of Vaginal Microbiome to Understand Cervical Cancer Disease Etiology—An Explainable AI Approach”. In: *Genes* 14.4 (Apr. 2023), p. 936. ISSN: 2073-4425. DOI: [10.3390/genes14040936](https://doi.org/10.3390/genes14040936). URL: <http://dx.doi.org/10.3390/genes14040936> (Cited on page 8).
- [38] Fatma Hilal Yagin et al. “Explainable artificial intelligence model for identifying COVID-19 gene biomarkers”. In: *Computers in Biology and Medicine* 154 (Mar. 2023), p. 106619. ISSN: 0010-4825. DOI: [10.1016/j.combiomed.2023.106619](https://doi.org/10.1016/j.combiomed.2023.106619). URL: <http://dx.doi.org/10.1016/j.combiomed.2023.106619> (Cited on page 8).
- [39] Pierfrancesco Novielli et al. “Personalized identification of autism-related bacteria in the gut microbiome using explainable artificial intelligence”. In: *iScience* 27.9 (Sept. 2024), p. 110709. ISSN: 2589-0042. DOI: [10.1016/j.isci.2024.110709](https://doi.org/10.1016/j.isci.2024.110709). URL: <http://dx.doi.org/10.1016/j.isci.2024.110709> (Cited on page 9).
- [40] Che-Cheng Chang et al. “Explainable machine learning model for identifying key gut microbes and metabolites biomarkers associated with myasthenia gravis”. In: *Computational and Structural Biotechnology Journal* 23 (Dec. 2024), 1572–1583. ISSN: 2001-0370. DOI: [10.1016/j.csbj.2024.04.025](https://doi.org/10.1016/j.csbj.2024.04.025). URL: <http://dx.doi.org/10.1016/j.csbj.2024.04.025> (Cited on page 9).
- [41] Hania Tourab et al. “The Use of Machine Learning and Explainable Artificial Intelligence in Gut Microbiome Research: A Scoping Review”. In: (Oct. 2024). DOI: [10.36227/techrxiv.172902810.02756061/v1](https://doi.org/10.36227/techrxiv.172902810.02756061/v1). URL: <http://dx.doi.org/10.36227/techrxiv.172902810.02756061/v1> (Cited on page 9).
- [42] Jaeyoung Shin. “Feasibility of local interpretable model-agnostic explanations (LIME) algorithm as an effective and interpretable feature selection method: comparative fNIRS study”. In: *Biomedical Engineering Letters* 13.4 (June 2023), 689–703. ISSN: 2093-985X. DOI: [10.1007/s13534-023-00291-x](https://doi.org/10.1007/s13534-023-00291-x). URL: <http://dx.doi.org/10.1007/s13534-023-00291-x> (Cited on page 9).
- [43] Advithi D and Umadevi V. “Integrating SMOTE and LIME Techniques for Enhanced Stroke Prediction using Machine Learning Approaches”. In: *2024 International Conference on Emerging Technologies in Computer Science for Interdisciplinary Applications (ICETCS)*. IEEE, Apr. 2024. DOI: [10.1109/icetcs61022.2024.10544182](https://doi.org/10.1109/icetcs61022.2024.10544182). URL: <http://dx.doi.org/10.1109/ICETCS61022.2024.10544182> (Cited on page 9).
- [44] Mercy Mawia Mulwa, Ronald Waweru Mwangi, and Agnes Mindila. “<sc>GMM-LIME</sc> explainable machine learning model for interpreting sensor-based human gait”. In: *Engineering Reports* (Feb. 2024). ISSN: 2577-8196. DOI: [10.1002/eng2.12864](https://doi.org/10.1002/eng2.12864). URL: <http://dx.doi.org/10.1002/eng2.12864> (Cited on page 9).

- [45] Lev Utkin et al. “Combining an Autoencoder and a Variational Autoencoder for Explaining the Machine Learning Model Predictions”. In: *2021 28th Conference of Open Innovations Association (FRUCT)*. IEEE, Jan. 2021, 489–494. DOI: [10.23919/fruct50888.2021.9347612](https://doi.org/10.23919/fruct50888.2021.9347612). URL: <http://dx.doi.org/10.23919/FRUCT50888.2021.9347612> (Cited on page 10).
- [46] Niloofar Ranjbar and Reza Safabakhsh. “Using Decision Tree as Local Interpretable Model in Autoencoder-based LIME”. In: *2022 27th International Computer Conference, Computer Society of Iran (CSICC)*. IEEE, Feb. 2022, 1–7. DOI: [10.1109/csicc55295.2022.9780503](https://doi.org/10.1109/csicc55295.2022.9780503). URL: <http://dx.doi.org/10.1109/CSICC55295.2022.9780503> (Cited on page 10).
- [47] Xu Xiang et al. “Stable local interpretable model-agnostic explanations based on a variational autoencoder”. In: *Applied Intelligence* 53.23 (Sept. 2023), 28226–28240. ISSN: 1573-7497. DOI: [10.1007/s10489-023-04942-5](https://doi.org/10.1007/s10489-023-04942-5). URL: <http://dx.doi.org/10.1007/s10489-023-04942-5> (Cited on page 10).
- [48] Xingyu Zhao et al. *BayLIME: Bayesian Local Interpretable Model-Agnostic Explanations*. 2020. DOI: [10.48550/ARXIV.2012.03058](https://doi.org/10.48550/ARXIV.2012.03058). URL: <https://arxiv.org/abs/2012.03058> (Cited on page 10).
- [49] Maxim S. Kovalev, Lev V. Utkin, and Ernest M. Kasimov. “SurvLIME: A method for explaining machine learning survival models”. In: *Knowledge-Based Systems* 203 (Sept. 2020), p. 106164. ISSN: 0950-7051. DOI: [10.1016/j.knosys.2020.106164](https://doi.org/10.1016/j.knosys.2020.106164). URL: <http://dx.doi.org/10.1016/j.knosys.2020.106164> (Cited on page 10).
- [50] Isaac Ahern et al. *NormLime: A New Feature Importance Metric for Explaining Deep Neural Networks*. 2019. DOI: [10.48550/ARXIV.1909.04200](https://doi.org/10.48550/ARXIV.1909.04200). URL: <https://arxiv.org/abs/1909.04200> (Cited on page 10).
- [51] I.U. Ekanayake, D.P.P. Meddage, and Upaka Rathnayake. “A novel approach to explain the black-box nature of machine learning in compressive strength predictions of concrete using Shapley additive explanations (SHAP)”. In: *Case Studies in Construction Materials* 16 (June 2022), e01059. ISSN: 2214-5095. DOI: [10.1016/j.cscm.2022.e01059](https://doi.org/10.1016/j.cscm.2022.e01059). URL: <http://dx.doi.org/10.1016/j.cscm.2022.e01059> (Cited on page 10).
- [52] Pasindu Meddage et al. “Interpretation of Machine-Learning-Based (Black-box) Wind Pressure Predictions for Low-Rise Gable-Roofed Buildings Using Shapley Additive Explanations (SHAP)”. In: *Buildings* 12.6 (May 2022), p. 734. ISSN: 2075-5309. DOI: [10.3390/buildings12060734](https://doi.org/10.3390/buildings12060734). URL: <http://dx.doi.org/10.3390/buildings12060734> (Cited on page 11).
- [53] Randika K. Makumbura et al. “Advancing water quality assessment and prediction using machine learning models, coupled with explainable artificial intelligence (XAI) techniques like shapley additive explanations (SHAP) for interpreting the black-box nature”. In: *Results in Engineering* 23 (Sept. 2024), p. 102831. ISSN: 2590-1230. DOI: [10.1016/j.rineng.2024.102831](https://doi.org/10.1016/j.rineng.2024.102831). URL: <http://dx.doi.org/10.1016/j.rineng.2024.102831> (Cited on page 11).

- [54] Maximilian Muschalik et al. “Beyond TreeSHAP: Efficient Computation of Any-Order Shapley Interactions for Tree Ensembles”. In: *Proceedings of the AAAI Conference on Artificial Intelligence* 38.13 (Mar. 2024), 14388–14396. ISSN: 2159-5399. DOI: [10.1609/aaai.v38i13.29352](https://doi.org/10.1609/aaai.v38i13.29352). URL: <http://dx.doi.org/10.1609/aaai.v38i13.29352> (Cited on page 11).
- [55] Nguyễn Quốc Huy and Từ Lăng Phiêu. “GIẢI THÍCH ĐẶC TRƯNG THỂ TÍN DỤNG THEO PHƯƠNG PHÁP LIME VÀ SHAP SAU GIAI ĐOẠN HỌC UndefinedU”. In: *Tạp chí Khoa học* 20.10 (Oct. 2023). ISSN: 2734-9918. DOI: [10.54607/hcmue.js.20.10.3906\(2023\)](https://doi.org/10.54607/hcmue.js.20.10.3906(2023)). URL: [http://dx.doi.org/10.54607/hcmue.js.20.10.3906\(2023\)](http://dx.doi.org/10.54607/hcmue.js.20.10.3906(2023)) (Cited on page 11).
- [56] Viswan Vimbi, Noushath Shaffi, and Mufti Mahmud. “Interpreting artificial intelligence models: a systematic review on the application of LIME and SHAP in Alzheimer’s disease detection”. In: *Brain Informatics* 11.1 (Apr. 2024). ISSN: 2198-4026. DOI: [10.1186/s40708-024-00222-1](https://doi.org/10.1186/s40708-024-00222-1). URL: <http://dx.doi.org/10.1186/s40708-024-00222-1> (Cited on page 11).
- [57] Diogo Gaspar, Paulo Silva, and Catarina Silva. “Explainable AI for Intrusion Detection Systems: LIME and SHAP Applicability on Multi-Layer Perceptron”. In: *IEEE Access* 12 (2024), 30164–30175. ISSN: 2169-3536. DOI: [10.1109/access.2024.3368377](https://doi.org/10.1109/access.2024.3368377). URL: <http://dx.doi.org/10.1109/ACCESS.2024.3368377> (Cited on page 11).
- [58] Kahakashan Ashraf et al. “Beyond the Black Box: Employing LIME and SHAP for Transparent Health Predictions with Machine Learning Models”. In: *2024 International Conference on Advances in Computing, Communication, Electrical, and Smart Systems (iCACCESS)*. IEEE, Mar. 2024. DOI: [10.1109/icaccess61735.2024.10499522](https://doi.org/10.1109/icaccess61735.2024.10499522). URL: <http://dx.doi.org/10.1109/iCACCESS61735.2024.10499522> (Cited on page 11).
- [59] Sotiris Raptis, Christos Ilioudis, and Kiriaki Theodorou. “From pixels to prognosis: unveiling radiomics models with SHAP and LIME for enhanced interpretability”. In: *Biomedical Physics & Engineering Express* 10.3 (Mar. 2024), p. 035016. ISSN: 2057-1976. DOI: [10.1088/2057-1976/ad34db](https://doi.org/10.1088/2057-1976/ad34db). URL: <http://dx.doi.org/10.1088/2057-1976/ad34db> (Cited on page 11).
- [60] Rituparna Chowdhury et al. “Unveiling Predictive Factors in Apple Quality: Leveraging LIME, SHAP, and the Synergy of Machine Learning Models and Artificial Neural Networks”. In: *2024 6th International Conference on Electrical Engineering and Information & Communication Technology (ICEEICT)*. IEEE, May 2024. DOI: [10.1109/iceeict62016.2024.10534426](https://doi.org/10.1109/iceeict62016.2024.10534426). URL: <http://dx.doi.org/10.1109/ICEEICT62016.2024.10534426> (Cited on page 12).
- [61] Ulf Lesley and Alejandro Kuratomi Hernández. “Improving XAI Explanations for Clinical Decision-Making – Physicians’ Perspective on Local Explanations in Healthcare”. In: *Artificial Intelligence in Medicine*. Springer Nature Switzerland, 2024, 296–312. ISBN: 9783031665356. DOI: [10.1007/978-3-031-66535-6_32](https://doi.org/10.1007/978-3-031-66535-6_32). URL: http://dx.doi.org/10.1007/978-3-031-66535-6_32 (Cited on page 12).

- [62] Bujar Raufi, Ciaran Finnegan, and Luca Longo. “A Comparative Analysis of SHAP, LIME, ANCHORS, and DICE for Interpreting a Dense Neural Network in Credit Card Fraud Detection”. In: *Explainable Artificial Intelligence*. Springer Nature Switzerland, 2024, 365–383. ISBN: 9783031638039. DOI: [10.1007/978-3-031-63803-9_20](https://doi.org/10.1007/978-3-031-63803-9_20). URL: http://dx.doi.org/10.1007/978-3-031-63803-9_20 (Cited on page 12).
- [63] Chihcheng Hsieh, Catarina Moreira, and Chun Ouyang. “DiCE4EL: Interpreting Process Predictions using a Milestone-Aware Counterfactual Approach”. In: *2021 3rd International Conference on Process Mining (ICPM)*. IEEE, Oct. 2021, 88–95. DOI: [10.1109/icpm53251.2021.9576881](https://doi.org/10.1109/icpm53251.2021.9576881). URL: <http://dx.doi.org/10.1109/ICPM53251.2021.9576881> (Cited on page 12).
- [64] Siqiong Zhou et al. “SCGAN: Sparse CounterGAN for Counterfactual Explanations in Breast Cancer Prediction”. In: (Apr. 2023). DOI: [10.1101/2023.04.16.23288633](https://doi.org/10.1101/2023.04.16.23288633). URL: <http://dx.doi.org/10.1101/2023.04.16.23288633> (Cited on page 12).
- [65] Yingying Fang et al. “DiffExplainer: Unveiling Black Box Models Via Counterfactual Generation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Springer Nature Switzerland, 2024, 208–218. ISBN: 9783031721175. DOI: [10.1007/978-3-031-72117-5_20](https://doi.org/10.1007/978-3-031-72117-5_20). URL: http://dx.doi.org/10.1007/978-3-031-72117-5_20 (Cited on page 12).
- [66] Hiba Fadlallah et al. “Colorectal cancer: Recent advances in management and treatment”. In: *World Journal of Clinical Oncology* 15.9 (Sept. 2024), 1136–1156. ISSN: 2218-4333. DOI: [10.5306/wjco.v15.i9.1136](https://doi.org/10.5306/wjco.v15.i9.1136). URL: <http://dx.doi.org/10.5306/wjco.v15.i9.1136> (Cited on page 19).
- [67] Xiang-Yuan Tao, Qian-Qian Li, and Yong Zeng. “Clinical application of liquid biopsy in colorectal cancer: detection, prediction, and treatment monitoring”. In: *Molecular Cancer* 23.1 (July 2024). ISSN: 1476-4598. DOI: [10.1186/s12943-024-02063-2](https://doi.org/10.1186/s12943-024-02063-2). URL: <http://dx.doi.org/10.1186/s12943-024-02063-2> (Cited on page 19).
- [68] Emily Vogtmann et al. “Colorectal Cancer and the Human Gut Microbiome: Reproducibility with Whole-Genome Shotgun Sequencing”. In: *PLOS ONE* 11.5 (May 2016). Ed. by John Parkinson, e0155362. ISSN: 1932-6203. DOI: [10.1371/journal.pone.0155362](https://doi.org/10.1371/journal.pone.0155362). URL: <http://dx.doi.org/10.1371/journal.pone.0155362> (Cited on page 19).
- [69] Qiang Feng et al. “Gut microbiome development along the colorectal adenoma–carcinoma sequence”. In: *Nature Communications* 6.1 (Mar. 2015). ISSN: 2041-1723. DOI: [10.1038/ncomms7528](https://doi.org/10.1038/ncomms7528). URL: <http://dx.doi.org/10.1038/ncomms7528> (Cited on page 19).
- [70] Jun Yu et al. “Metagenomic analysis of faecal microbiome as a tool towards targeted non-invasive biomarkers for colorectal cancer”. In: *Gut* 66.1 (Sept. 2015), 70–78. ISSN: 1468-3288. DOI: [10.1136/gutjnl-2015-309800](https://doi.org/10.1136/gutjnl-2015-309800). URL: <http://dx.doi.org/10.1136/gutjnl-2015-309800> (Cited on page 19).

- [71] Georg Zeller et al. “Potential of fecal microbiota for early-stage detection of colorectal cancer”. In: *Molecular Systems Biology* 10.11 (Nov. 2014). ISSN: 1744-4292. DOI: [10.15252/msb.20145645](https://doi.org/10.15252/msb.20145645). URL: <http://dx.doi.org/10.15252/msb.20145645> (Cited on pages 19, 114).
- [72] Zhenwei Dai et al. “Multi-cohort analysis of colorectal cancer metagenome identified altered bacteria across populations and universal bacterial markers”. In: *Microbiome* 6.1 (Apr. 2018). ISSN: 2049-2618. DOI: [10.1186/s40168-018-0451-2](https://doi.org/10.1186/s40168-018-0451-2). URL: <http://dx.doi.org/10.1186/s40168-018-0451-2> (Cited on pages 19, 114, 115).
- [73] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. 2016. DOI: [10.48550/ARXIV.1602.04938](https://arxiv.org/abs/1602.04938). URL: <https://arxiv.org/abs/1602.04938> (Cited on pages 21, 26).
- [74] Sharath M. Shankaranarayana and Davor Runje. “ALIME: Autoencoder Based Approach for Local Interpretability”. In: *Intelligent Data Engineering and Automated Learning – IDEAL 2019*. Springer International Publishing, 2019, 454–463. ISBN: 9783030336073. DOI: [10.1007/978-3-030-33607-3_49](https://doi.org/10.1007/978-3-030-33607-3_49). URL: http://dx.doi.org/10.1007/978-3-030-33607-3_49 (Cited on pages 21, 28).
- [75] Scott Lundberg and Su-In Lee. *A Unified Approach to Interpreting Model Predictions*. 2017. DOI: [10.48550/ARXIV.1705.07874](https://arxiv.org/abs/1705.07874). URL: <https://arxiv.org/abs/1705.07874> (Cited on pages 21, 32).
- [76] Ramaravind Kommiya Mothilal, Amit Sharma, and Chenhao Tan. “Explaining Machine Learning Classifiers through Diverse Counterfactual Explanations”. In: (2019). DOI: [10.48550/ARXIV.1905.07697](https://arxiv.org/abs/1905.07697). URL: <https://arxiv.org/abs/1905.07697> (Cited on pages 21, 36).
- [77] Damien Garreau and Ulrike von Luxburg. *Explaining the Explainer: A First Theoretical Analysis of LIME*. 2020. DOI: [10.48550/ARXIV.2001.03447](https://arxiv.org/abs/2001.03447). URL: <https://arxiv.org/abs/2001.03447> (Cited on page 28).
- [78] Niloofar Ranjbar and Reza Safabakhsh. *Using Decision Tree as Local Interpretable Model in Autoencoder-based LIME*. 2022. DOI: [10.48550/ARXIV.2204.03321](https://arxiv.org/abs/2204.03321). URL: <https://arxiv.org/abs/2204.03321> (Cited on page 29).
- [79] Luke Merrick and Ankur Taly. “The Explanation Game: Explaining Machine Learning Models Using Shapley Values”. In: *Machine Learning and Knowledge Extraction*. Springer International Publishing, 2020, 17–38. ISBN: 9783030573218. DOI: [10.1007/978-3-030-57321-8_2](https://doi.org/10.1007/978-3-030-57321-8_2). URL: http://dx.doi.org/10.1007/978-3-030-57321-8_2 (Cited on page 32).
- [80] I. Elizabeth Kumar et al. *Problems with Shapley-value-based explanations as feature importance measures*. 2020. DOI: [10.48550/ARXIV.2002.11097](https://arxiv.org/abs/2002.11097). URL: <https://arxiv.org/abs/2002.11097> (Cited on page 33).
- [81] Hui Wen Loh et al. “Application of explainable artificial intelligence for healthcare: A systematic review of the last decade (2011–2022)”. In: *Computer Methods and Programs in Biomedicine* 226 (Nov. 2022), p. 107161. ISSN: 0169-2607. DOI: [10.1016/j.cmpb.2022.107161](https://doi.org/10.1016/j.cmpb.2022.107161). URL: <http://dx.doi.org/10.1016/j.cmpb.2022.107161> (Cited on page 33).

- [82] Andrea Ferrario and Michele Loi. “The Robustness of Counterfactual Explanations Over Time”. In: *IEEE Access* 10 (2022), 82736–82750. ISSN: 2169-3536. DOI: [10.1109/access.2022.3196917](https://doi.org/10.1109/access.2022.3196917). URL: <http://dx.doi.org/10.1109/ACCESS.2022.3196917> (Cited on page 36).
- [83] Sandra Wachter, Brent Mittelstadt, and Chris Russell. “Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR”. In: (2017). DOI: [10.48550/ARXIV.1711.00399](https://doi.org/10.48550/ARXIV.1711.00399). URL: <https://arxiv.org/abs/1711.00399> (Cited on page 36).
- [84] Leo Breiman. In: *Machine Learning* 45.1 (2001), 5–32. ISSN: 0885-6125. DOI: [10.1023/a:1010933404324](https://doi.org/10.1023/a:1010933404324). URL: <http://dx.doi.org/10.1023/A:1010933404324> (Cited on page 39).
- [85] Jerome H. Friedman. “Greedy function approximation: A gradient boosting machine.” In: *The Annals of Statistics* 29.5 (Oct. 2001). ISSN: 0090-5364. DOI: [10.1214/aos/1013203451](https://doi.org/10.1214/aos/1013203451). URL: <http://dx.doi.org/10.1214/aos/1013203451> (Cited on page 40).
- [86] Andrew Maltez Thomas et al. “Metagenomic analysis of colorectal cancer datasets identifies cross-cohort microbial diagnostic signatures and a link with choline degradation”. In: *Nature Medicine* 25.4 (Apr. 2019), 667–678. ISSN: 1546-170X. DOI: [10.1038/s41591-019-0405-7](https://doi.org/10.1038/s41591-019-0405-7). URL: <http://dx.doi.org/10.1038/s41591-019-0405-7> (Cited on page 114).
- [87] Wenxuan Zuo, Sonia Michail, and Fengzhu Sun. “Metagenomic Analyses of Multiple Gut Datasets Revealed the Association of Phage Signatures in Colorectal Cancer”. In: *Frontiers in Cellular and Infection Microbiology* 12 (June 2022). ISSN: 2235-2988. DOI: [10.3389/fcimb.2022.918010](https://doi.org/10.3389/fcimb.2022.918010). URL: <http://dx.doi.org/10.3389/fcimb.2022.918010> (Cited on page 114).
- [88] Nagavardhini Avuthu and Chittibabu Guda. “Meta-Analysis of Altered Gut Microbiota Reveals Microbial and Metabolic Biomarkers for Colorectal Cancer”. In: *Microbiology Spectrum* 10.4 (Aug. 2022). Ed. by Jan Claesen. ISSN: 2165-0497. DOI: [10.1128/spectrum.00013-22](https://doi.org/10.1128/spectrum.00013-22). URL: <http://dx.doi.org/10.1128/spectrum.00013-22> (Cited on page 114).
- [89] Areej A. Alhazmi et al. “Gut Microbial and Associated Metabolite Markers for Colorectal Cancer Diagnosis”. In: *Microorganisms* 11.8 (Aug. 2023), p. 2037. ISSN: 2076-2607. DOI: [10.3390/microorganisms11082037](https://doi.org/10.3390/microorganisms11082037). URL: <http://dx.doi.org/10.3390/microorganisms11082037> (Cited on page 114).
- [90] Kaitlin J. Flynn, Nielson T. Baxter, and Patrick D. Schloss. “Metabolic and Community Synergy of Oral Bacteria in Colorectal Cancer”. In: *mSphere* 1.3 (June 2016). Ed. by Katherine McMahon. ISSN: 2379-5042. DOI: [10.1128/msphere.00102-16](https://doi.org/10.1128/msphere.00102-16). URL: <http://dx.doi.org/10.1128/msphere.00102-16> (Cited on page 114).

- [91] Yan-Dong Li, Kang-Xin He, and Wei-Fang Zhu. “Correlation between invasive microbiota in margin-surrounding mucosa and anastomotic healing in patients with colorectal cancer”. In: *World Journal of Gastrointestinal Oncology* 11.9 (Sept. 2019), 717–728. ISSN: 1948-5204. DOI: [10.4251/wjgo.v11.i9.717](https://doi.org/10.4251/wjgo.v11.i9.717). URL: <http://dx.doi.org/10.4251/wjgo.v11.i9.717> (Cited on page 115).
- [92] Shintaro Okumura et al. “Gut bacteria identified in colorectal cancer patients promote tumourigenesis via butyrate secretion”. In: *Nature Communications* 12.1 (Sept. 2021). ISSN: 2041-1723. DOI: [10.1038/s41467-021-25965-x](https://doi.org/10.1038/s41467-021-25965-x). URL: <http://dx.doi.org/10.1038/s41467-021-25965-x> (Cited on page 115).
- [93] So-Ra Han et al. “Complete genome sequencing of *Shigella* sp. PAMC 28760: Identification of CAZyme genes and analysis of their potential role in glycogen metabolism for cold survival adaptation”. In: *Microbial Pathogenesis* 137 (Dec. 2019), p. 103759. ISSN: 0882-4010. DOI: [10.1016/j.micpath.2019.103759](https://doi.org/10.1016/j.micpath.2019.103759). URL: <http://dx.doi.org/10.1016/j.micpath.2019.103759> (Cited on page 115).
- [94] Fedor Galkin et al. “Human Gut Microbiome Aging Clock Based on Taxonomic Profiling and Deep Learning”. In: *iScience* 23.6 (June 2020), p. 101199. ISSN: 2589-0042. DOI: [10.1016/j.isci.2020.101199](https://doi.org/10.1016/j.isci.2020.101199). URL: <http://dx.doi.org/10.1016/j.isci.2020.101199> (Cited on page 115).
- [95] Weiwei Chu et al. “Metagenomic analysis identified microbiome alterations and pathological association between intestinal microbiota and polycystic ovary syndrome”. In: *Fertility and Sterility* 113.6 (June 2020), 1286–1298.e4. ISSN: 0015-0282. DOI: [10.1016/j.fertnstert.2020.01.027](https://doi.org/10.1016/j.fertnstert.2020.01.027). URL: <http://dx.doi.org/10.1016/j.fertnstert.2020.01.027> (Cited on page 115).
- [96] Mark F. Richardson et al. “Population Genomics of the *Wolbachia* Endosymbiont in *Drosophila melanogaster*”. In: *PLoS Genetics* 8.12 (Dec. 2012). Ed. by Artyom Kopp, e1003129. ISSN: 1553-7404. DOI: [10.1371/journal.pgen.1003129](https://doi.org/10.1371/journal.pgen.1003129). URL: <http://dx.doi.org/10.1371/journal.pgen.1003129> (Cited on page 115).
- [97] Asem Sanjit Singh et al. “Antibiotic alters host’s gut microbiota, fertility, and antimicrobial peptide gene expression vis-à-vis ampicillin treatment on model organism *Drosophila melanogaster*”. In: *International Microbiology* (Mar. 2024). ISSN: 1618-1905. DOI: [10.1007/s10123-024-00507-9](https://doi.org/10.1007/s10123-024-00507-9). URL: <http://dx.doi.org/10.1007/s10123-024-00507-9> (Cited on page 116).
- [98] Ana T Eugénio, Marta S P Marialva, and Patrícia Beldade. “Effects of *Wolbachia* on Transposable Element Expression Vary Between *Drosophila melanogaster* Host Genotypes”. In: *Genome Biology and Evolution* 15.3 (Feb. 2023). Ed. by Andrea Betancourt. ISSN: 1759-6653. DOI: [10.1093/gbe/evad036](https://doi.org/10.1093/gbe/evad036). URL: <http://dx.doi.org/10.1093/gbe/evad036> (Cited on page 116).
- [99] Jing Chen et al. “A specific innate immune response silences the virulence of *Pseudomonas aeruginosa* in a latent infection model in the *Drosophila melanogaster* host”. In: *PLOS Pathogens* 20.6 (June 2024). Ed. by David Skurnik, e1012252. ISSN: 1553-7374. DOI: [10.1371/journal.ppat.1012252](https://doi.org/10.1371/journal.ppat.1012252). URL: <http://dx.doi.org/10.1371/journal.ppat.1012252> (Cited on page 116).

- [100] Christine V. Macpherson et al. “The untapped potential of cell culture in disentangling insect-microbial relationships”. In: *Microbiome Research Reports* 3.2 (Feb. 2024). ISSN: 2771-5965. DOI: [10.20517/mrr.2023.66](https://doi.org/10.20517/mrr.2023.66). URL: <http://dx.doi.org/10.20517/mrr.2023.66> (Cited on page 116).

Ý NGHĨA CỦA OTU

Bảng A.1. Bảng đối chiếu OTU

OTUcode	Species
Otu0024	Bifidobacterium_adolescentis
Otu0028	Bifidobacterium_bifidum
Otu0029	Bifidobacterium_breve
Otu0035	Bifidobacterium_longum
Otu0122	Rhodococcus_erythropolis
Otu0169	Arthrobacter_sp_LS16
Otu0183	Rothia_dentocariosa
Otu0193	Micromonospora_aurantiaca
Otu0217	Pseudonocardia_sp_EC080610-09
Otu0218	Pseudonocardia_sp_EC080619-01
Otu0228	Streptomyces_avermitilis
Otu0233	Streptomyces_fulvissimus
Otu0236	Streptomyces_griseus
Otu0253	Streptomyces_sp_S10(2016)
Otu0280	Hydrogenobaculum_sp_HO
Otu0283	Thermocrinis_ruber
Otu0290	Bacteroides_cellulosilyticus
Otu0292	Bacteroides_helcogenes
Otu0294	Bacteroides_salanitronis
Otu0302	Porphyromonas_asaccharolytica
Otu0303	Porphyromonas_gingivalis
Otu0309	Prevotella_intermedia
Otu0312	Prevotella_sp_oral_taxon_299
Otu0345	Blattabacterium_punctulatus
Otu0357	Capnocytophaga_canimorsus
Otu0345	Blattabacterium_punctulatus
Otu0357	Capnocytophaga_canimorsus

OTUcode	Species
Otu0383	Myroides_profundi
Otu0361	Cellulophaga_baltica
Otu0406	Pedobacter_heparinus
Otu0420	Candidatus_Saccharibacteria_bacterium_RAAC3_TM7_1
Otu0430	Chlamydia_trachomatis
Otu0468	Cyanothece_sp_ATCC_51142
Otu0479	Synechococcus_elongatus
Otu0493	Synechococcus_sp_WH_7803
Otu0504	Nostoc_sp_PCC_7120
Otu0513	Leptolyngbya_sp_PCC_7376
Otu0528	Deferribacter_desulfuricans
Otu0547	Thermus_oshimai
Otu0550	Thermus_sp_CCB_US3_UF1
Otu0562	Anoxybacillus_gonensis
Otu0565	Bacillus_atrophaeus
Otu0580	Bacillus_paralicheniformis
Otu0639	Paenibacillus_riograndensis
Otu0664	Staphylococcus_argenteus
Otu0672	Staphylococcus_hyicus
Otu0677	Staphylococcus_schleiferi
Otu0679	Staphylococcus_warneri
Otu0727	Lactobacillus_rhamnosus
Otu0760	Streptococcus_lutetiensis
Otu0781	Streptococcus_thermophilus
Otu0793	Clostridium_beijerinckii
Otu0800	Clostridium_ljungdahlii
Otu0847	Filifactor_alocis
Otu0857	Ruminococcus_albus
Otu0868	Halobacteroides_halobius
Otu0879	Thermoanaerobacter_mathranii
Otu0915	Parvimonas_micra
Otu0917	Fusobacterium_hwasookii
Otu0923	Sneathia_amnii
Otu0969	Bartonella_grahamii
Otu0990	Brucella_canis
Otu0993	Brucella_microti
Otu0994	Brucella_ovis
Otu0998	Ochrobactrum_anthropi
Otu1116	Wolbachia_endosymbiont_of_Drosophila_melanogaster
Otu1118	Wolbachia_endosymbiont_of_Onchocerca_ochengi
Otu1129	Rickettsia_africae
Otu1134	Rickettsia_conorii

OTUcode	Species
Otu1136	Rickettsia_heilongjiangensis
Otu1140	Rickettsia_monacensis
Otu1142	Rickettsia_parkeri
Otu1145	Rickettsia_rhipicephali
Otu1203	Taylorella_asinigenitalis
Otu1204	Taylorella_equiagenitalis
Otu1218	Burkholderia_pyrrocinia
Otu1231	Burkholderia_ubonensis
Otu1288	Janthinobacterium_sp_B9-8
Otu1289	Janthinobacterium_sp_Marseille
Otu1310	Methylovorus_glucosotrophus
Otu1316	Neisseria_elongata
Otu1324	Nitrosomonas_sp_AL212
Otu1363	Desulfovibrio_vulgaris
Otu1372	Geobacter_daltonii
Otu1385	Haliangium_ochraceum
Otu1455	Alteromonas_sp_Mac1
Otu1457	Alteromonas_stellipolaris
Otu1521	Thioalkalivibrio_nitratireducens
Otu1547	Citrobacter_freundii
Otu1550	Citrobacter_sp_FDAARGOS_156
Otu1568	Enterobacter_hormaechei
Otu1600	Pantoea_sp_PSNIH1
Otu1612	Proteus_vulgaris
Otu1617	Salmonella_bongori
Otu1628	Shigella_dysenteriae
Otu1631	Shigella_sp_PAMC_28760
Otu1636	Wigglesworthia_glossinidia
Otu1644	Yersinia_frederiksenii
Otu1727	Azotobacter_chroococcum
Otu1771	Pseudomonas_stutzeri
Otu1776	Pseudomonadaceae_bacterium_C6819
Otu1784	Francisella_sp_FSC1006
Otu1800	Grimontia_hollisae
Otu1853	Brachyspira_murdochii
Otu1877	Treponema_denticola
Otu1882	Treponema_putidum
Otu1902	Spiroplasma_culicicola
Otu1911	Mycoplasma_arthritis
Otu1915	Mycoplasma_canadense
Otu1947	Thermodesulfobacterium_geofontis
Otu1952	Marinitoga_piezophila

OTUcode	Species
Otu1971	Thermotoga_sp_RQ2
Otu1980	Methyacidiphilum_fumariolicum

HƯỚNG DẪN CODE CHẠY THỰC NGHIỆM

Dưới đây là các dòng lệnh chạy thực nghiệm trong code này đã được lưu trong xai.sh và xai2.sh:

```
python lime_export.py -r data -i yu -n 50 --sample 1 --model rf_model --selection_method lime --k 10 --rf_n_estimators 500
python lime_export.py -r data -i yu -n 50 --sample 1 --model gbc_model --selection_method lime --k 10 --n_estimators 500

python lime_export.py -r data -i yu -n 50 --sample 1 --model rf_model --selection_method alime --k 10 --rf_n_estimators 500
python lime_export.py -r data -i yu -n 50 --sample 1 --model gbc_model --selection_method alime --k 10 --n_estimators 500

python lime_export.py -r data -i yu -n 50 --sample 1 --model rf_model --selection_method shap --k 10 --rf_n_estimators 500
python lime_export.py -r data -i yu -n 50 --sample 1 --model gbc_model --selection_method shap --k 10 --n_estimators 500

python lime_export.py -r data -i yu -n 50 --sample 1 --model rf_model --selection_method dice --k 10 --rf_n_estimators 500
python lime_export.py -r data -i yu -n 50 --sample 1 --model gbc_model --selection_method dice --k 10 --n_estimators 500
```

Hình B.1. Các dòng lệnh thực nghiệm của tập Yu

Hình B.1 là các dòng lệnh thực nghiệm của tập Yu với cả 4 phương pháp XAI là LIME, ALIME, SHAP, DiCE và 2 mô hình RF, GBC. Trong đó tham số -n là số lượng đặc trưng chọn lọc, ở đây là 50 đặc trưng với các đặc trưng được trích xuất từ mẫu có chỉ số 1 của tập dữ liệu. Số lượng cây trong mô hình được lựa chọn là 500. Số lượng 500 cây được chọn vì nó là giá trị mặc định hợp lý, đảm bảo mô hình đủ mạnh để học từ dữ liệu, đồng thời không làm chậm quá trình phân tích. Tham số -k là số lần lặp lại trong quá trình k-fold cross-validation. Trong 10-fold cross-validation, dữ liệu được chia thành 10 phần. Mô hình sẽ được huấn luyện trên 9 phần và kiểm tra trên 1 phần còn lại, sau đó lặp lại quy trình này cho tất cả 10 phần.

```
python lime_export.py -r data -i feng -n 50 --sample 1 --model rf_model --selection_method lime --k 10 --rf_n_estimators 500
python lime_export.py -r data -i feng -n 50 --sample 1 --model gbc_model --selection_method lime --k 10 --n_estimators 500

python lime_export.py -r data -i feng -n 50 --sample 1 --model rf_model --selection_method alime --k 10 --rf_n_estimators 500
python lime_export.py -r data -i feng -n 50 --sample 1 --model gbc_model --selection_method alime --k 10 --n_estimators 500

python lime_export.py -r data -i feng -n 50 --sample 1 --model rf_model --selection_method shap --k 10 --rf_n_estimators 500
python lime_export.py -r data -i feng -n 50 --sample 1 --model gbc_model --selection_method shap --k 10 --n_estimators 500

python lime_export.py -r data -i feng -n 50 --sample 1 --model rf_model --selection_method dice --k 10 --rf_n_estimators 500
python lime_export.py -r data -i feng -n 50 --sample 1 --model gbc_model --selection_method dice --k 10 --n_estimators 500
```

Hình B.2. Các dòng lệnh thực nghiệm của tập Feng

Hình B.2 là các dòng lệnh thực nghiệm của tập Feng với cả 4 phương pháp XAI là

LIME, ALIME, SHAP, DiCE và 2 mô hình RF, GBC. Như đã mô tả ở trên thì tham số `-n` là số lượng đặc trưng chọn lọc, ở đây là 50 đặc trưng với các đặc trưng được trích xuất từ mẫu có chỉ số 1 của tập dữ liệu. Số lượng cây trong mô hình được lựa chọn là 500. Số lượng 500 cây được chọn vì nó là giá trị mặc định hợp lý, đảm bảo mô hình đủ mạnh để học từ dữ liệu, đồng thời không làm chậm quá trình phân tích. Tham số `-k` là số lần lặp lại trong quá trình k-fold cross-validation. Trong 10-fold cross-validation, dữ liệu được chia thành 10 phần. Mô hình sẽ được huấn luyện trên 9 phần và kiểm tra trên 1 phần còn lại, sau đó lặp lại quy trình này cho tất cả 10 phần.

```
python lime_export.py -r data -i zeller -n 50 --sample 1 --model rf_model --selection_method lime --k 10 --rf_n_estimators 500
python lime_export.py -r data -i zeller -n 50 --sample 1 --model gbc_model --selection_method lime --k 10 --n_estimators 500

python lime_export.py -r data -i zeller -n 50 --sample 1 --model rf_model --selection_method alime --k 10 --rf_n_estimators 500
python lime_export.py -r data -i zeller -n 50 --sample 1 --model gbc_model --selection_method alime --k 10 --n_estimators 500

python lime_export.py -r data -i zeller -n 50 --sample 1 --model rf_model --selection_method shap --k 10 --rf_n_estimators 500
python lime_export.py -r data -i zeller -n 50 --sample 1 --model gbc_model --selection_method shap --k 10 --n_estimators 500

python lime_export.py -r data -i zeller -n 50 --sample 1 --model rf_model --selection_method dice --k 10 --rf_n_estimators 500
python lime_export.py -r data -i zeller -n 50 --sample 1 --model gbc_model --selection_method dice --k 10 --n_estimators 500
```

Hình B.3. Các dòng lệnh thực nghiệm của tập Zeller

Hình B.3 là các dòng lệnh thực nghiệm của tập Zeller với cả 4 phương pháp XAI là LIME, ALIME, SHAP, DiCE và 2 mô hình RF, GBC. Trong đó các tham số tương tự như hình B.1 và B.2 đã được mô tả như trên.

```
python lime_export.py -r data -i vogtmann -n 50 --sample 1 --model rf_model --selection_method lime --k 10 --rf_n_estimators 500
python lime_export.py -r data -i vogtmann -n 50 --sample 1 --model gbc_model --selection_method lime --k 10 --n_estimators 500

python lime_export.py -r data -i vogtmann -n 50 --sample 1 --model rf_model --selection_method tsp --k 10 --rf_n_estimators 500
python lime_export.py -r data -i vogtmann -n 50 --sample 1 --model gbc_model --selection_method tsp --k 10 --n_estimators 500

python lime_export.py -r data -i vogtmann -n 50 --sample 1 --model rf_model --selection_method shap --k 10 --rf_n_estimators 500
python lime_export.py -r data -i vogtmann -n 50 --sample 1 --model gbc_model --selection_method shap --k 10 --n_estimators 500

python lime_export.py -r data -i vogtmann -n 50 --sample 1 --model rf_model --selection_method dice --k 10 --rf_n_estimators 500
python lime_export.py -r data -i vogtmann -n 50 --sample 1 --model gbc_model --selection_method dice --k 10 --n_estimators 500
```

Hình B.4. Các dòng lệnh thực nghiệm của tập Vogtmann

Hình B.4 là các dòng lệnh thực nghiệm của tập Vogtmann với cả 4 phương pháp XAI là LIME, ALIME, SHAP, DiCE và 2 mô hình RF, GBC. Cũng tương tự như trên, các tham số đã được mô tả và sử dụng như các hình B.1, B.2, B.3 và đã được diễn giải ở trên.

Hình B.5 là các dòng lệnh thực nghiệm của các tập dữ liệu gốc Yu, Zeller, Feng, Vogtmann với cả 4 phương pháp XAI là LIME, ALIME, SHAP, DiCE và 2 mô hình RF, GBC. nghĩa là thay vì chọn lọc ra 50 đặc trưng thì ở đây chúng tôi sẽ chạy qua hết tất cả các đặc trưng có trong từng tập dữ liệu. Tham số `-k` là số lần lặp lại trong quá trình k-fold cross-validation. Trong 10-fold cross-validation, dữ liệu được chia thành 10 phần. Mô hình sẽ được huấn luyện trên 9 phần và kiểm tra trên 1 phần còn lại, sau đó lặp lại quy trình này cho tất cả 10 lần.

Sau đó các kết quả XAI được thực hiện trên Jupyter Notebook trực quan hóa kết quả để thấy rõ các đặc trưng bệnh hoặc không bệnh và diễn giải dự đoán của mô hình qua từng phương pháp. Để giải thích và phân tích dự đoán của mô hình, các phương pháp XAI đã được áp dụng nhằm nhận diện các đặc trưng quan trọng và trực quan hóa kết quả. Ban đầu, đề tài đã sử dụng các phương pháp như LIME, ALIME, SHAP, và DICE để lựa chọn 50 đặc


```
python lime_export.py -r data -i yu --model gbc_model --k 10  
python lime_export.py -r data -i feng --model gbc_model --k 10  
python lime_export.py -r data -i zeller --model gbc_model --k 10  
python lime_export.py -r data -i vogtmann --model gbc_model --k 10  
python lime_export.py -r data -i yu --model rf_model --k 10  
python lime_export.py -r data -i feng --model rf_model --k 10  
python lime_export.py -r data -i zeller --model rf_model --k 10  
python lime_export.py -r data -i vogtmann --model rf_model --k 10
```

Hình B.5. Các dòng lệnh của dữ liệu gốc.

trưng quan trọng nhất từ tập dữ liệu. Kết quả này sẽ được trực quan hóa và trình bày trong các file tương ứng như LIME.ipynb, ALIME.ipynb, SHAP.ipynb, và DICE.ipynb. Tại đây, các đặc trưng được trực quan theo thứ tự từ 1 đến 50 để quan sát đóng góp của từng đặc trưng vào mô hình. Phân tích này nhằm trả lời câu hỏi quan trọng: liệu khi số lượng đặc trưng tăng lên, các đặc trưng phía sau có còn đóng góp đáng kể cho mô hình hay không.

Sau khi xác định các đặc trưng quan trọng, tiếp tục thực hiện bước trực quan hóa biểu đồ min-max của các giá trị trọng số mà mỗi phương pháp XAI tính toán được. Điều này giúp hiểu rõ hơn về mức độ ảnh hưởng của từng đặc trưng được chọn. Cụ thể, các biểu đồ histogram và min-max của LIME, ALIME, SHAP, và DICE được lưu lần lượt tại các file LIME_histogram.ipynb, LIME_minmax.ipynb, ALIME_histogram.ipynb, ALIME_minmax.ipynb, SHAP_histogram.ipynb, SHAP_minmax.ipynb, DICE_histogram.ipynb và DICE_minmax.ipynb. Các biểu đồ này không chỉ cung cấp cái nhìn tổng quan về sự phân phối của trọng số mà còn giúp so sánh hiệu quả giữa các phương pháp trong việc lựa chọn các đặc trưng.

Bước quan trọng nhất trong nghiên cứu là sử dụng bốn phương pháp XAI để dự đoán và giải thích mô hình. Với kết quả huấn luyện 50 đặc trưng quan trọng nhất sau khi lọc bằng hai mô hình RF và GBC. Từng kết quả huấn luyện đã trình bày giải thích một cách chi tiết từ XAI để làm rõ các đặc trưng tác động tích cực hoặc tiêu cực đến hiệu suất dự đoán và kết quả dự đoán của XAI có trùng khớp với mô hình hay không. Kết quả này được trình bày trong các file LIME_XAI_RF.ipynb, ALIME_XAI_RF.ipynb, SHAP_XAI_RF.ipynb và DICE_XAI_RF.ipynb. Sự giải thích của từng phương pháp cung cấp thông tin hữu ích để hiểu sâu hơn về cách thức mô hình đưa ra dự đoán và mối liên hệ giữa các đặc trưng với các nhãn đầu ra.

Để tăng tính khách quan, đề tài cũng thực hiện thử nghiệm trên 50 mẫu ngẫu nhiên và phân tích tần suất xuất hiện của các đặc trưng quan trọng nhất trong các mẫu này. Kết quả cho thấy sự xuất hiện lặp lại của các đặc trưng ở tần suất cao, và trích xuất

những đặc trưng có độ quan trọng cao (trọng số lớn) khi được lựa chọn với 50 mẫu ngẫu nhiên. Những kết quả này được trình bày trong các file LIME_random50sample.ipynb, ALIME_random50sample.ipynb, SHAP_random50sample.ipynb và DICE_random50sample.ipynb.

Cuối cùng, để hiểu rõ hơn về dữ liệu gốc, sau khi huấn luyện tất với qua tất cả các đặc trưng trong từng tập dữ liệu, kết quả được trực quan hóa bằng các biểu đồ như boxplot và histogram. Điều này giúp kiểm tra các vấn đề tiềm năng như phân phối dữ liệu với tất cả các đặc trưng có trong dữ liệu. Các biểu đồ này được lưu trữ trong file RAW.ipynb và RAW_histogram.ipynb.